

imgs/pee-logo.png

imgs/coppe-logo.pdf

Reconhecimento Acústico de Alvos Submarinos no Dataset IARA

Da Reprodução dos Baselines à Evolução dos Modelos SVM Nyström (MEL e LOFAR)

Evandro Rocha


Universidade Federal do Rio de Janeiro
UFRJ / COPPE / PEE

2026

Agenda da Apresentação

Contexto e Dataset IARA
Representações Espectrais
Reprodução dos Baselines
A Proposta com SVM Nyström
Evolução Experimental: SVM em MEL
Hiperparâmetros e Limites do SVM

Incerteza e Opção de Rejeição
Robustez ao CPA
Síntese e Matrizes de Confusão
Estratégia de SVM em Cascata
Discussão e Próximos Passos



Dataset IARA (Silva et al., 2025)

O **IARA** é a maior base pública para classificação acústica submarina na costa brasileira (PMPAS-BS / Petrobras):

Base Total vs. Benchmark:

- ▶ **Base Completa IARA: 1.825 gravações** (129 h 34 min, ~ 50 GB) divididas em 8 coleções (Observatórios e Gliders).
- ▶ **Benchmark Multiclasse: 639 áudios** (> 64 h) com alvos únicos e identificados via AIS.
- ▶ **4 Classes Reais:**
 - ▶ **SMALL, MEDIUM, LARGE, BACKGROUND.**

Protocolo $5 \times 2cv$ (10 Folds)

Exclusive Ships on Test: A partição é estritamente dividida no nível de **ID de arquivo físico original** (639 áudios $\times 10 = 6.390$ testes). Nenhuma janela de um mesmo navio reside simultaneamente em treino e teste (*zero data leakage*).

Distribuição das Classes Acústicas e Desbalanceamento

imgs/pee-logo-short.png

O dataset é composto por 639 gravações de áudio físicas, apresentando desbalanceamento natural entre categorias:

Classe Acústica	Porte Físico	Áudios Únicos	Proporção (%)	Testes ($5 \times 2cv$)	Assinatura Predominante
SMALL	< 50 m	178	27,9%	1.780	Lanchas, botes (baixa SNR, motores rápidos)
MEDIUM	50 – 100 m	149	23,3%	1.490	Rebocadores, barcos de apoio e pesca
LARGE	> 100 m	214	33,5%	2.140	Petroleiros, cargueiros (raias puras, cavitação)
BACKGROUND	Sem alvos	98	15,3%	980	Ruído ambiente marítimo natural
Total	—	639	100,0%	6.390	> 64 horas de gravações reais

Impacto do Desbalanceamento no Treinamento

- ▶ A classe **LARGE** representa um terço do dataset (33,5%), enquanto **BACKGROUND** corresponde a apenas 15,3%.
- ▶ Devido à disparidade energética e amostral, modelos ingênuos tendem a negligenciar classes minoritárias, justificando o uso mandatório do **Índice SP** como métrica de avaliação.

Para mitigar o desbalanceamento das classes, adota-se o **Índice SP** como métrica primária:

Índice SP (Média Geométrica dos Recalls por Classe)

$$SP = \sqrt[4]{R_{SMALL} \cdot R_{MEDIUM} \cdot R_{LARGE} \cdot R_{BACKGROUND}} \times 100\%$$

Propriedades Críticas do Índice SP:

- ▶ **Penalização Severa de Zeros:** Se qualquer uma das 4 classes apresentar $\text{Recall}_k = 0\%$, o índice zera instantaneamente ($\text{SP} = 0\%$).
- ▶ **Robustez contra Vieses:** Diferentemente da acurácia global (que pode ser inflada pela classe majoritária *LARGE*), o SP avalia o equilíbrio real e só é alto se houver acerto consistente em todas as categorias.
- ▶ **Exigência Operacional:** Garante que embarcações pequenas (*SMALL*) e ruído (*BACKGROUND*) não sejam negligenciados.

Representações Espectrais: Vetores de Entrada dos Modelos

imgs/pee-logo-short.png

O áudio contínuo é fatiado em janelas de 0,512 s e convertido em vetores numéricos para alimentar os classificadores:

1. Espectro LOFAR (1024 Atributos)

- ▶ **Vetor de Entrada:** 1024 valores.
- ▶ **O que mede:** Energia sonora em frequências finas e lineares (tons puros e harmônicos periódicos).
- ▶ **Papel no Modelo:** Máxima riqueza e resolução detalhada em frequência.

2. Espectro MEL (256 Atributos)

- ▶ **Vetor de Entrada:** 256 valores.
- ▶ **O que mede:** Energia agrupada em faixas perceptuais (timbre, envelope sonoro e ruídos contínuos).
- ▶ **Papel no Modelo:** Representação compacta e suave, resistente a variações espúrias.

Como Alimentam os Modelos?

Cada janela acústica gera um vetor (1024 ou 256 dimensões) processado individualmente por modelos tabulares (MLP, SVM, RF) ou empilhado temporalmente para redes profundas (CNN, CRNN).

Reprodução Local dos Baselines do Artigo (Silva et al., 2025)

imgs/pee-logo-short.png

Antes da proposição de novas abordagens, foi replicado com rigor o pipeline do artigo nos 10 folds ($5 \times 2cv$):

Classificador	Espectro	Índice SP (%) (Artigo)	Índice SP (%) (Local)	Diferença
Random Forest (RF)	MEL	$62,22 \pm 1,86$	$62,10 \pm 1,92$	$-0,12$ p.p.
Random Forest (RF)	LOFAR	$56,92 \pm 1,69$	$56,85 \pm 1,75$	$-0,07$ p.p.
MLP [32, 16]	MEL	$63,38 \pm 1,81$	$64,66 \pm 2,11$	$+1,28$ p.p.
MLP [32, 16]	LOFAR	$66,51 \pm 1,39$	$66,25 \pm 1,78$	$-0,26$ p.p.
CNN Convolucional	MEL	$63,52 \pm 2,26$	$63,40 \pm 2,15$	$-0,12$ p.p.
CNN Convolucional	LOFAR	$66,05 \pm 1,90$	$65,92 \pm 1,85$	$-0,13$ p.p.

Conclusão da Reprodução

Os resultados reproduzidos localmente confirmam com precisão estatística os valores da literatura. O **MLP LOFAR** ($66,51\%$ **Artigo** / $66,25\%$ **Local**) consolidou-se como o benchmark principal a ser superado.

Método Clássico em UATR

O SVM foi historicamente um dos primeiros métodos aplicados em UATR e continua sendo empregado como baseline de referência em trabalhos recentes (e.g., Xu et al., reportando 69,24% no **DeepShip**). Contudo, os datasets da literatura são de pequeno a médio porte (**ShipsEar**: 3h; **DeepShip**: 47h); a avaliação em bases de grande escala como o IARA (> 64h) permanecia em aberto.

Lacuna na Literatura:

- ▶ **Dados Limitados:** Validações anteriores restritas a bases pequenas e poucos trânsitos.
- ▶ **Custo Computacional:** Crescimento de memória e tempo $O(N^2)/O(N^3)$ inviabilizava testes massivos.

A Fronteira do Dataset IARA:

- ▶ **Base de Grande Escala:** O IARA é uma das maiores bases públicas mundiais (tráfego real).
- ▶ **Objetivo do Estudo:** Investigar a capacidade e o limite do SVM sob este patamar de complexidade.

O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- ▶ **Volume de Amostras (N no IARA):** N é o número de janelas espectrais de treinamento — MEL (0,512s) $\approx$ 500k janelas; LOFAR (0,058s) $\approx$ 800k janelas.
- ▶ **Custo do RBF Clássico:** A matriz Gram $N \times N$ exigiria $> 1,0$ Terabyte de RAM (inviável).
- ▶ **Aproximação de Nyström (Baixo Rank):** Seleccionam-se m amostras de referência (*landmarks*) para projetar o kernel no espaço linear explícito $\mathbb{R}^m$.
- ▶ **Base Projetada de Treinamento ($N \times m$):**
 - ▶ MEL ($m = 4000$): $500k \times 4000 \times 4B \approx 8$ GB de RAM (overhead total ≈ 10 GB).
 - ▶ LOFAR ($m = 4000$): $800k \times 4000 \times 4B \approx 13$ GB de RAM (overhead total ≈ 15 GB).
- ▶ **Complexidade Linear:** Reduz o treinamento para $O(N \cdot m^2)$, resolvido eficientemente via SGD.
- ▶ **Tamanho do Modelo Final:** Armazena apenas o vetor de pesos linear ($4 \times m$ coeficientes $\approx < 100$ KB).

Evolução do SVM com Espectrograma MEL (Banda Larga)

imgs/pee-logo-short.png

Foi investigada a progressão da capacidade do SVM variando-se o número de componentes m de Nyström e a regularização:

Configuração SVM MEL	Componentes m	Índice SP (%)	Acurácia Bal. (%)	Observação
SVM MEL ($m=300$)	300	$59,96 \pm 3,38$	$62,34 \pm 1,98$	Sub-amostragem severa
SVM MEL ($m=1000$)	1000	$62,96 \pm 2,08$	$64,11 \pm 1,98$	Boa generalização
SVM MEL ($m=2000$)	2000	$63,04 \pm 2,37$	$64,45 \pm 1,93$	Saturação linear
SVM MEL ($m=3000$)	3000	$63,65 \pm 1,99$	$64,77 \pm 1,87$	Incremento consistente
Melhor SVM MEL ($m = 4000$)	4000	$63,78 \pm 1,14$	$64,56 \pm 1,18$	Melhor MEL (ElasticNet, $C=2.0$)
SVM MEL ($m=4000$, $C=0.5$)	4000	$57,51 \pm 1,66$	$58,14 \pm 1,16$	Sub-ajuste por excesso de penalidade

Destaque Experimental no MEL

O ****SVM Golden MEL ($m = 4000$)**** alcançou **** $63,78\% \pm 1,14\%$ de SP****, superando a CNN MEL (63,52%) e o RF MEL (62,22%) com a ****menor variância de todo o benchmark ($\pm 1,14\%$)****!

imgs/pee-logó-short.png

componentes m), atingindo tetos bem definidos:

Espectro	Configuração Avaliada	Comp. <i>m</i>	Reg. <i>C</i>	Índice SP (%)	Acurácia (%)	Diagnóstico Experimental
LOFAR	SVM LOFAR (<i>m</i> =1000)	1000	1,0	57,86 ± 3,83	60,95 ± 2,89	Sub-amostragem severa do espaço 1024-D
LOFAR	SVM LOFAR (<i>m</i> =2000, <i>C</i> =0.1)	2000	0,1	54,84 ± 1,60	59,67 ± 1,28	Sub-ajuste rígido por excesso de penalidade
LOFAR	SVM LOFAR (<i>m</i> =4000, <i>C</i> =0.5, E-Net)	4000	0,5	60,66 ± 2,78	63,23 ± 2,05	Falta de flexibilidade no hiperplano
LOFAR	SVM LOFAR (<i>m</i>=6000, <i>C</i>=1.0, E-Net)	6000	1,0	63,83 ± 1,91	65,47 ± 1,77	Teto Máximo Absoluto LOFAR
MEL	SVM MEL (<i>m</i> =4000, <i>C</i> =0.5, E-Net)	4000	0,5	57,51 ± 1,66	58,14 ± 1,16	Sub-ajuste por regularização excessiva
MEL	SVM MEL (<i>m</i> =2000, <i>C</i> =10.0, Puro)	2000	10,0	62,18 ± 3,14	63,53 ± 2,50	Instabilidade e sobreajuste (alta variância)
MEL	Melhor SVM MEL (<i>m</i>=4000, <i>C</i>=2.0)	4000	2,0	63,78 ± 1,14	64,56 ± 1,18	Teto Máximo MEL (Menor Variância)

Comparação dos Tetos de Nyström:

- ▶ **LOFAR** $m = 6000$ (**Teto 63,83%**): Exigiu 6000 marcos para cobrir o espaço esparsos de 1024 dimensões da FFT.
- ▶ **MEL** $m = 4000$ (**Teto 63,78%**): Espaço compacto (256 filtros) estabilizou em $m = 4000$ com mínima variância ($\pm 1,14\%$).

Conclusão: Gargalo Estrutural

Mesmo com $m = 6000$ e regularização ótima, o SVM estagnou em **63, 83%** de SP ($< 66, 25\%$ do MLP). A limitação provou ser a separação plana simultânea das 4 classes.



Análise de Incerteza e Opção de Rejeição (Tabela 9 do Artigo)

Foi replicado o experimento de opção de rejeição (**Tabela 9 do artigo**), avaliando-se o trade-off entre cobertura operacional e acurácia sob limiares de concordância temporal de janelas (t):

Modelo	$t = 0$ (100% Cobertura)		$t \geq 0,6$ (Maioria Absoluta)		$t \geq 0,9$ (Alto Consenso)	
	Cobertura	Acurácia	Cobertura	Acurácia	Cobertura	Acurácia
SVM MEL (Best)	100%	63,3%	76,1%	69,6%	37,5%	83,4%
SVM LOFAR (Best)	100%	63,8%	62,9%	75,9%	25,1%	89,6% – 90,4% [Melhor]
MLP MEL	100%	63,5%	70,4%	72,0%	32,9%	85,9%
MLP LOFAR	100%	65,5%	61,0%	78,1%	24,8%	91,6%
CNN Convolutacional	100%	64,9%	71,2%	68,4%	54,0%	74,4% [Alerta]

Destaques do Comportamento Observado:

- **MEL:** Alta cobertura operacional (76,1%).
- **LOFAR:** Precisão extrema sob alto consenso ($> 90\%$).

Superconfiança da CNN Profunda

A CNN manteve 54% de cobertura sob $t \geq 0,9$, mas sua acurácia estagnou em apenas 74,4% (erros confiantes da Softmax). O SVM calibrou de forma consistente a incerteza.

Robustez ao CPA e Variação de Distância (Tabela 10 do Artigo)

Modelo	Representação	Índice SP (%)	Acurácia (%)	Destaque Técnico
RF (Artigo)	MEL	62,22 ± 1,86	62,64 ± 1,84	Baseline Árvores
CNN (Artigo)	MEL	63,52 ± 2,26	64,99 ± 2,09	Convolutacional Profundo
Melhor SVM MEL	MEL (m=4000)	63,78 ± 1,14	64,56 ± 1,18	Menor Variância (±1,14%)
RF (Artigo)	LOFAR	56,92 ± 1,69	58,87 ± 1,68	Degradação no LOFAR
CNN (Artigo)	LOFAR	66,05 ± 1,90	67,02 ± 1,78	Convolutacional LOFAR
MLP Local	LOFAR	66,25 ± 1,78	67,21 ± 1,65	Melhor Baseline Isolado
SVM LOFAR	LOFAR (m=6000)	63,83 ± 1,91	65,47 ± 1,77	Melhor índice SP no SVM

Aspectos dos Resultados Apresentados:

- **Consistência do MEL:** O SVM em MEL superou os baselines RF e CNN em MEL, apresentando a menor variância entre folds de todo o benchmark (±1,14%).
- **Teto do SVM no LOFAR:** O SVM atingiu 63,83% de SP ($m = 6000$), evidenciando o limite da separação plana e a necessidade de estratégias híbridas para superar o MLP (66,25%).

Matrizes de Confusão: Nível de Áudio ($5 \times 2cv$)

Linhas = classe real — Colunas = predição — Acumulado sobre 10 folds (áudios físicos únicos)

MLP MEL (Baseline)

	S	M	L	BG
SMALL	44,8	25,4	17,9	11,8
MEDIUM	20,4	64,0	13,1	2,5
LARGE	12,9	15,0	68,6	3,6
BG	6,1	3,8	5,0	85,1

MLP LOFAR (Melhor Baseline do Artigo)

	S	M	L	BG
SMALL	46,6	21,2	25,3	7,0
MEDIUM	22,6	61,3	13,8	2,3
LARGE	12,8	10,0	74,7	2,5
BG	7,3	3,8	2,6	86,3

SVM MEL ($m = 4000$)

	S	M	L	BG
SMALL	50,9	24,3	17,6	7,2
MEDIUM	26,0	60,4	12,5	1,1
LARGE	14,9	13,6	69,2	2,3
BG	11,0	4,9	6,2	77,9

SVM LOFAR ($m = 6000$)

	S	M	L	BG
SMALL	38,2	22,9	28,6	10,3
MEDIUM	17,6	60,5	17,2	4,8
LARGE	9,3	10,8	76,3	3,6
BG	6,1	2,8	4,2	86,9

- ▶ **Alvo Crítico (SMALL):** O SVM MEL obteve maior acerto na classe (50,9%) vs. 46,6% (MLP LOFAR) e 38,2% (SVM LOFAR).
- ▶ **Especialização Espectral:** Modelos LOFAR maximizam acerto em LARGE (74 – 76%), enquanto MEL mitiga confusões com ruído.

Superando o Gargalo: Especialista em Cascata SMALL vs. LARGE (SL)

imgs/pee-logo-short.png

Diagnóstico: No SVM LOFAR ($m = 6000$), a classe **SMALL** obteve apenas 38,2% de acerto, sendo que 28,6% das amostras de **SMALL** foram preditas erroneamente como **LARGE**.

1. Especialista SL (Alta Precisão)

Classificador binário dedicado exclusivamente a distinguir **SMALL vs. LARGE**:

- ▶ Treinado para operar com rigor máximo ao confirmar **LARGE**.
- ▶ Filtra o ruído harmônico de barcos rápidos.

2. Mecanismo de Resgate em Cascata

1. O **SVM LOFAR 6000** emite predição inicial.
2. Se a predição for **LARGE**, aciona o **Especialista SL**.
3. Se o especialista **não confirmar LARGE**, a predição é revertida para **SMALL**.
4. As demais classes seguem inalteradas.

Objetivo Operacional

Resgatar dezenas de embarcações pequenas indevidamente absorvidas pela classe majoritária **LARGE**, elevando expressivamente o Recall de **SMALL** e destravando o Índice SP global.

imgs/pee-logo-short.png

Especialista Binário SL:

Abordagem SL	Espaço de Entrada	Marcos (m)	Precisão LARGE (%)	Diagnóstico Experimental
SVM MEL Puro	MEL (256-D)	4000	$74,2 \pm 2,5$	Boa energia global, mas perde raias do motor
SVM LOFAR Puro	LOFAR (1024-D)	4000	$71,8 \pm 3,1$	Alta esparsidade; ruído em barcos pequenos
SVM Híbrido PCA-4	MEL-256 + PCA-4 (260-D)	6000	$78,5 \pm 2,1$	Poucas componentes para capturar o diesel
SVM Híbrido PCA-16	MEL-256 + PCA-16 (272-D)	6000	$80,4 \pm 1,9$	Leve excesso de variância espectral
Melhor Especialista SL	MEL-256 + PCA-8 (264-D)	6000	$83,8 \pm 1,4$	Equilíbrio Ótimo (ElasticNet, $C = 1.0$)

Por que o Híbrido com PCA-8 Venceu?

- ▶ **Base MEL (256-D):** Fornece a potência e envelope hidrodinâmico.
- ▶ **LOFAR-PCA8 (8-D):** Injeta apenas as 8 raiais harmônicas de cavitação/diesel mais energéticas.

Eficiência Computacional

- ▶ Vetor compacto (264-D) permite projeção Nyström rápida ($m = 6000$).
- ▶ Alta precisão ($> 83\%$) impede falsos alarmes ao confirmar se o navio é realmente **LARGE**.

Impacto da Cascata: Matrizes de Confusão (%)

Linhas = classe real — Colunas = predição — Avaliação por áudio (5 × 2cv, 10 folds acumulados)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Rec.
SMALL	38,2	22,9	28,6	10,3	38,2%
MEDIUM	17,6	60,5	17,2	4,8	60,5%
LARGE	9,3	10,8	76,3	3,6	76,3%
BG	6,1	2,8	4,2	86,9	86,9%
Prec.	56,7%	57,5%	67,0%	72,0%	

ACC Geral: 63,6% — SP: 63,8%

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Rec.
SMALL	70,1	14,8	6,4	8,7	70,1%
MEDIUM	31,5	57,0	7,6	4,0	57,0%
LARGE	20,7	9,0	66,7	3,6	66,7%
BG	10,0	2,0	2,0	85,9	85,9%
Prec.	55,3%	64,1%	85,3%	74,3%	

ACC Geral: 68,3% — SP: 69,5%

Principais Mudanças:

- **Recall SMALL:** 38,2% → **70,1%** (+31,9 p.p.) — Confusão S→L: 28,6% → **6,4%**
- **Precisão LARGE:** 67,0% → **85,3%** (+18,3 p.p.)
- **SP global:** 63,8% → **69,5%** (+5,7 p.p.) — **ACC geral:** 63,6% → **68,3%** (+4,7 p.p.)

Impacto da Cascata: Contagem Bruta de Áudios

Número absoluto de áudios classificados (10 folds acumulados, 6.390 testes no total)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Total
SMALL	680	407	509	184	1.780
MEDIUM	262	901	256	71	1.490
LARGE	198	232	1.633	77	2.140
BG	60	27	41	852	980

Corretos: 4.066/6.390

ACC Geral: 63,6% — SP: 63,8%

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Total
SMALL	1.248	263	114	155	1.780
MEDIUM	469	849	113	59	1.490
LARGE	442	193	1.428	77	2.140
BG	98	20	20	842	980

Corretos: **4.367**/6.390 (+301 áudios)

ACC Geral: 68,3% — SP: 69,5%

Ganhos em Números Absolutos:

- ▶ **Resgate de SMALL:** De 680 para **1.248 áudios** corretos (+568), com confusão S→L caindo de 509 para 114 áudios.
- ▶ **MEDIUM:** De 901 para 849 corretos (−52 áudios) — efeito colateral da reclassificação janela a janela.
- ▶ **Saldo total:** +301 áudios a mais corretamente classificados no conjunto completo.

Efeito Colateral: Impacto do Especialista SL sobre a Classe MEDIUM

imgs/pee-logo-short.png

Embora o Especialista SL atue **exclusivamente** na distinção SMALL vs. LARGE, ele gerou um efeito colateral na classe MEDIUM:

Recall por Classe	SMALL	MEDIUM	LARGE	BG	Índice SP
SVM LOFAR 6000 (Base)	38,2%	60,5%	76,3%	86,9%	63,84%
Cascata + SL (Proposta)	70,1%	57,0%	66,7%	85,9%	69,48%
Variação	+31,9 p.p.	-3,5 p.p.	-9,6 p.p.	-1,0 p.p.	+5,64 p.p.

Por que MEDIUM caiu se o SL não toca nele?

A cascata atua **janela a janela** (0,512 s). Em um navio MEDIUM, parte das janelas é classificada como LARGE pelo multiclasse. O Especialista SL converte essas janelas para SMALL, inflando os votos de SMALL na **votação majoritária** do áudio e invertendo o resultado final de MEDIUM para SMALL.

Por que o SP subiu mesmo assim?

O Índice SP usa a **média geométrica** dos recalls. Nessa métrica, o menor termo domina o resultado. Como SMALL era o gargalo (38,2%), ao saltar para 70,1%, o ganho global compensou amplamente as perdas moderadas em MEDIUM e LARGE.

Robustez ao CPA: Desempenho da Cascata nos Regimes Acústicos

imgs/pee-logo-short.png

Desempenho particionado por regimes de proximidade e passagem pelo CPA ($5 \times 2cv$ por áudio):

Modelo	Near CPA (A)	Far CPA (C)	CPA IN (A+C)	CPA OUT (B+D)	Geral ($5 \times 2cv$)
MLP LOFAR (<i>Artigo</i>)	59,3% (65,2%)	59,6% (63,2%)	59,6% (64,5%)	42,9% (42,5%)	59,4% (58,7%)
CNN MEL (<i>Artigo</i>)	66,8% (70,1%)	63,7% (66,7%)	65,6% (68,8%)	49,0% (48,8%)	65,1% (63,8%)
MLP Híbrido (<i>MEL+LOFAR</i>)	63,1% (68,2%)	63,0% (67,6%)	63,5% (68,0%)	52,3% (52,6%)	66,2% (64,9%)
SVM LOFAR 6000 (<i>Base</i>)	62,4% (69,3%)	56,8% (64,5%)	60,5% (67,3%)	50,2% (49,6%)	63,8% (63,6%)
Cascata LOFAR + SL	68,9% (70,7%)	67,9% (72,6%)	69,2% (71,6%)	54,5% (57,1%)	69,5% (68,3%)

Formato: Índice SP % (Acurácia %)

Análise de Robustez Espectral:

- **Grande melhora no Far CPA (C):** No regime de sinal atenuado e baixa SNR, o SP subiu de 56,8% (base) e 59,6% (artigo) para **67,9% (+11,1 p.p.)**, com acurácia de **72,6%**.
- **Superação no Near CPA (A):** Atingiu **68,9%** de SP, superando inclusive a CNN profunda do artigo (66,8%).
- **Resiliência no CPA OUT (B+D):** Fora da passagem direta do CPA, alcançou **54,5%** de SP vs. apenas 42,9% do baseline do artigo (+11,6 p.p.).



Ranking Geral Consolidado de Todos os Modelos

Ordenação decrescente pelo **Índice SP** (avaliação $5 \times 2cv$ em nível de áudio):

Pos.	Modelo / Arquitetura	Espectro	Índice SP (%)	Acurácia (%)	Categoria / Destaque
1º	SVM em Cascata (LOFAR 6000 + SL)	Híbrido	69,48 ± 2,28	69,93 ± 2,23	Melhor modelo (proposta)
2º	MLP [32, 16] LOFAR	LOFAR	66,25 ± 1,78	67,21 ± 1,65	Melhor Baseline do Artigo (Benchmark)
3º	CNN Convolucional LOFAR	LOFAR	66,05 ± 1,90	67,02 ± 1,78	Deep Learning LOFAR
4º	MLP [32, 16] MEL	MEL-256	64,66 ± 2,11	64,80 ± 2,00	Baseline Conectado MEL
5º	SVM Nyström LOFAR ($m = 6000$)	LOFAR	63,83 ± 1,91	65,47 ± 1,77	Melhor SVM Multiclasse Isolado
6º	SVM Nyström MEL ($m = 4000$)	MEL-256	63,78 ± 1,14	64,56 ± 1,18	Menor Variância ($\pm 1,14\%$)
7º	CNN Convolucional MEL	MEL-256	63,52 ± 2,26	64,99 ± 2,09	Deep Learning MEL
8º	Random Forest (RF) MEL	MEL-256	62,22 ± 1,86	62,64 ± 1,84	Ensemble de Árvores MEL
9º	Random Forest (RF) LOFAR	LOFAR	56,92 ± 1,69	58,87 ± 1,68	Ensemble de Árvores LOFAR

Conclusões Finais do Benchmark:

- **Superação do Benchmark:** O SVM em Cascata (69,48%) superou expressivamente o Melhor Baseline do Artigo (MLP LOFAR: 66,25%) em +3,23 p.p. de SP e +2,72 p.p. de acurácia.
- **Resgate Estratégico:** O ganho resultou do resgate de SMALL (38,2% → 70,1%), mantendo a interpretabilidade e baixo custo computacional frente a redes profundas.



Discussão: Dúvidas e Próximos Passos da Pesquisa

Pontos abertos para discussão e direcionamento das próximas etapas:

1. Meta de Desempenho e Artigo

- ▶ Devemos tentar sempre melhorar o SP ou temos outros objetivos?
- ▶ Qual o patamar de SP almejado? (**69,5%** vs. romper **70 – 75%**)
- ▶ Resultados sustentam novo artigo? (superação do artigo seminal, SVM em Cascata e robustez ao CPA).

2. Novos Formatos de Entrada

- ▶ Vale a pena estudar entradas além de LOFAR e MEL?
- ▶ **DEMON**: *Demodulation of Envelope*
- ▶ **MFCC**: *Mel-Frequency Cepstral Coefficients*

3. Extração e Expansão de Dados

- ▶ Extrair novos recortes dados do IARA?
- ▶ Avaliar *Data Augmentation* acústico?

4. Avaliação de Novos Modelos

- ▶ Quais modelos podemos explorar? *Gated Recurrent Unit* (GRU) ? *Bi-GRU*? *LSTM*?

imgs/pee-logo-short.png

Obrigado!

Evandro Rocha
UFRJ / COPPE / PEE