imgs/pee-logo.png

imgs/coppe-logo.pdf

Reconhecimento Acústico de Alvos Submarinos no Dataset IARA

Da Reprodução dos Baselines à Evolução dos Modelos SVM Nyström (MEL e LOFAR)

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ / COPPE / PEE

2026

imgs/pee-logo-short.png

Agenda da Apresentação

imgs/pee-logo-short.png

Acervo e Coleções do Dataset IARA (Silva et al., 2025)

O **IARA** reúne 129h 34min de gravações reais na Bacia de Santos (PMPAS-BS / Petrobras):

Plataforma	Coleção	Áudios	CPA	Descrição Acústica
UO	A	456	In	Distância < 250 m (aproximação)
	B	199	Out	Distância < 250 m (afastamento)
	C	341	In	Distância $250 - 500$ m
	D	449	Out	Distância $250 - 500$ m
	E	261	—	Ruído ambiente marítimo puro
Subtotal UO (OS)		**1.706**	**Base oficial dos experimentos**	
Gliders	F	35	In	Plataforma móvel (alto-mar)
	G	37	Out	Plataforma móvel (alto-mar)
	H	47	—	Ruído ambiente em águas profundas
Subtotal Gliders		**119**	0 SMALL, 3 MEDIUM (inviável p/ SP)	
Total Geral IARA		**1.825**	129h 34min ($\sim$ 50 GB de dados)	

Por que Usar Apenas UO (1.706)?

- **Estabilidade Física**: UO é fixo no leito marinho ($\sim$ 2.000 m). Canal acústico constante, sem ruído de propulsão próprio.
- **Inviabilidade dos Gliders**: O Glider não possui gravações de SMALL (0%) e apenas 3 de MEDIUM, zerando matematicamente o Índice SP.

Curadoria Rigorosa

Alvos únicos na zona de exclusão (2 km), validados via AIS com comprimento físico para rotulação precisa.

Protocolo Experimental 5×2cv: Treino, Validação e Teste

imgs/pee-logo-short.png

Como as **1.706 gravações de UO** são particionadas no protocolo oficial (Silva et al., 2025):

A Divisão dos 1.706 Áudios em 3 Conjuntos

Em cada iteração, os 1.706 áudios são divididos em duas metades:

- **50% Treino (853 áudios):** Ajuste dos pesos e parâmetros dos modelos.
- **50% Avaliação (853 áudios):** Fatia de 853 particionada em:
  - **Validação (214 áudios $\approx 12,5\%$ do total):** 25% da avaliação p/ *early stopping* em redes (MLP, CNN).
  - **Teste Final (639 áudios $\approx 37,5\%$ do total):** 75% da avaliação p/ avaliação cega oficial.

Balanço Amostral por Fold

$$\underbrace{853}_{\text{Treino (50\%)}} + \underbrace{214}_{\text{Val (12,5\%)}} + \underbrace{\mathbf{639}}_{\textbf{Teste (37,5\%)}} =$$

$$\mathbf{1.706}\ \text{UO (100\%)}$$

Protocolo 5×2cv (10 Folds de Teste)

- **Exclusive Ships on Test**: Divisão estratificada por navio físico (ID de arquivo). Nenhum navio de teste está no treino (*zero data leakage*).
- **Volume de Teste**:
  639 áudios $\times$ 10 folds = **6.390** avaliações.
- Matrizes de confusão e Índice SP consolidados sobre essas 6.390 predições de teste.

imgs/pee-logo-short.png

Distribuição das Classes na Partição de Teste (639 Áudios)

Em cada um dos 10 folds, o conjunto de teste avaliado é composto por 639 gravações de UO, apresentando desbalanceamento natural entre categorias:

Classe Acústica	Porte Físico	Áudios no Teste / Fold	Proporção (%)	Testes (5×2cv)	Assinatura Predominante
SMALL	< 50 m	178	$27,9\%$	1.780	Lanchas, botes (baixa SNR, motores rápidos)
MEDIUM	$50 - 100$ m	149	$23,3\%$	1.490	Rebocadores, barcos de apoio e pesca
LARGE	> 100 m	214	$\mathbf{33,5\%}$	2.140	Petroleiros, cargueiros (raias puras, cavitação)
BACKGROUND	Sem alvos	98	$\mathbf{15,3\%}$	980	Ruído ambiente marítimo natural
Total	—	**639**	$\mathbf{100,0\%}$	**6.390**	> 64 horas de gravações de teste

Impacto do Desbalanceamento no Treinamento

- A classe **LARGE** representa um terço do teste ($33,5\%$), enquanto **BACKGROUND** corresponde a apenas $15,3\%$.
- Devido à disparidade energética e amostral, modelos ingênuos tendem a negligenciar classes minoritárias, justificando o uso mandatório do **Índice SP** como métrica de avaliação.

imgs/pee-logo-short.png

Métrica Oficial de Avaliação: Índice SP

Para mitigar o desbalanceamento das classes, adota-se o **Índice SP** como métrica primária:

Índice SP (Média Geométrica dos Recalls por Classe)

$$\mathrm{SP} = \sqrt[4]{R_{\mathrm{SMALL}} \cdot R_{\mathrm{MEDIUM}} \cdot R_{\mathrm{LARGE}} \cdot R_{\mathrm{BACKGROUND}}} \times 100\%$$

Propriedades Críticas do Índice SP:

- **Penalização Severa de Zeros:** Se qualquer uma das 4 classes apresentar $\mathrm{Recall}_k = 0\%$, o índice zera instantaneamente ($\mathrm{SP} = 0\%$).
- **Robustez contra Vieses:** Diferentemente da acurácia global (que pode ser inflada pela classe majoritária *LARGE*), o SP avalia o equilíbrio real e só é alto se houver acerto consistente em todas as categorias.
- **Exigência Operacional:** Garante que embarcações pequenas (*SMALL*) e ruído (*BACKGROUND*) não sejam negligenciados.

imgs/pee-logo-short.png

Representações Espectrais: Vetores de Entrada dos Modelos

O áudio contínuo é fatiado em janelas de $0,512$ s e convertido em vetores numéricos para alimentar os classificadores:

1. Espectro LOFAR (1024 Atributos)

- **Vetor de Entrada: 1024** valores.
- **O que mede:** Energia sonora em frequências finas e lineares (tons puros e harmônicos periódicos).
- **Papel no Modelo:** Máxima riqueza e resolução detalhada em frequência.

2. Espectro MEL (256 Atributos)

- **Vetor de Entrada: 256** valores.
- **O que mede:** Energia agrupada em faixas perceptuais (timbre, envelope sonoro e ruídos contínuos).
- **Papel no Modelo:** Representação compacta e suave, resistente a variações espúrias.

Como Alimentam os Modelos?

Cada janela acústica gera um vetor (1024 ou 256 dimensões) processado individualmente por modelos tabulares (MLP, SVM, RF) ou empilhado temporalmente para redes profundas (CNN, CRNN).

imgs/pee-logo-short.png

Reprodução Local dos Baselines do Artigo (Silva et al., 2025)

Antes da proposição de novas abordagens, foi replicado com rigor o pipeline do artigo nos 10 folds (5×2cv):

Classificador	**Espectro**	**Índice SP (%) (Artigo)**	**Índice SP (%) (Local)**	**Diferença**
Random Forest (RF)	MEL	$62,22 \pm 1,86$	$62,10 \pm 1,92$	$-0,12$ p.p.
Random Forest (RF)	LOFAR	$56,92 \pm 1,69$	$56,85 \pm 1,75$	$-0,07$ p.p.
MLP [32, 16]	MEL	$63,38 \pm 1,81$	$64,66 \pm 2,11$	$+1,28$ p.p.
MLP [32, 16]	**LOFAR**	$\mathbf{66,51 \pm 1,39}$	$\mathbf{66,25 \pm 1,78}$	$\mathbf{-0,26}$ p.p.
CNN Convolucional	MEL	$63,52 \pm 2,26$	$63,40 \pm 2,15$	$-0,12$ p.p.
CNN Convolucional	**LOFAR**	$\mathbf{66,05 \pm 1,90}$	$\mathbf{65,92 \pm 1,85}$	$\mathbf{-0,13}$ p.p.

Conclusão da Reprodução

Os resultados reproduzidos localmente confirmam com precisão estatística os valores da literatura. O **MLP LOFAR (**$66,51\%$ **Artigo /** $66,25\%$ **Local)** consolidou-se como o benchmark principal a ser superado.

imgs/pee-logo-short.png

Motivação: O SVM em Sonar Passivo

Método Clássico em UATR

O SVM foi historicamente um dos primeiros métodos aplicados em UATR e continua sendo empregado como baseline de referência em trabalhos recentes (e.g., Xu et al., reportando 69,24% no **DeepShip**). Contudo, os datasets da literatura são de pequeno a médio porte (**ShipsEar**: 3h; **DeepShip**: 47h); a avaliação em bases de grande escala como o IARA ($>$ 64h) permanecia em aberto.

Lacuna na Literatura:

- **Dados Limitados**: Validações anteriores restritas a bases pequenas e poucos trânsitos.
- **Custo Computacional**: Crescimento de memória e tempo $O(N^2)/O(N^3)$ inviabilizava testes massivos.

A Fronteira do Dataset IARA:

- **Base de Grande Escala**: O IARA é uma das maiores bases públicas mundiais (tráfego real).
- **Objetivo do Estudo**: Investigar a capacidade e o limite do SVM sob este patamar de complexidade.

imgs/pee-logo-short.png

SVM com Aproximação de Nyström

O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- **Volume de Amostras (N no IARA)**: N é o número de janelas espectrais de treinamento — MEL $(0,512\text{s}) \approx 500\text{k}$ janelas; LOFAR $(0,058\text{s}) \approx 800\text{k}$ janelas.
- **Custo do RBF Clássico**: A matriz Gram $N \times N$ exigiria $> 1,0$ Terabyte de RAM (inviável).

- **Aproximação de Nyström (Baixo Rank)**: Selecionam-se m amostras de referência (*landmarks*) para projetar o kernel no espaço linear explícito $\mathbb{R}^m$.
- **Base Projetada de Treinamento ($N \times m$)**:
  - MEL ($m = 4000$): $500\text{k} \times 4000 \times 4\text{B} \approx$ **8** GB de RAM (overhead total ≈ 10 GB).
  - LOFAR ($m = 4000$): $800\text{k} \times 4000 \times 4\text{B} \approx$ **13** GB de RAM (overhead total ≈ 15 GB).
- **Complexidade Linear**: Reduz o treinamento para $O(N \cdot m^2)$, resolvido eficientemente via SGD.
- **Tamanho do Modelo Final**: Armazena apenas o vetor de pesos linear ($4 \times m$ coeficientes $\approx <$ **100** KB).

imgs/pee-logo-short.png

Evolução do SVM com Espectrograma MEL (Banda Larga)

Foi investigada a progressão da capacidade do SVM variando-se o número de componentes m de Nyström e a regularização:

Configuração SVM MEL	Componentes m	Índice SP (%)	Acurácia Bal. (%)	Observação
SVM MEL (m=300)	300	$59,96 \pm 3,38$	$62,34 \pm 1,98$	Sub-amostragem severa
SVM MEL (m=1000)	1000	$62,96 \pm 2,08$	$64,11 \pm 1,98$	Boa generalização
SVM MEL (m=2000)	2000	$63,04 \pm 2,37$	$64,45 \pm 1,93$	Saturação linear
SVM MEL (m=3000)	3000	$63,65 \pm 1,99$	$64,77 \pm 1,87$	Incremento consistente
Melhor SVM MEL ($m = 4000$)	**4000**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**Melhor MEL (ElasticNet, C=2.0)**
SVM MEL (m=4000, C=0.5)	4000	$57,51 \pm 1,66$	$58,14 \pm 1,16$	Sub-ajuste por excesso de penalidade

Destaque Experimental no MEL

O **SVM Golden MEL ($m = 4000$)** alcançou **$63,78\% \pm 1,14\%$ de SP**, superando a CNN MEL ($63,52\%$) e o RF MEL ($62,22\%$) com a **menor variância de todo o benchmark ($\pm 1,14\%$)**!

imgs/pee-logo-short.png

Exploração de Hiperparâmetros e Limite de Desempenho do SVM

Foi realizada uma busca exaustiva de hiperparâmetros (C, penalização ElasticNet ρ e componentes m), atingindo tetos bem definidos:

Espectro	Configuração Avaliada	Comp. m	Reg. C	Índice SP (%)	Acurácia (%)	Diagnóstico Experimental
LOFAR	SVM LOFAR (m=1000)	1000	1,0	$57,86 \pm 3,83$	$60,95 \pm 2,89$	Sub-amostragem severa do espaço 1024-D
LOFAR	SVM LOFAR (m=2000, C=0.1)	2000	0,1	$54,84 \pm 1,60$	$59,67 \pm 1,28$	Sub-ajuste rígido por excesso de penalidade
LOFAR	SVM LOFAR (m=4000, C=0.5, E-Net)	4000	0,5	$60,66 \pm 2,78$	$63,23 \pm 2,05$	Falta de flexibilidade no hiperplano
LOFAR	**SVM LOFAR (m=6000, C=1.0, E-Net)**	**6000**	**1,0**	$\mathbf{63,83 \pm 1,91}$	$\mathbf{65,47 \pm 1,77}$	**Teto Máximo Absoluto LOFAR**
MEL	SVM MEL (m=4000, C=0.5, E-Net)	4000	0,5	$57,51 \pm 1,66$	$58,14 \pm 1,16$	Sub-ajuste por regularização excessiva
MEL	SVM MEL (m=2000, C=10.0, Puro)	2000	10,0	$62,18 \pm 3,14$	$63,53 \pm 2,50$	Instabilidade e sobreajuste (alta variância)
MEL	**Melhor SVM MEL (m=4000, C=2.0)**	**4000**	**2,0**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**Teto Máximo MEL (Menor Variância)**

Comparação dos Tetos de Nyström:

- **LOFAR** $m = 6000$ **(Teto $63,83\%$):** Exigiu 6000 marcos para cobrir o espaço esparso de 1024 dimensões da FFT.
- **MEL** $m = 4000$ **(Teto $63,78\%$):** Espaço compacto (256 filtros) estabilizou em $m = 4000$ com mínima variância ($\pm 1,14\%$).

Conclusão: Gargalo Estrutural

Mesmo com $m = 6000$ e regularização ótima, o SVM estagnou em $\mathbf{63,83}\%$ de SP ($< 66,25\%$ do MLP). A limitação provou ser a separação plana simultânea das 4 classes.

imgs/pee-logo-short.png

Análise de Incerteza e Opção de Rejeição (Tabela 9 do Artigo)

Foi replicado o experimento de opção de rejeição (**Tabela 9 do artigo**), avaliando-se o trade-off entre cobertura operacional e acurácia sob limiares de concordância temporal de janelas (t):

Modelo	$t = 0$ **(100% Cobertura)**		$t \geq 0,6$ **(Maioria Absoluta)**		$t \geq 0,9$ **(Alto Consenso)**	
	Cobertura	**Acurácia**	**Cobertura**	**Acurácia**	**Cobertura**	**Acurácia**
SVM MEL (Best)	100%	63,3%	**76,1%**	**69,6%**	37,5%	83,4%
SVM LOFAR (Best)	100%	63,8%	62,9%	75,9%	**25,1%**	**89,6% – 90,4%** [Melhor]
MLP MEL	100%	63,5%	70,4%	72,0%	32,9%	85,9%
MLP LOFAR	100%	65,5%	61,0%	78,1%	24,8%	91,6%
CNN Convolucional	100%	64,9%	71,2%	68,4%	54,0%	**74,4%** [Alerta]

Destaques do Comportamento Observado:

- **MEL:** Alta cobertura operacional (76,1%).
- **LOFAR:** Alta Precisão sob alto consenso (> 90%).

Robustez ao CPA e Variação de Distância (Tabela 10 do Artigo)

imgs/pee-logo-short.png

- Foi avaliada a capacidade de generalização diante da distância física da embarcação ao hidrofone (reprodução da Tabela 10 do artigo):

Treinado em	Avaliado em	MLP LOFAR (SP %)	SVM LOFAR (SP %)
Near CPA (A)	Near CPA (A)	$63,64 \pm 2,86\%$	$\mathbf{65,12 \pm 2,40\%}$
Near CPA (A)	Far CPA (C)	$42,50 \pm 3,10\%$	$\mathbf{44,80 \pm 2,85\%}$
Far CPA (C)	Far CPA (C)	$55,20 \pm 2,50\%$	$\mathbf{56,90 \pm 2,10\%}$
Far CPA (C)	Near CPA (A)	$48,10 \pm 3,40\%$	$\mathbf{50,25 \pm 2,90\%}$

Conclusões de Robustez ao CPA

- **Near CPA (A):** Alta SNR, espectro limpo.
- **Far CPA (C):** Baixa SNR, forte atenuação do meio.
- O **SVM LOFAR** superou o MLP do artigo em todos os cenários de transferência inter-distância, comprovando a robustez da margem de separabilidade RBF.

imgs/pee-logo-short.png

Síntese dos Resultados Obtidos nesta Etapa

Modelo	Representação	Índice SP (%)	Acurácia (%)	Destaque Técnico
RF (Artigo)	MEL	$62,22 \pm 1,86$	$62,64 \pm 1,84$	Baseline Árvores
CNN (Artigo)	MEL	$63,52 \pm 2,26$	$64,99 \pm 2,09$	Convolucional Profundo
Melhor SVM MEL	**MEL (m=4000)**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**Menor Variância** ($\pm 1,14\%$)
RF (Artigo)	LOFAR	$56,92 \pm 1,69$	$58,87 \pm 1,68$	Degradação no LOFAR
CNN (Artigo)	LOFAR	$66,05 \pm 1,90$	$67,02 \pm 1,78$	Convolucional LOFAR
MLP Local	LOFAR	$66,25 \pm 1,78$	$67,21 \pm 1,65$	Melhor Baseline Isolado
SVM LOFAR	**LOFAR (m=6000)**	$\mathbf{63,83 \pm 1,91}$	$\mathbf{65,47 \pm 1,77}$	**Melhor índice SP no SVM**

Aspectos dos Resultados Apresentados:

- **Consistência do MEL:** O SVM em MEL superou os baselines RF e CNN em MEL, apresentando a menor variância entre folds de todo o benchmark ($\pm 1,14\%$).
- **Teto do SVM no LOFAR:** O SVM atingiu $63,83\%$ de SP ($m = 6000$), evidenciando o limite da separação plana e a necessidade de estratégias híbridas para superar o MLP ($66,25\%$).

imgs/pee-logo-short.png

Matrizes de Confusão: Nível de Áudio (5×2cv)

Linhas = classe real — Colunas = predição — Acumulado sobre 10 folds (áudios físicos únicos)

MLP MEL (Baseline)

	S	M	L	BG
SMALL	44,8	25,4	17,9	11,8
MEDIUM	20,4	**64,0**	13,1	2,5
LARGE	12,9	15,0	**68,6**	3,6
BG	6,1	3,8	5,0	**85,1**

SVM MEL ($m = 4000$)

	S	M	L	BG
SMALL	50,9	24,3	17,6	7,2
MEDIUM	26,0	**60,4**	12,5	1,1
LARGE	14,9	13,6	**69,2**	2,3
BG	11,0	4,9	6,2	**77,9**

MLP LOFAR (Melhor Baseline do Artigo)

	S	M	L	BG
SMALL	46,6	21,2	25,3	7,0
MEDIUM	22,6	**61,3**	13,8	2,3
LARGE	12,8	10,0	**74,7**	2,5
BG	7,3	3,8	2,6	**86,3**

SVM LOFAR ($m = 6000$)

	S	M	L	BG
SMALL	38,2	22,9	28,6	10,3
MEDIUM	17,6	**60,5**	17,2	4,8
LARGE	9,3	10,8	**76,3**	3,6
BG	6,1	2,8	4,2	**86,9**

- **Alvo Crítico (SMALL):** O **SVM MEL** obteve maior acerto na classe ($50,9\%$) vs. $46,6\%$ (MLP LOFAR) e $38,2\%$ (SVM LOFAR).
- **Especialização Espectral:** Modelos LOFAR maximizam acerto em LARGE ($74 - 76\%$), enquanto MEL mitiga confusões com ruído.

Superando o Gargalo: Especialista em Cascata SMALL vs. LARGE (SL)

imgs/pee-logo-short.png

Diagnóstico: No SVM LOFAR ($m = 6000$), a classe **SMALL** obteve apenas $38,2\%$ de acerto, sendo que $28,6\%$ **das amostras de SMALL foram preditas erroneamente como LARGE**.

1. Especialista SL (Alta Precisão)

Classificador binário dedicado exclusivamente a distinguir **SMALL vs. LARGE**:

- Treinado para operar com rigor máximo ao confirmar **LARGE**.
- Filtra o ruído harmônico de barcos rápidos.

2. Mecanismo de Resgate em Cascata

1. O **SVM LOFAR 6000** emite predição inicial.
2. Se a predição for **LARGE**, aciona o **Especialista SL**.
3. Se o especialista **não confirmar LARGE**, a predição é revertida para **SMALL**.
4. As demais classes seguem inalteradas.

Objetivo Operacional

Resgatar dezenas de embarcações pequenas indevidamente absorvidas pela classe majoritária LARGE, elevando expressivamente o Recall de SMALL e destravando o Índice SP global.

Evolução dos Classificadores Especialistas SL (SMALL vs. LARGE)

imgs/pee-logo-short.png

Foram exploradas múltiplas variantes de representação espectral e hiperparâmetros para o Especialista Binário SL:

Abordagem SL	Espaço de Entrada	Marcos (m)	Precisão LARGE (%)	Diagnóstico Experimental
SVM MEL Puro	MEL (256-D)	4000	$74,2 \pm 2,5$	Boa energia global, mas perde raias do motor
SVM LOFAR Puro	LOFAR (1024-D)	4000	$71,8 \pm 3,1$	Alta esparsidade; ruído em barcos pequenos
SVM Híbrido (PCA-4)	MEL-256 + LOFAR-PCA4 (260-D)	6000	$78,5 \pm 2,1$	Poucas componentes para capturar o diesel
SVM Híbrido (PCA-16)	MEL-256 + LOFAR-PCA16 (272-D)	6000	$80,4 \pm 1,9$	Leve excesso de variância espectral
Melhor Especialista SL	**MEL-256 + LOFAR-PCA8 (264-D)**	**6000**	$\mathbf{83,8 \pm 1,4}$	**Equilíbrio Ótimo: MEL + LOFAR Compacto**

Por que o Híbrido com PCA-8 Venceu?

- **Base MEL (256-D):** Fornece a potência e envelope hidrodinâmico.
- **LOFAR-PCA8 (8-D):** Injeta apenas as 8 raias harmônicas de cavitação/diesel mais energéticas.

Eficiência Computacional

- Vetor compacto (264-D) permite projeção Nyström rápida ($m = 6000$).
- Alta precisão ($> 83\%$) impede falsos alarmes ao confirmar se o navio é realmente LARGE.

Arquitetura do Especialista SL: Fusão Híbrida (MEL-256 + LOFAR-PCA8)

imgs/pee-logo-short.png

O especialista binário combina a potência do envelope contínuo com as raias discretas de cavitação:

imgs/fusao_hibrida_mel_lofar_pt.jpg

1. Sinergia Espectral (Vetor de 264-D)

MEL (256-D): Fornece a energia hidrodinâmica e o envelope global.
LOFAR-PCA (8-D): Adiciona as 8 raias harmônicas dominantes do motor diesel.

2. Filtragem

O PCA reduz os 1.024 bins esparsos para 8 atributos críticos, descartando ruído e elevando a precisão em LARGE para **83,8%** no SVM Nyström ($m = 6000$).

imgs/pee-logo-short.png

Impacto da Cascata: Matrizes de Confusão (%)

Linhas = classe real — Colunas = predição — Avaliação por áudio ($5 \times 2cv$, 10 folds acumulados)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Rec.
SMALL	38,2	22,9	28,6	10,3	38,2%
MEDIUM	17,6	**60,5**	17,2	4,8	60,5%
LARGE	9,3	10,8	**76,3**	3,6	76,3%
BG	6,1	2,8	4,2	**86,9**	86,9%
Prec.	56,7%	57,5%	67,0%	72,0%	

ACC Geral: 63,6% — **SP:** 63,8%

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Rec.
SMALL	**70,1**	14,8	**6,4**	8,7	**70,1%**
MEDIUM	31,5	57,0	7,6	4,0	57,0%
LARGE	20,7	9,0	**66,7**	3,6	66,7%
BG	10,0	2,0	2,0	**85,9**	85,9%
Prec.	55,3%	64,1%	**85,3%**	74,3%	

ACC Geral: 68,3% — SP: 69,5%

Principais Mudanças:

- **Recall SMALL:** 38,2% → **70,1%** (**+31,9 p.p.**) — Confusão S→L: 28,6% → **6,4%**
- **Precisão LARGE:** 67,0% → **85,3%** (**+18,3 p.p.**)
- **SP global:** 63,8% → **69,5%** (**+5,7 p.p.**) — **ACC geral:** 63,6% → **68,3%** (**+4,7 p.p.**)

imgs/pee-logo-short.png

Impacto da Cascata: Contagem Bruta de Áudios

Número absoluto de áudios classificados (10 folds acumulados, 6.390 testes no total)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Total
SMALL	680	407	509	184	1.780
MEDIUM	262	**901**	256	71	1.490
LARGE	198	232	**1.633**	77	2.140
BG	60	27	41	**852**	980

Corretos: 4.066/6.390

ACC Geral: $63,6\%$ — **SP:** $63,8\%$

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Total
SMALL	**1.248**	263	**114**	155	1.780
MEDIUM	469	849	113	59	1.490
LARGE	442	193	**1.428**	77	2.140
BG	98	20	20	**842**	980

Corretos: **4.367**/6.390 (**+301 áudios**)

ACC Geral: 68$,3\%$ — **SP: 69**$,5\%$

Ganhos em Números Absolutos:

- **Resgate de SMALL:** De 680 para **1.248 áudios** corretos (**+568**), com confusão S→L caindo de 509 para **114 áudios**.
- **MEDIUM:** De 901 para 849 corretos (−52 áudios) — efeito colateral da reclassificação janela a janela.
- **Saldo total: +301 áudios** a mais corretamente classificados no conjunto completo.

Efeito Colateral: Impacto do Especialista SL sobre a Classe MEDIUM

imgs/pee-logo-short.png

Embora o Especialista SL atue **exclusivamente** na distinção SMALL vs. LARGE, ele gerou um efeito colateral na classe MEDIUM:

Recall por Classe	**SMALL**	**MEDIUM**	**LARGE**	**BG**	**Índice SP**
SVM LOFAR 6000 (Base)	$38,2\%$	$60,5\%$	$76,3\%$	$86,9\%$	$63,84\%$
Cascata + SL (Proposta)	$70,1\%$	$57,0\%$	$66,7\%$	$85,9\%$	$\mathbf{69,48}\%$
Variação	**+31,9 p.p.**	$-3,5$ p.p.	$-9,6$ p.p.	$-1,0$ p.p.	**+5,64 p.p.**

Por que MEDIUM caiu se o SL não toca nele?

A cascata atua **janela a janela** ($0,512$ s). Em um navio MEDIUM, parte das janelas é classificada como LARGE pelo multiclasse. O Especialista SL converte essas janelas para SMALL, inflando os votos de SMALL na **votação majoritária** do áudio e invertendo o resultado final de MEDIUM para SMALL.

Por que o SP subiu mesmo assim?

O Índice SP usa a **média geométrica** dos recalls. Nessa métrica, o menor termo domina o resultado. Como SMALL era o gargalo ($38,2\%$), ao saltar para $70,1\%$, o ganho global compensou amplamente as perdas moderadas em MEDIUM e LARGE.

Robustez ao CPA: Desempenho da Cascata nos Regimes Acústicos

imgs/pee-logo-short.png

Desempenho particionado por regimes de proximidade e passagem pelo CPA (5×2cv por áudio):

Modelo	**Near CPA (A)**	**Far CPA (C)**	**CPA IN (A+C)**	**CPA OUT (B+D)**	**Geral (5×2cv)**
MLP LOFAR *(Artigo)*	$59,3\%$ $(65,2\%)$	$59,6\%$ $(63,2\%)$	$59,6\%$ $(64,5\%)$	$42,9\%$ $(42,5\%)$	$59,4\%$ $(58,7\%)$
CNN MEL *(Artigo)*	$66,8\%$ $(70,1\%)$	$63,7\%$ $(66,7\%)$	$65,6\%$ $(68,8\%)$	$49,0\%$ $(48,8\%)$	$65,1\%$ $(63,8\%)$
MLP Híbrido *(MEL+LOFAR)*	$63,1\%$ $(68,2\%)$	$63,0\%$ $(67,6\%)$	$63,5\%$ $(68,0\%)$	$52,3\%$ $(52,6\%)$	$66,2\%$ $(64,9\%)$
SVM LOFAR 6000 *(Base)*	$62,4\%$ $(69,3\%)$	$56,8\%$ $(64,5\%)$	$60,5\%$ $(67,3\%)$	$50,2\%$ $(49,6\%)$	$63,8\%$ $(63,6\%)$
Cascata LOFAR + SL	$\mathbf{68,9\%}$ $(\mathbf{70,7\%})$	$\mathbf{67,9\%}$ $(\mathbf{72,6\%})$	$\mathbf{69,2\%}$ $(\mathbf{71,6\%})$	$\mathbf{54,5\%}$ $(\mathbf{57,1\%})$	$\mathbf{69,5\%}$ $(\mathbf{68,3\%})$

Formato: Índice SP % (Acurácia %)

Análise de Robustez Espectral:

- **Grande melhora no Far CPA (C):** No regime de sinal atenuado e baixa SNR, o SP subiu de $56,8\%$ (base) e $59,6\%$ (artigo) para $\mathbf{67,9\%}$ (**+11,1 p.p.**), com acurácia de $\mathbf{72,6\%}$.
- **Superação no Near CPA (A):** Atingiu $\mathbf{68,9\%}$ de SP, superando inclusive a CNN profunda do artigo ($66,8\%$).
- **Resiliência no CPA OUT (B+D):** Fora da passagem direta do CPA, alcançou $\mathbf{54,5\%}$ de SP vs. apenas $42,9\%$ do baseline do artigo (**+11,6 p.p.**).

Ranking Geral Consolidado de Todos os Modelos

imgs/pee-logo-short.png

Ordenação decrescente pelo **Índice SP** (avaliação 5×2cv em nível de áudio):

Pos.	Modelo / Arquitetura	Espectro	Índice SP (%)	Acurácia (%)	Categoria / Destaque
1º	**SVM em Cascata (LOFAR 6000 + SL)**	**Híbrido**	$\mathbf{69,48 \pm 2,28}$	$\mathbf{69,93 \pm 2,23}$	**Melhor modelo (proposta)**
2º	**MLP [32, 16] LOFAR**	**LOFAR**	$\mathbf{66,25 \pm 1,78}$	$\mathbf{67,21 \pm 1,65}$	**Melhor Baseline do Artigo (Benchmark)**
3º	CNN Convolucional LOFAR	LOFAR	$66,05 \pm 1,90$	$67,02 \pm 1,78$	Deep Learning LOFAR
4º	MLP [32, 16] MEL	MEL-256	$64,66 \pm 2,11$	$64,80 \pm 2,00$	Baseline Conectado MEL
5º	SVM Nyström LOFAR ($m = 6000$)	LOFAR	$63,83 \pm 1,91$	$65,47 \pm 1,77$	Melhor SVM Multiclasse Isolado
6º	SVM Nyström MEL ($m = 4000$)	MEL-256	$63,78 \pm 1,14$	$64,56 \pm 1,18$	Menor Variância ($\pm 1,14\%$)
7º	CNN Convolucional MEL	MEL-256	$63,52 \pm 2,26$	$64,99 \pm 2,09$	Deep Learning MEL
8º	Random Forest (RF) MEL	MEL-256	$62,22 \pm 1,86$	$62,64 \pm 1,84$	Ensemble de Árvores MEL
9º	Random Forest (RF) LOFAR	LOFAR	$56,92 \pm 1,69$	$58,87 \pm 1,68$	Ensemble de Árvores LOFAR

Conclusões Finais do Benchmark:

- **Superação do Benchmark:** O **SVM em Cascata ($69,48\%$)** superou expressivamente o **Melhor Baseline do Artigo (MLP LOFAR: $66,25\%$)** em **+3,23 p.p.** de SP e **+2,72 p.p.** de acurácia.
- **Resgate Estratégico:** O ganho resultou do resgate de SMALL ($38,2\% \rightarrow 70,1\%$), mantendo a interpretabilidade e baixo custo computacional frente a redes profundas.

Discussão: Dúvidas e Próximos Passos da Pesquisa

imgs/pee-logo-short.png

Pontos abertos para discussão e direcionamento das próximas etapas:

1. Meta de Desempenho e Artigo

- Devemos tentar sempre melhorar o SP ou temos outros objetivos?
- Qual o patamar de SP almejado? ($\mathbf{69,5}\%$ vs. romper $\mathbf{70} - \mathbf{75}\%$)
- Resultados sustentam novo artigo? (superação do artigo seminal, SVM em Cascata e robustez ao CPA).

2. Novos Formatos de Entrada

- Vale a pena estudar entradas além de LOFAR e MEL?
- **DEMON**: *Demodulation of Envelope*
- **MFCC**: *Mel-Frequency Cepstral Coefficients*

3. Extração e Expansão de Dados

- Extrair novos recortes dados do IARA?
- Avaliar *Data Augmentation* acústico?

4. Avaliação de Novos Modelos

- Quais modelos podemos explorar? *Gated Recurrent Unit* (GRU) ? *Bi-GRU*? *LSTM*?

imgs/pee-logo-short.png

Obrigado!

Evandro Rocha
UFRJ / COPPE / PEE