

Máquinas de Vetor Suporte

Natanael Junior ^{1 2 3}

natmourajr@lps.ufrj.br, natmourajr.github.io

¹Univeridade Federal do Rio de Janeiro

²Programa de Engenharia Elétrica - PEE

³Laboratório de Processamento de Sinais

10/08/2017

Estrutura da Apresentação

- 1 Introdução
- 2 Histórico de Machine Learning
- 3 Como Classificar?
- 4 Máquinas de Vetor Suporte
- 5 Aplicações
- 6 Referências Bibliográficas

- O que é Classificação?

- O que é Classificação?

Definição de Classificação

Em problemas de aprendizado de máquina, a **classificação** é a tarefa de identificar a que de um conjunto de **categorias** um evento pertence, com base em um conjunto de treinamento de dados contendo observações, cuja participação categórica é conhecida.

- O que é Classificação?

Definição de Classificação

Em problemas de aprendizado de máquina, a **classificação** é a tarefa de identificar a que de um conjunto de **categorias** um evento pertence, com base em um conjunto de treinamento de dados contendo observações, cuja participação categórica é conhecida.

- Em outras palavras...é o que você faz o tempo, durante um período de tempo chamado **vida**

- O que é Classificação?

Definição de Classificação

Em problemas de aprendizado de máquina, a **classificação** é a tarefa de identificar a que de um conjunto de **categorias** um evento pertence, com base em um conjunto de treinamento de dados contendo observações, cuja participação categórica é conhecida.

- Em outras palavras...é o que você faz o tempo, durante um período de tempo chamado **vida**
- Inteligência Computacional: Ensinar um computador a classificar...

Um pouco de história...

- **Idade Antiga**: 1943 - Neurônio Artificial [1] e 1961 - *Perceptron* [2, 3].
- **Idade Média**: 1968 - É comprovado **matematicamente** que o *Perceptron* só tem exito em separação de classes linearmente separáveis [4, 5]
- **Idade Moderna**: Década de 1980 - *MultiLayer Perceptron* (MLP) [6], **Backpropagation** [7], Teorema do Aproximador Universal [8] e a Bíblia de Redes Neurais [9].
- **Idade Contemporânea**: Década de 1990 - SVM [10], Redes Bayesianas [11]
- **Idade Contemporânea**: Metade da Década de 1990 - Aprendizado dirigido pelo conhecimento do especialista → Aprendizado dirigido pelos dados

Histórico de *Machine Learning* (cont.)

- **Idade Contemporânea:** Ensemble de Classificadores (*bagging*, *boosted* e derivados) [12] → *Random Florest*, *Boosted Decision Trees*
- **Idade Contemporânea:** *Extreme Learning Machines* [13] → *Reservoir Learning* → *Echo-State Networks*
- 1997 - *IBM Deep Blue* “derrota” Garry Kasparov [14]
- 2006 - *Deep Learning* - o termo é cunhado pela primeira vez [15]
- 2010 - **Microsoft Kineck** - um aparelho utiliza **aprendizado de máquina** para fazer processamento de imagens e tempo real em **escala industrial**
- 2010 - **DeepMind** - a empresa é desenvolvida como sendo uma empresa europeia de aprendizado máquina que, em 2014, será comprada pelo Google
- 2011 - **IBM Watson** derrota dois campeões de *Jeopardy!* [16] - **Processamento de Linguagem Natural**

Histórico de *Machine Learning* (cont.)

- 2011 - **Google Brain** - o programa é desenvolvido. Totalmente voltado para **Deep Learning**
- 2012 - **Google Brain: X Labs** - O laboratório desenvolve um algoritmo de busca autônoma para vídeos no *YouTube* e procura por ...**gatos**
- 2014 - **Facebook** - o programa **DeepFace** é desenvolvido para reconhecer e identificar automaticamente fotos da rede social
- 2015 - **Amazon** - a empresa lança um pacote de desenvolvimento para **Aprendizado de Máquina**
- 2015 - **Microsoft** - outra grande empresa lança um pacote voltado para **Aprendizado de Máquina**, desta vez com o foco em distribuição de processamento visando o ajuste de modelos
- 2016 - **Google DeepMind: AlphaGo** - um algoritmo do Google derrota o campeão mundial de Go (um jogo de tabuleiro chinês). Em comparação com o xadrez (que tem 10^{27} possíveis movimentos), o Go tem 10^{174} possíveis movimentos.


Como classificar?

- Classificadores Lineares
 - Discriminante de Fisher
 - Regressão Logística
 - Classificadores Naïve-Bayes
 - Perceptron
- Máquinas de Vetor Suporte
- Redes Neurais
- Árvores de Decisão
- Vizinhos Mais Próximos (Nearest Neighbor)

Entre Outros...


Como classificar?

- Essencialmente...



Como classificar?


- Podemos separar com uma reta...mas qual?



- Em 1963, durante o seu **doutorado**, **Vladimir N. Vapnik** criou um método que encontra uma reta, por ele considerada, ótima para a separação de duas classes [17]
- Esse método, mais tarde, seria utilizado para a criação das Máquinas de Vetor Suporte (SVM)


- Em 1963, durante o seu **doutorado**, **Vladimir N. Vapnik** criou um método que encontra uma reta, por ele considerada, ótima para a separação de duas classes [17]
- Esse método, mais tarde, seria utilizado para a criação das Máquinas de Vetor Suporte (SVM)
- Vapnik chamou a idéia inicial de o **método da rua mais larga possível** - **Widest Street Approach**

Máquinas de Vetor Suporte



Máquinas de Vetor Suporte


Feature₂



- Chute inicial: da posição da rua
- $\vec{w} \perp$ rua
- Pergunta: De qual lado da rua estará o evento?

Máquinas de Vetor Suporte


Feature₂



- Chute inicial: da posição da rua
- $\vec{w} \perp$ rua
- Pergunta: De qual lado da rua estará o evento?


Máquinas de Vetor Suporte

De qual lado da rua o evento x está?



Máquinas de Vetor Suporte


De qual lado da rua o evento x está?



Máquinas de Vetor Suporte

De qual lado da rua o evento x está?


Feature₂



Máquinas de Vetor Suporte

De qual lado da rua o evento x está?

Feature₂



- $\langle \vec{w}, \vec{x} \rangle + b > 0$: +
- $\langle \vec{w}, \vec{x} \rangle + b < 0$: -
- **Regra de Decisão**
- Qual é o $\vec{w}$?
- Qual é o b ?

Qual o valor **ótimo** de $\vec{w}$?

- Para encontrar esse valor, vamos colocar algumas restrições...

$$\langle \vec{w}, \vec{x}_+ \rangle + b \geq 1$$

$$\langle \vec{w}, \vec{x}_- \rangle + b \leq -1$$

- Ou seja, os eventos de treinamento **no limite** devem se localizar na **sarjeta**

Qual o valor **ótimo** de $\vec{w}$?

- Se os alvos forem no formato **maximamente** esparsos, ou seja

$y_i = +1$ para eventos positivos $y_i = -1$ para eventos negativos

- Então podemos reescrever as equações anteriores como:

$$y_i (\langle \vec{w}, \vec{x}_+ \rangle + b) \geq 1$$

$$y_i (\langle \vec{w}, \vec{x}_- \rangle + b) \geq 1$$

- Ou seja:

$$y_i (\langle \vec{w}, \vec{x} \rangle + b) \geq 1 \rightarrow y_i (\langle \vec{w}, \vec{x} \rangle + b) - 1 \geq 0$$


- Nova **regra de decisão**! No limite: $y_i (\langle \vec{w}, \vec{x} \rangle + b) - 1 = 0$

Máquinas de Vetor Suporte

Idéia inicial...método da rua mais larga...

- Qual a largura da rua em função do que já temos?

Feature₂



Idéia inicial...método da rua mais larga...

- O vetor $\vec{x}_+ - \vec{x}_-$ dependente da posição dos $\vec{x}_+$ e $\vec{x}_-$
- O vetor $\vec{x}_+ - \vec{x}_-$ projetado em $\vec{w}$ gera a largura da rua

Para $x_+ \rightarrow \langle \vec{w}, \vec{x}_+ \rangle = 1 - b$

Para $x_- \rightarrow \langle \vec{w}, \vec{x}_- \rangle = 1 + b$

- Assim sendo a largura se torna $\frac{2}{\|\vec{w}\|}$
- Maximizar a largura $\rightarrow$ Minimizar $\|\vec{w}\| \rightarrow$ Minimizar $\frac{1}{2}\|\vec{w}\|^2$

Para maximizar alguma função com restrições, utilizamos o **multiplicador de Lagrange**

$$L = \frac{1}{2} \|w\|^2 - \sum_i \alpha_i [y_i (\langle \vec{w}, \vec{x} \rangle + b) - 1]$$

- Apenas os α_i de eventos na sarjeta assumirão valores diferentes de 0.

Podemos derivar o multiplicador de Lagrange em função de w , assim para maximização, temos:

$$\frac{\partial L}{\partial w} = w - \sum_i \alpha_i y_i \vec{x} = 0 \rightarrow w = \sum_i \alpha_i y_i \vec{x}_i$$

Podemos derivar o multiplicador de Lagrange em função de b , assim para maximização, temos:

$$\frac{\partial L}{\partial b} = - \sum_i \alpha_i y_i = 0 \rightarrow \sum_i \alpha_i y_i = 0$$

Chegando a duas equações importantes para SVM:

$$w = \sum_i \alpha_i y_i \vec{x}_i \qquad \sum_i \alpha_i y_i = 0$$

Reescrevendo o multiplicador de Lagrange com as equações descritas anteriormente, temos:

$$L = \frac{1}{2} \left(\sum_i \alpha_i y_i \vec{x}_i \right) \cdot \left(\sum_j \alpha_j y_j \vec{x}_j \right) - \sum_i \alpha_i y_i \vec{x}_i \cdot \left(\sum_j \alpha_j y_j \vec{x}_j \right) - \sum_i \alpha_i y_i b + \sum_i \alpha_i$$

Resolvendo, chegamos à:

$$L = \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \langle \vec{x}_i, \vec{x}_j \rangle$$

Reescrevendo a **Regra de Decisão**, temos

$$\sum_i \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b$$


Então:

$$\sum_i \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b > 0 \rightarrow + \qquad \sum_i \alpha_i y_i \langle \vec{x}_i, \vec{x} \rangle + b < 0 \rightarrow -$$

- Ou seja, no caso de classes **linearmente separáveis**, a reta ótima de separação, pode ser obtida por este método
- A otimização é feita em uma **função convexa**, ou seja, sem **mínimos locais**!


Máquinas de Vetor Suporte

Ok, mas e no caso de classes não-linearmente separáveis? Que tal tentar uma nova **perspectiva**?



Máquinas de Vetor Suporte

Ok, mas e no caso de classes não-linearmente separáveis? Que tal tentar uma nova **perspectiva**?




- Quanto mais dimensões nos dados, maior a capacidade de discriminação dos mesmos
- Todos os algoritmos se beneficiam disso? **Não!** Somente aqueles que tem funções de atualização convexas (SVM)
- Para a utilização: “*Kernel Trick*”

$$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$$

- Levar para uma alta dimensão e lá fazer a separação.

Máquinas de Vetor Suporte




Soft-Margin


- A proposta inicial do SVM é que no limite os eventos estejam na sarjeta.
- Nem sempre todos os eventos respeitam isso.
- Neste caso, o tamanho da rua deve variar para acomodar todos os eventos
- Consequência: Diminuição do tamanho da rua (margem) → afastamento do ótimo → perda de generalização

Máquinas de Vetor Suporte

Soft-Margin




Soft-Margin



Detecção de Novidade em Sinais de Sonar Passivo

O ambiente submarino é **altamente** ruidoso


- Ruídos de Navios (propulsão, maquinários e etc)
- Ruídos de Animais Marinhos (camarões, cetáceos e etc)
- Ruídos Ambientais (chuva, ondas, deslocamentos sísmicos e etc)
- Possível ocorrência de multi-caminhos (reflexão no material do leito do mar)




Detecção de Novidade em Sinais de Sonar Passivo

Além de ruidoso, os espectros dos diversos ruídos por muitas vezes se sobrepõem.

Ambient and Localised Noise Sources in the Ocean




Caso Ideal



Detecção de Novidade em Sinais de Sonar Passivo


LOFARgram for ClassA with Decimation Ratio: 3 and 1024 FFT Points







- Cada linha: 400 bins de frequência
- Cada bin: intensidade da frequência no instante de tempo

Detecção de Novidade em Sinais de Sonar Passivo

Para o encapsulamento dos dados, o treinamento da SVM deve ser modificado como mostrado em [18]







Detecção de Novidade em Sinais de Sonar Passivo



- Margem muito estreita
- Alta Quantidade de SVs
- Baixa Prob. de Detecção
- Alta Eficiência para Detecção de Novidade

Resultados Qualitativos - $\nu = 0.001$



- Margem flexível
- Redução drástica na quantidade de SVs
- Elevada Prob. de Detecção
- Redução na Detecção de Novidade

**Perguntas?
Obrigado**

Referências Bibliográficas

- [1] W. S. McCulloch and W. Pitts, “A logical calculus of the ideas immanent in nervous activity,” *The bulletin of mathematical biophysics*, vol. 5, no. 4, pp. 115–133, 1943.
- [2] F. Rosenblatt, “The perceptron, a perceiving and recognizing automaton: (project para),” report, Cornell Aeronautical Laboratory, 1957.
- [3] F. Rosenblatt, *Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms*. Spartan Books, 1962.
- [4] J. Mycielski, “Review: Marvin minsky and seymour papert, perceptrons, an introduction to computational geometry,” *Bulletin of the American Mathematical Society*, vol. 78, pp. 12–15, 01 1972.

Referências Bibliográficas (cont.)

- [5] M. Minsky and S. Papert, *Perceptrons: An Introduction to Computational Geometry*.
The MIT Press, 1st edition ed., 1969.
- [6] K. Hornik, "Approximation capabilities of multilayer feedforward networks," *Neural Networks*, vol. 4, no. 2, pp. 251 – 257, 1991.
- [7] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning internal representations by error propagation," in *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1* (D. E. Rumelhart, J. L. McClelland, and C. PDP Research Group, eds.), pp. 318–362, Cambridge, MA, USA: MIT Press, 1986.
- [8] G. Cybenko, "Approximation by superpositions of a sigmoidal function," *Mathematics of Control, Signals and Systems*, vol. 2, no. 4, pp. 303–314, 1989.

Referências Bibliográficas (cont.)

- [9] S. Haykin, *Neural Networks: A Comprehensive Foundation*. MacMillan Publishing Company, 1994.
- [10] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [11] J. Pearl, "Bayesian networks: A model of self-activated memory for evidential reasoning," in *Proceedings of the 7th Conference of the Cognitive Science Society, University of California, Irvine*, pp. 329–334, Aug. 1985.
- [12] L. Rokach, "Ensemble-based classifiers," *Artificial Intelligence Review*, vol. 33, no. 1, pp. 1–39, 2010.

Referências Bibliográficas (cont.)

- [13] G.-B. Huang, Q.-Y. Zhu, and C.-K. Siew, “Extreme learning machine: Theory and applications,” *Neurocomputing*, vol. 70, no. 1–3, pp. 489 – 501, 2006.

Neural Networks
Selected Papers from the 7th Brazilian Symposium on Neural Networks (SBRN '04)
7th Brazilian Symposium on Neural Networks.

- [14] F.-H. Hsu, *Behind Deep Blue: Building the Computer that Defeated the World Chess Champion*.

Princeton University Press, 2004.

- [15] G. E. Hinton, S. Osindero, and Y.-W. Teh, “A fast learning algorithm for deep belief nets,” *Neural Comput.*, vol. 18, pp. 1527–1554, July 2006.

- [16] D. A. Ferrucci, “Introduction to “this is watson”,” *IBM Journal of Research and Development*, vol. 56, pp. 1:1–1:15, May 2012.

- [17] B. E. Boser, I. M. Guyon, and V. N. Vapnik, “A training algorithm for optimal margin classifiers,” in *Proceedings of the Fifth Annual Workshop on Computational Learning Theory, COLT '92*, (New York, NY, USA), pp. 144–152, ACM, 1992.
- [18] B. Schölkopf and A. J. Smola, *Learning with Kernels*. Cambridge, MA: MIT Press, 2002.