Engenharia Elétrica UFRJ

COPPE UFRJ
Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia

Reconhecimento Acústico de Alvos Submarinos no Dataset IARA

Reunião de 26/10/2026: Próximos Passos

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ / COPPE / PEE

26 de outubro de 2026

Agenda da Apresentação

I. Onde Estamos

1. Panorama: Modelos e Representações Implementados

II. Para Onde Vamos

2. Próximos Passos



Panorama de Resultados

Representações de Espectro Implementadas

MEL

Log-espectrograma em escala Mel (256 bandas): comprime as altas frequências e preserva a envoltória espectral de banda larga.

HHT

Transformada de Hilbert–Huang: decomposição em modos intrínsecos e espectro de Hilbert (sinais não estacionários).

LOFAR

Espectrograma com normalização TPSW (remove o fundo de banda larga e realça linhas tonais): 1.024 faixas de 7,8 Hz, até 8 kHz.

DEMON

Demodulação da envoltória: frequências de modulação ligadas à rotação do eixo e ao número de pás do hélice.

MEL e LOFAR são as representações do artigo (Silva et al., 2025); HHT e DEMON foram acrescentadas neste trabalho.

Modelos Implementados: Índice SP (%)

Família	MEL	LOFAR	HHT	DEMON
Random Forest	$61,5 \pm 1,9$	$63,1 \pm 1,8$	$57,6 \pm 2,1$	$44,4 \pm 2,2$
SVM Nyström	$63,8 \pm 1,1$	$63,8 \pm 1,9$	$51,2 \pm 6,1$	$44,9 \pm 4,6$
MLP [32, 16]	$64,7 \pm 2,0$	$66,2 \pm 1,8$	$56,7 \pm 1,4$	$53,1 \pm 2,4$
BiGRU + atenção	$63,6 \pm 1,5$	$62,2 \pm 1,1$	$58,2 \pm 2,1$	$55,5 \pm 1,4$
CNN 2D	$65,5 \pm 1,7^{\dagger}$	$66,5 \pm 1,3$	$60,7 \pm 2,0$	$53,2 \pm 2,3$
SVM em cascata (híbrido)‡		$67,2 \pm 1,8$		
Artigo: melhor modelo		**CNN** $66,05 \pm 1,90$		

10 folds do 5 × 2cv, 4 classes, voto por gravação. As CNNs LOFAR e MEL são as do artigo (reproduzidas); †artigo: $63,52 \pm 2,26$ (a CNN MEL antiga do repositório, de outra arquitetura, dava $63,8 \pm 2,2$; $p = 0,02$). ‡SVM LOFAR seguido de um especialista SMALL × LARGE (MEL + LOFAR-PCA8), por janela: recall SMALL $38,2 \rightarrow 63,7\%$ e LARGE $76,3 \rightarrow 63,5\%$ em relação ao SVM LOFAR.

Patamar

Com MEL ou LOFAR, todas as famílias ficam entre **61,5% e 66,5%** de SP; a cascata chega a **67,2%**. Não há diferença significativa entre os melhores (cascata vs. MLP LOFAR: $p = 0,56$; vs. CNN LOFAR: $p = 0,78$; F-test 5 × 2cv), e todos estão dentro de um desvio do artigo.

Recall por Classe: SMALL e MEDIUM São as Mais Difíceis

Recall médio (%) por representação

	SMALL	MEDIUM	LARGE	BACKGR.
MEL	49,2	61,7	68,3	79,0
LOFAR	47,2	58,5	73,5	81,9
HHT	38,8	55,7	68,2	72,1
DEMON	34,2	44,2	68,0	66,1
20 modelos	**42,4**	**55,0**	**69,5**	**74,8**
faixa	12–58	35–64	61–79	28–88

Média das 5 famílias em cada representação.

Para onde vão os erros (MEL e LOFAR)

Real \ Pred.	S	M	L	B
SMALL	**48,2**	23,1	22,2	6,5
MEDIUM	24,5	**60,1**	13,4	2,0
LARGE	14,6	12,1	**70,9**	2,4
BACKGR.	10,4	4,2	5,0	**80,4**

% por linha; 10 modelos (5 famílias × MEL/LOFAR).

Leitura

LARGE e **BACKGROUND** são as classes mais fáceis; **SMALL** é a mais difícil (menos da metade acertada) e se confunde quase igualmente com MEDIUM e LARGE. Os erros se concentram entre as **classes de navios**: só 2–7% dos navios são classificados como fundo. É o principal alvo da Tarefa 1.

Os Modelos Erram Juntos

Q de Yule entre os erros de dois modelos, por gravação (+1 = erram sempre juntos; 0 = erros independentes):

Mesma representação, famílias diferentes

Mediana **Q = 0,83** (0,55 a 0,97)

	MEL	LOFAR	HHT	DEMON
Q	0,87	0,87	0,83	0,76

Mesma família, representações diferentes

Mediana **Q = 0,63** (0,47 a 0,90)

Par	Q
MEL × LOFAR	0,83
MEL × DEMON	0,53

Leitura

Trocar o classificador muda pouco: os erros dependem mais da **gravação** e da **representação** do que do modelo. Há gravações que todos erram (o caso extremo são SMALL com energia concentrada abaixo de 200 Hz, como navios grandes). Isso motiva olhar diretamente para o **conteúdo espectral** das classes.



Próximos Passos

Tarefa 1: Frequências Comuns no LOFAR por Classe

Objetivo

Comparar os espectros LOFAR de SMALL, MEDIUM e LARGE e encontrar **frequências comuns** a cada classe — e verificar se as gravações que os modelos erram têm o padrão de frequências de outra classe.

(a) Espectro médio

- Espectro LOFAR médio de cada classe.
- Diferença entre classes, faixa a faixa, com teste estatístico e correção FDR.

(b) Linhas tonais

- Picos que persistem no tempo em cada gravação.
- Frequências e harmônicos mais comuns em cada classe.

(c) Acertos × erros

- Repetir (a) e (b) separando gravações acertadas e erradas.
- Ex.: os SMALL errados se parecem com o espectro de LARGE?

Extensão: repetir (a)–(c) com MEL, HHT e DEMON (no DEMON, frequências de modulação: rotação do eixo e pás).
Custo: LOFAR já processado para as 1.706 gravações; roda em CPU.

Tarefa 2: Multi-Head Adaptativo e HHT Modificada

Objetivo

Obter códigos de outros projetos e avaliar se podem ser incorporados ao pipeline do IARA.

(a) Multi-head adaptativo (Mateus)

- Enviar e-mail ao Mateus solicitando o código.
- Analisar o código.
- Verificar se pode ser usado no IARA.

(b) HHT modificada (Natanael)

- Solicitar o código ao Natanael.
- Reimplementar em Python.

Tarefa 3: Combinação de Representações

Objetivo

Criar uma **nova representação** que combine MEL, LOFAR, HHT e DEMON, para servir de entrada no treino de novos modelos.

Já feito: MEL + DEMON por concatenação simples (um vetor colado no outro). A questão é se existe uma forma melhor de combinar.

Imagem multicanal

Levar as representações a um eixo de tempo e frequência comum e empilhá-las como canais de uma mesma imagem (como o RGB).

Projeção conjunta

Extrair componentes que resumem as representações em conjunto (ex.: PCA conjunta, análise de correlação canônica).

Seleção de bandas

Montar um vetor com as faixas mais informativas de cada representação, guiado pelas frequências da Tarefa 1.

Desafio: as representações têm resoluções diferentes — MEL e LOFAR a cada 0,512 s; HHT e DEMON a cada $\sim$5 s — e eixos distintos (o DEMON mede frequência de modulação, não frequência acústica).

Tarefa 4: Compactação das Representações

Objetivo

Verificar se representações compactadas (menos dimensões) ajudam os modelos a classificar.

LOFAR + PCA

Projeção linear nos componentes de maior variância.

LOFAR + KPCA

PCA com *kernel*: captura relações não lineares entre as frequências.

HHT + Autoencoder

Rede que aprende a comprimir e reconstruir a representação; o código comprimido vira a entrada do classificador.

Já feito: PCA de 64 componentes no SVM LOFAR, sem efeito significativo, e LOFAR-PCA8 no especialista híbrido SMALL $\times$ LARGE.
Avaliação: compactação ajustada só no treino de cada fold; comparar com a representação original no mesmo modelo (F-test 5×2cv).

Tarefa 5: Modelos Mais Recentes

Objetivo

Verificar se arquiteturas mais recentes, que modelam a sequência temporal do sinal, melhoram a classificação.

Recorrentes

- LSTM e GRU
- Bi-LSTM e Bi-GRU (leem a sequência nos dois sentidos)

Transformers

Atenção sobre toda a sequência de janelas, sem recorrência.

Seq-KAN

Redes de Kolmogorov–Arnold aplicadas a sequências.

Já feito: Bi-GRU com atenção nas 4 representações (SP de 55,5% a 63,6%) e GRU em experimentos com MEL + LOFAR-PCA. Ainda não implementados: LSTM, Bi-LSTM, Transformers e Seq-KAN.

Tarefa 6: LOFAR $\times$ DEMON ao Longo do Tempo

Objetivo

Acompanhar, janela a janela, a classificação do LOFAR junto com a do DEMON e ver se as duas vão concordando ao longo da gravação.

Como

- Alinhar no tempo (LOFAR a cada 0,512 s; DEMON a cada $\sim$5 s).
- Registrar a classe de cada um por instante. Ex.: janela 1 — LOFAR = LARGE, DEMON = LARGE.

O que observar

- Trechos em que concordam e em que divergem.
- Efeito da aproximação do navio (CPA).
- Se, quando concordam, a classificação acerta mais.

Analogia: apuração das eleições

As regiões entram na contagem em tempos distintos (normalmente o Sudeste antes do Nordeste), e não se espera o Nordeste para começar a apurar. Da mesma forma: classificar continuamente com o modelo de janelas curtas (LOFAR) e, quando chegar a decisão do modelo de janelas longas (DEMON), **combinar na votação**.



Obrigado!

Evandro Rocha
UFRJ / COPPE / PEE