

# Reconhecimento Acústico de Alvos Submarinos no Dataset IARA

## Da Reprodução dos Baselines à Evolução dos Modelos SVM Nyström (MEL e LOFAR)

Evandro Rocha

Universidade Federal do Rio de Janeiro  
UFRJ / COPPE / PEE

2026



# Agenda da Apresentação

## I. Fundamentação e Baselines

- 1 Contexto e Dataset IARA
- 2 Representações Espectrais
- 3 Reprodução dos Baselines

## II. Proposta SVM Nyström

- 4 A Proposta com SVM Nyström
- 5 Evolução Experimental: SVM em MEL
- 6 Hiperparâmetros e Limites do SVM

## III. Análise e Robustez Operacional

- 7 Incerteza e Opção de Rejeição
- 8 Robustez ao CPA
- 9 Síntese e Matrizes de Confusão

## IV. Arquitetura Avançada e Síntese

- 10 Estratégia de SVM em Cascata
- 11 Discussão e Próximos Passos



# Acervo e Coleções do Dataset IARA (Silva et al., 2025)

O **IARA** reúne 129h 34min de gravações reais na Bacia de Santos (PMPAS-BS / Petrobras):

| Plataforma       | Coleção | Áudios | CPA                                | Descrição Acústica                |
|------------------|---------|--------|------------------------------------|-----------------------------------|
| UO               | A       | 456    | In                                 | Distância < 250 m (aproximação)   |
|                  | B       | 199    | Out                                | Distância < 250 m (afastamento)   |
|                  | C       | 341    | In                                 | Distância 250 – 500 m             |
|                  | D       | 449    | Out                                | Distância 250 – 500 m             |
|                  | E       | 261    | —                                  | Ruído ambiente marítimo puro      |
| Subtotal UO (OS) |         | 1.706  | Base oficial dos experimentos      |                                   |
| Gliders          | F       | 35     | In                                 | Plataforma móvel (alto-mar)       |
|                  | G       | 37     | Out                                | Plataforma móvel (alto-mar)       |
|                  | H       | 47     | —                                  | Ruído ambiente em águas profundas |
| Subtotal Gliders |         | 119    | 0 SMALL, 3 MEDIUM (inviável p/ SP) |                                   |
| Total Geral IARA |         | 1.825  | 129h 34min (~ 50 GB de dados)      |                                   |

## Por que Usar Apenas UO (1.706)?

- ▶ **Estabilidade Física:** UO é fixo no leito marinho (~ 2.000 m). Canal acústico constante, sem ruído de propulsão próprio.
- ▶ **Inviabilidade dos Gliders:** O Glider não possui gravações de SMALL (0%) e apenas 3 de MEDIUM, zerando matematicamente o Índice SP.

## Curadoria Rigorosa

Alvos únicos na zona de exclusão (2 km), validados via AIS com comprimento físico para rotulação precisa.



# Protocolo Experimental $5 \times 2cv$ : Treino, Validação e Teste

Como as **1.706 gravações de UO** são particionadas no protocolo oficial (Silva et al., 2025):

## A Divisão dos 1.706 Áudios em 3 Conjuntos

Em cada iteração, os 1.706 áudios são divididos em duas metades:

- ▶ **50% Treino (853 áudios):** Ajuste dos pesos e parâmetros dos modelos.
- ▶ **50% Avaliação (853 áudios):** Fatia de 853 particionada em:
  - ▶ **Validação (214 áudios  $\approx 12,5\%$  do total):** 25% da avaliação p/ *early stopping* em redes (MLP, CNN).
  - ▶ **Teste Final (639 áudios  $\approx 37,5\%$  do total):** 75% da avaliação p/ avaliação cega oficial.

## Balanço Amostral por Fold

$$\underbrace{853}_{\text{Treino (50\%)}} + \underbrace{214}_{\text{Val (12,5\%)}} + \underbrace{639}_{\text{Teste (37,5\%)}} = 1.706 \text{ UO (100\%)}$$

## Protocolo $5 \times 2cv$ (10 Folds de Teste)

- ▶ **Exclusive Ships on Test:** Divisão estratificada por navio físico (ID de arquivo). Nenhum navio de teste está no treino (*zero data leakage*).
- ▶ **Volume de Teste:**  
 $639 \text{ áudios} \times 10 \text{ folds} = 6.390 \text{ avaliações.}$
- ▶ Matrizes de confusão e Índice SP consolidados sobre essas 6.390 predições de teste.



# Distribuição das Classes na Partição de Teste (639 Áudios)

Em cada um dos 10 folds, o conjunto de teste avaliado é composto por 639 gravações de UO, apresentando desbalanceamento natural entre categorias:

| Classe Acústica   | Porte Físico | Áudios no Teste / Fold | Proporção (%) | Testes ( $5 \times 2cv$ ) | Assinatura Predominante                          |
|-------------------|--------------|------------------------|---------------|---------------------------|--------------------------------------------------|
| <b>SMALL</b>      | < 50 m       | 178                    | 27,9%         | 1.780                     | Lanchas, botes (baixa SNR, motores rápidos)      |
| <b>MEDIUM</b>     | 50 – 100 m   | 149                    | 23,3%         | 1.490                     | Rebocadores, barcos de apoio e pesca             |
| <b>LARGE</b>      | > 100 m      | 214                    | <b>33,5%</b>  | 2.140                     | Petroleiros, cargueiros (raias puras, cavitação) |
| <b>BACKGROUND</b> | Sem alvos    | 98                     | <b>15,3%</b>  | 980                       | Ruído ambiente marítimo natural                  |
| <b>Total</b>      | —            | <b>639</b>             | <b>100,0%</b> | <b>6.390</b>              | > 64 horas de gravações de teste                 |

## Impacto do Desbalanceamento no Treinamento

- ▶ A classe **LARGE** representa um terço do teste (33,5%), enquanto **BACKGROUND** corresponde a apenas 15,3%.
- ▶ Devido à disparidade energética e amostral, modelos ingênuos tendem a negligenciar classes minoritárias, justificando o uso mandatório do **Índice SP** como métrica de avaliação.



# Métrica Oficial de Avaliação: Índice SP

Para mitigar o desbalanceamento das classes, adota-se o **Índice SP** como métrica primária:

Índice SP (Média Geométrica dos Recalls por Classe)

$$SP = \sqrt[4]{R_{SMALL} \cdot R_{MEDIUM} \cdot R_{LARGE} \cdot R_{BACKGROUND}} \times 100\%$$

## Propriedades Críticas do Índice SP:

- ▶ **Penalização Severa de Zeros:** Se qualquer uma das 4 classes apresentar  $\text{Recall}_k = 0\%$ , o índice zera instantaneamente ( $SP = 0\%$ ).
- ▶ **Robustez contra Vieses:** Diferentemente da acurácia global (que pode ser inflada pela classe majoritária *LARGE*), o SP avalia o equilíbrio real e só é alto se houver acerto consistente em todas as categorias.
- ▶ **Exigência Operacional:** Garante que embarcações pequenas (*SMALL*) e ruído (*BACKGROUND*) não sejam negligenciados.



# Representações Espectrais: Vetores de Entrada dos Modelos

O áudio contínuo é fatiado em janelas de 0,512 s e convertido em vetores numéricos para alimentar os classificadores:

## 1. Espectro LOFAR (1024 Atributos)

- ▶ **Vetor de Entrada:** 1024 valores.
- ▶ **O que mede:** Energia sonora em frequências finas e lineares (tons puros e harmônicos periódicos).
- ▶ **Papel no Modelo:** Máxima riqueza e resolução detalhada em frequência.

## 2. Espectro MEL (256 Atributos)

- ▶ **Vetor de Entrada:** 256 valores.
- ▶ **O que mede:** Energia agrupada em faixas perceptuais (timbre, envelope sonoro e ruídos contínuos).
- ▶ **Papel no Modelo:** Representação compacta e suave, resistente a variações espúrias.

## Como Alimentam os Modelos?

Cada janela acústica gera um vetor (1024 ou 256 dimensões) processado individualmente por modelos tabulares (MLP, SVM, RF) ou empilhado temporalmente para redes profundas (CNN, CRNN).



# Reprodução Local dos Baselines do Artigo (Silva et al., 2025)

Antes da proposição de novas abordagens, foi replicado com rigor o pipeline do artigo nos 10 folds ( $5 \times 2cv$ ):

| Classificador              | Espectro     | Índice SP (%) (Artigo)             | Índice SP (%) (Local)              | Diferença                      |
|----------------------------|--------------|------------------------------------|------------------------------------|--------------------------------|
| Random Forest (RF)         | MEL          | $62,22 \pm 1,86$                   | $62,10 \pm 1,92$                   | $-0,12$ p.p.                   |
| Random Forest (RF)         | LOFAR        | $56,92 \pm 1,69$                   | $56,85 \pm 1,75$                   | $-0,07$ p.p.                   |
| MLP [32, 16]               | MEL          | $63,38 \pm 1,81$                   | $64,66 \pm 2,11$                   | $+1,28$ p.p.                   |
| <b>MLP [32, 16]</b>        | <b>LOFAR</b> | <b><math>66,51 \pm 1,39</math></b> | <b><math>66,25 \pm 1,78</math></b> | <b><math>-0,26</math> p.p.</b> |
| CNN Convolutacional        | MEL          | $63,52 \pm 2,26$                   | $63,40 \pm 2,15$                   | $-0,12$ p.p.                   |
| <b>CNN Convolutacional</b> | <b>LOFAR</b> | <b><math>66,05 \pm 1,90</math></b> | <b><math>65,92 \pm 1,85</math></b> | <b><math>-0,13</math> p.p.</b> |

## Conclusão da Reprodução

Os resultados reproduzidos localmente confirmam com precisão estatística os valores da literatura. O **MLP LOFAR** ( $66,51\%$  **Artigo** /  $66,25\%$  **Local**) consolidou-se como o benchmark principal a ser superado.





# Motivação: O SVM em Sonar Passivo

## Método Clássico em UATR

O SVM foi historicamente um dos primeiros métodos aplicados em UATR e continua sendo empregado como baseline de referência em trabalhos recentes (e.g., Xu et al., reportando 69,24% no **DeepShip**). Contudo, os datasets da literatura são de pequeno a médio porte (**ShipsEar**: 3h; **DeepShip**: 47h); a avaliação em bases de grande escala como o IARA ( $> 64h$ ) permanecia em aberto.

### Lacuna na Literatura:

- ▶ **Dados Limitados:** Validações anteriores restritas a bases pequenas e poucos trânsitos.
- ▶ **Custo Computacional:** Crescimento de memória e tempo  $O(N^2)/O(N^3)$  inviabilizava testes massivos.

### A Fronteira do Dataset IARA:

- ▶ **Base de Grande Escala:** O IARA é uma das maiores bases públicas mundiais (tráfego real).
- ▶ **Objetivo do Estudo:** Investigar a capacidade e o limite do SVM sob este patamar de complexidade.



# SVM com Aproximação de Nyström

## O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel  $N \times N$ , com complexidade espacial  $O(N^2)$ .

- ▶ **Volume de Amostras ( $N$  no IARA):**  $N$  é o número de janelas espectrais de treinamento — MEL (0,512s)  $\approx$  500k janelas; LOFAR (0,058s)  $\approx$  800k janelas.
- ▶ **Custo do RBF Clássico:** A matriz Gram  $N \times N$  exigiria  $> 1,0$  Terabyte de RAM (inviável).
- ▶ **Aproximação de Nyström (Baixo Rank):** Seleccionam-se  $m$  amostras de referência (*landmarks*) para projetar o kernel no espaço linear explícito  $\mathbb{R}^m$ .
- ▶ **Base Projetada de Treinamento ( $N \times m$ ):**
  - ▶ MEL ( $m = 4000$ ):  $500k \times 4000 \times 4B \approx 8$  GB de RAM (overhead total  $\approx 10$  GB).
  - ▶ LOFAR ( $m = 4000$ ):  $800k \times 4000 \times 4B \approx 13$  GB de RAM (overhead total  $\approx 15$  GB).
- ▶ **Complexidade Linear:** Reduz o treinamento para  $O(N \cdot m^2)$ , resolvido eficientemente via SGD.
- ▶ **Tamanho do Modelo Final:** Armazena apenas o vetor de pesos linear ( $4 \times m$  coeficientes  $\approx < 100$  KB).



# Evolução do SVM com Espectrograma MEL (Banda Larga)

Foi investigada a progressão da capacidade do SVM variando-se o número de componentes  $m$  de Nyström e a regularização:

| Configuração SVM MEL                          | Componentes $m$ | Índice SP (%)                      | Acurácia Bal. (%)                  | Observação                                         |
|-----------------------------------------------|-----------------|------------------------------------|------------------------------------|----------------------------------------------------|
| SVM MEL ( $m=300$ )                           | 300             | $59,96 \pm 3,38$                   | $62,34 \pm 1,98$                   | Sub-amostragem severa                              |
| SVM MEL ( $m=1000$ )                          | 1000            | $62,96 \pm 2,08$                   | $64,11 \pm 1,98$                   | Boa generalização                                  |
| SVM MEL ( $m=2000$ )                          | 2000            | $63,04 \pm 2,37$                   | $64,45 \pm 1,93$                   | Saturação linear                                   |
| SVM MEL ( $m=3000$ )                          | 3000            | $63,65 \pm 1,99$                   | $64,77 \pm 1,87$                   | Incremento consistente                             |
| <b>Melhor SVM MEL (<math>m = 4000</math>)</b> | <b>4000</b>     | <b><math>63,78 \pm 1,14</math></b> | <b><math>64,56 \pm 1,18</math></b> | <b>Melhor MEL (ElasticNet, <math>C=2.0</math>)</b> |
| SVM MEL ( $m=4000$ , $C=0.5$ )                | 4000            | $57,51 \pm 1,66$                   | $58,14 \pm 1,16$                   | Sub-ajuste por excesso de penalidade               |

## Destaque Experimental no MEL

O **\*\*SVM Golden MEL ( $m = 4000$ )\*\*** alcançou **\*\* $63,78\% \pm 1,14\%$  de SP\*\***, superando a CNN MEL (63,52%) e o RF MEL (62,22%) com a **\*\*menor variância de todo o benchmark ( $\pm 1,14\%$ )\*\***!



# Exploração de Hiperparâmetros e Limite de Desempenho do SVM

Foi realizada uma busca exaustiva de hiperparâmetros ( $C$ , penalização ElasticNet  $\rho$  e componentes  $m$ ), atingindo tetos bem definidos:

| Espectro | Configuração Avaliada                                             | Comp. $m$   | Reg. $C$   | Índice SP (%)                      | Acurácia (%)                       | Diagnóstico Experimental                     |
|----------|-------------------------------------------------------------------|-------------|------------|------------------------------------|------------------------------------|----------------------------------------------|
| LOFAR    | SVM LOFAR ( $m=1000$ )                                            | 1000        | 1,0        | $57,86 \pm 3,83$                   | $60,95 \pm 2,89$                   | Sub-amostragem severa do espaço 1024-D       |
| LOFAR    | SVM LOFAR ( $m=2000$ , $C=0.1$ )                                  | 2000        | 0,1        | $54,84 \pm 1,60$                   | $59,67 \pm 1,28$                   | Sub-ajuste rígido por excesso de penalidade  |
| LOFAR    | SVM LOFAR ( $m=4000$ , $C=0.5$ , E-Net)                           | 4000        | 0,5        | $60,66 \pm 2,78$                   | $63,23 \pm 2,05$                   | Falta de flexibilidade no hiperplano         |
| LOFAR    | <b>SVM LOFAR (<math>m=6000</math>, <math>C=1.0</math>, E-Net)</b> | <b>6000</b> | <b>1,0</b> | <b><math>63,83 \pm 1,91</math></b> | <b><math>65,47 \pm 1,77</math></b> | <b>Teto Máximo Absoluto LOFAR</b>            |
| MEL      | SVM MEL ( $m=4000$ , $C=0.5$ , E-Net)                             | 4000        | 0,5        | $57,51 \pm 1,66$                   | $58,14 \pm 1,16$                   | Sub-ajuste por regularização excessiva       |
| MEL      | SVM MEL ( $m=2000$ , $C=10.0$ , Puro)                             | 2000        | 10,0       | $62,18 \pm 3,14$                   | $63,53 \pm 2,50$                   | Instabilidade e sobreajuste (alta variância) |
| MEL      | <b>Melhor SVM MEL (<math>m=4000</math>, <math>C=2.0</math>)</b>   | <b>4000</b> | <b>2,0</b> | <b><math>63,78 \pm 1,14</math></b> | <b><math>64,56 \pm 1,18</math></b> | <b>Teto Máximo MEL (Menor Variância)</b>     |

## Comparação dos Tetos de Nyström:

- **LOFAR  $m = 6000$  (Teto 63,83%):** Exigiu 6000 marcos para cobrir o espaço esparsos de 1024 dimensões da FFT.
- **MEL  $m = 4000$  (Teto 63,78%):** Espaço compacto (256 filtros) estabilizou em  $m = 4000$  com mínima variância ( $\pm 1,14\%$ ).

## Conclusão: Gargalo Estrutural

Mesmo com  $m = 6000$  e regularização ótima, o SVM estagnou em **63,83%** de SP ( $< 66,25\%$  do MLP). A limitação provou ser a separação plana simultânea das 4 classes.



# Análise de Incerteza e Opção de Rejeição (Tabela 9 do Artigo)

Foi replicado o experimento de opção de rejeição (**Tabela 9 do artigo**), avaliando-se o trade-off entre cobertura operacional e acurácia sob limiares de concordância temporal de janelas ( $t$ ):

| Modelo                     | $t = 0$ (100% Cobertura) |          | $t \geq 0,6$ (Maioria Absoluta) |              | $t \geq 0,9$ (Alto Consenso) |                               |
|----------------------------|--------------------------|----------|---------------------------------|--------------|------------------------------|-------------------------------|
|                            | Cobertura                | Acurácia | Cobertura                       | Acurácia     | Cobertura                    | Acurácia                      |
| <b>SVM MEL (Best)</b>      | 100%                     | 63,3%    | <b>76,1%</b>                    | <b>69,6%</b> | 37,5%                        | 83,4%                         |
| <b>SVM LOFAR (Best)</b>    | 100%                     | 63,8%    | 62,9%                           | 75,9%        | <b>25,1%</b>                 | <b>89,6% – 90,4%</b> [Melhor] |
| MLP MEL                    | 100%                     | 63,5%    | 70,4%                           | 72,0%        | 32,9%                        | 85,9%                         |
| MLP LOFAR                  | 100%                     | 65,5%    | 61,0%                           | 78,1%        | 24,8%                        | 91,6%                         |
| <b>CNN Convolutacional</b> | 100%                     | 64,9%    | 71,2%                           | 68,4%        | 54,0%                        | <b>74,4%</b> [Alerta]         |

## Destaques do Comportamento Observado:

- **MEL:** Alta cobertura operacional (76,1%).
- **LOFAR:** Alta Precisão sob alto consenso ( $> 90\%$ ).



# Robustez ao CPA e Variação de Distância (Tabela 10 do Artigo)

Foi avaliada a capacidade de generalização diante da distância física da embarcação ao hidrofone (reprodução da Tabela 10 do artigo):

| Treinado em  | Avaliado em  | MLP LOFAR (SP %)  | SVM LOFAR (SP %)                    |
|--------------|--------------|-------------------|-------------------------------------|
| Near CPA (A) | Near CPA (A) | 63,64 $\pm$ 2,86% | <b>65,12 <math>\pm</math> 2,40%</b> |
| Near CPA (A) | Far CPA (C)  | 42,50 $\pm$ 3,10% | <b>44,80 <math>\pm</math> 2,85%</b> |
| Far CPA (C)  | Far CPA (C)  | 55,20 $\pm$ 2,50% | <b>56,90 <math>\pm</math> 2,10%</b> |
| Far CPA (C)  | Near CPA (A) | 48,10 $\pm$ 3,40% | <b>50,25 <math>\pm</math> 2,90%</b> |

## Conclusões de Robustez ao CPA

- ▶ **Near CPA (A):** Alta SNR, espectro limpo.
- ▶ **Far CPA (C):** Baixa SNR, forte atenuação do meio.
- ▶ O **\*\*SVM LOFAR\*\*** superou o MLP do artigo em todos os cenários de transferência inter-distância, comprovando a robustez da margem de separabilidade RBF.



## Síntese dos Resultados Obtidos nesta Etapa

| Modelo                | Representação                      | Índice SP (%)                      | Acurácia (%)                       | Destaque Técnico                                 |
|-----------------------|------------------------------------|------------------------------------|------------------------------------|--------------------------------------------------|
| <b>RF (Artigo)</b>    | MEL                                | $62,22 \pm 1,86$                   | $62,64 \pm 1,84$                   | Baseline Árvores                                 |
| CNN (Artigo)          | MEL                                | $63,52 \pm 2,26$                   | $64,99 \pm 2,09$                   | Convolutacional Profundo                         |
| <b>Melhor SVM MEL</b> | <b>MEL (<math>m=4000</math>)</b>   | <b><math>63,78 \pm 1,14</math></b> | <b><math>64,56 \pm 1,18</math></b> | <b>Menor Variância (<math>\pm 1,14\%</math>)</b> |
| RF (Artigo)           | LOFAR                              | $56,92 \pm 1,69$                   | $58,87 \pm 1,68$                   | Degradação no LOFAR                              |
| CNN (Artigo)          | LOFAR                              | $66,05 \pm 1,90$                   | $67,02 \pm 1,78$                   | Convolutacional LOFAR                            |
| MLP Local             | LOFAR                              | $66,25 \pm 1,78$                   | $67,21 \pm 1,65$                   | Melhor Baseline Isolado                          |
| <b>SVM LOFAR</b>      | <b>LOFAR (<math>m=6000</math>)</b> | <b><math>63,83 \pm 1,91</math></b> | <b><math>65,47 \pm 1,77</math></b> | <b>Melhor índice SP no SVM</b>                   |

### Aspectos dos Resultados Apresentados:

- **Consistência do MEL:** O SVM em MEL superou os baselines RF e CNN em MEL, apresentando a menor variância entre folds de todo o benchmark ( $\pm 1,14\%$ ).
- **Teto do SVM no LOFAR:** O SVM atingiu 63,83% de SP ( $m = 6000$ ), evidenciando o limite da separação plana e a necessidade de estratégias híbridas para superar o MLP (66,25%).

# Matrizes de Confusão: Nível de Áudio ( $5 \times 2cv$ )

Linhas = classe real — Colunas = predição — Acumulado sobre 10 folds (áudios físicos únicos)

MLP MEL (Baseline)

|        | S    | M    | L    | BG   |
|--------|------|------|------|------|
| SMALL  | 44,8 | 25,4 | 17,9 | 11,8 |
| MEDIUM | 20,4 | 64,0 | 13,1 | 2,5  |
| LARGE  | 12,9 | 15,0 | 68,6 | 3,6  |
| BG     | 6,1  | 3,8  | 5,0  | 85,1 |

MLP LOFAR (Melhor Baseline do Artigo)

|        | S    | M    | L    | BG   |
|--------|------|------|------|------|
| SMALL  | 46,6 | 21,2 | 25,3 | 7,0  |
| MEDIUM | 22,6 | 61,3 | 13,8 | 2,3  |
| LARGE  | 12,8 | 10,0 | 74,7 | 2,5  |
| BG     | 7,3  | 3,8  | 2,6  | 86,3 |

SVM MEL ( $m = 4000$ )

|        | S    | M    | L    | BG   |
|--------|------|------|------|------|
| SMALL  | 50,9 | 24,3 | 17,6 | 7,2  |
| MEDIUM | 26,0 | 60,4 | 12,5 | 1,1  |
| LARGE  | 14,9 | 13,6 | 69,2 | 2,3  |
| BG     | 11,0 | 4,9  | 6,2  | 77,9 |

SVM LOFAR ( $m = 6000$ )

|        | S    | M    | L    | BG   |
|--------|------|------|------|------|
| SMALL  | 38,2 | 22,9 | 28,6 | 10,3 |
| MEDIUM | 17,6 | 60,5 | 17,2 | 4,8  |
| LARGE  | 9,3  | 10,8 | 76,3 | 3,6  |
| BG     | 6,1  | 2,8  | 4,2  | 86,9 |

- ▶ **Alvo Crítico (SMALL):** O SVM MEL obteve maior acerto na classe (50,9%) vs. 46,6% (MLP LOFAR) e 38,2% (SVM LOFAR).
- ▶ **Especialização Espectral:** Modelos LOFAR maximizam acerto em LARGE (74 – 76%), enquanto MEL mitiga confusões com ruído.



# Superando o Gargalo: Especialista em Cascata SMALL vs. LARGE (SL)

**Diagnóstico:** No SVM LOFAR ( $m = 6000$ ), a classe **SMALL** obteve apenas 38,2% de acerto, sendo que 28,6% das amostras de **SMALL** foram preditas erroneamente como **LARGE**.

## 1. Especialista SL (Alta Precisão)

Classificador binário dedicado exclusivamente a distinguir **SMALL** vs. **LARGE**:

- ▶ Treinado para operar com rigor máximo ao confirmar **LARGE**.
- ▶ Filtra o ruído harmônico de barcos rápidos.

## 2. Mecanismo de Resgate em Cascata

1. O **SVM LOFAR 6000** emite predição inicial.
2. Se a predição for **LARGE**, aciona o **Especialista SL**.
3. Se o especialista **não confirmar LARGE**, a predição é revertida para **SMALL**.
4. As demais classes seguem inalteradas.

## Objetivo Operacional

Resgatar dezenas de embarcações pequenas indevidamente absorvidas pela classe majoritária **LARGE**, elevando expressivamente o Recall de **SMALL** e destravando o Índice SP global.



# Evolução dos Classificadores Especialistas SL (SMALL vs. LARGE)

Foram exploradas múltiplas variantes de representação espectral e hiperparâmetros para o Especialista Binário SL:

| Abordagem SL                  | Espaço de Entrada                   | Marcos ( $m$ ) | Precisão LARGE (%)               | Diagnóstico Experimental                      |
|-------------------------------|-------------------------------------|----------------|----------------------------------|-----------------------------------------------|
| SVM MEL Puro                  | MEL (256-D)                         | 4000           | $74,2 \pm 2,5$                   | Boa energia global, mas perde raias do motor  |
| SVM LOFAR Puro                | LOFAR (1024-D)                      | 4000           | $71,8 \pm 3,1$                   | Alta esparsidade; ruído em barcos pequenos    |
| SVM Híbrido (PCA-4)           | MEL-256 + LOFAR-PCA4 (260-D)        | 6000           | $78,5 \pm 2,1$                   | Poucas componentes para capturar o diesel     |
| SVM Híbrido (PCA-16)          | MEL-256 + LOFAR-PCA16 (272-D)       | 6000           | $80,4 \pm 1,9$                   | Leve excesso de variância espectral           |
| <b>Melhor Especialista SL</b> | <b>MEL-256 + LOFAR-PCA8 (264-D)</b> | <b>6000</b>    | <b><math>83,8 \pm 1,4</math></b> | <b>Equilíbrio Ótimo: MEL + LOFAR Compacto</b> |

## Por que o Híbrido com PCA-8 Venceu?


- **Base MEL (256-D):** Fornece a potência e envelope hidrodinâmico.
- **LOFAR-PCA8 (8-D):** Injeta apenas as 8 raias harmônicas de cavitação/diesel mais energéticas.

## Eficiência Computacional

- Vetor compacto (264-D) permite projeção Nyström rápida ( $m = 6000$ ).
- Alta precisão ( $> 83\%$ ) impede falsos alarmes ao confirmar se o navio é realmente LARGE.

Arqu

O especialista binário combina a potência do envelope contínuo com as raias discretas de cavitação:




### 1. Sinergia Espectral (Vetor de 264-D)

**MEL (256-D):** Fornece a energia hidrodinâmica e o envelope global.

**LOFAR-PCA (8-D):** Adiciona as 8 raia harmônicas dominantes do motor diesel.

## 2. Filtragem

O PCA reduz os 1.024 bins esparsos para 8 atributos críticos, descartando ruído e elevando a precisão em LARGE para **83,8%** no SVM Nyström ( $m = 6000$ ).



### SVM LOFAR 6000 (Base)

**ACC Geral: 63,6% — SP: 63,8%**

### Cascata LOFAR 6000 + SL (Proposta)

**ACC Geral: 68,3% — SP: 69,5%**

- **Recall SMALL:** 38,2% → **70,1% (+31,9 p.p.)** — Confusão S→L: 28,6% → **6,4%**
- **Precisão LARGE:** 67,0% → **85,3% (+18,3 p.p.)**
- **SP global:** 63,8% → **69,5% (+5,7 p.p.)** — **ACC geral:** 63,6% → **68,3% (+4,7 p.p.)**

- ## Impacto da Cascata: Contagem Bruta de Áudios



# Efeito Colateral: Impacto do Especialista SL sobre a Classe MEDIUM

Embora o Especialista SL atue **exclusivamente** na distinção SMALL vs. LARGE, ele gerou um efeito colateral na classe MEDIUM:

| Recall por Classe       | SMALL             | MEDIUM    | LARGE     | BG        | Índice SP         |
|-------------------------|-------------------|-----------|-----------|-----------|-------------------|
| SVM LOFAR 6000 (Base)   | 38,2%             | 60,5%     | 76,3%     | 86,9%     | 63,84%            |
| Cascata + SL (Proposta) | 70,1%             | 57,0%     | 66,7%     | 85,9%     | <b>69,48%</b>     |
| <b>Variação</b>         | <b>+31,9 p.p.</b> | -3,5 p.p. | -9,6 p.p. | -1,0 p.p. | <b>+5,64 p.p.</b> |

## Por que MEDIUM caiu se o SL não toca nele?

A cascata atua **janela a janela** (0,512 s). Em um navio MEDIUM, parte das janelas é classificada como LARGE pelo multiclasse. O Especialista SL converte essas janelas para SMALL, inflando os votos de SMALL na **votação majoritária** do áudio e invertendo o resultado final de MEDIUM para SMALL.

## Por que o SP subiu mesmo assim?

O Índice SP usa a **média geométrica** dos recalls. Nessa métrica, o menor termo domina o resultado. Como SMALL era o gargalo (38,2%), ao saltar para 70,1%, o ganho global compensou amplamente as perdas moderadas em MEDIUM e LARGE.



# Robustez ao CPA: Desempenho da Cascata nos Regimes Acústicos

Desempenho particionado por regimes de proximidade e passagem pelo CPA ( $5 \times 2cv$  por áudio):

| Modelo                           | Near CPA (A)         | Far CPA (C)          | CPA IN (A+C)         | CPA OUT (B+D)        | Geral ( $5 \times 2cv$ ) |
|----------------------------------|----------------------|----------------------|----------------------|----------------------|--------------------------|
| MLP LOFAR ( <i>Artigo</i> )      | 59,3% (65,2%)        | 59,6% (63,2%)        | 59,6% (64,5%)        | 42,9% (42,5%)        | 59,4% (58,7%)            |
| CNN MEL ( <i>Artigo</i> )        | 66,8% (70,1%)        | 63,7% (66,7%)        | 65,6% (68,8%)        | 49,0% (48,8%)        | 65,1% (63,8%)            |
| MLP Híbrido ( <i>MEL+LOFAR</i> ) | 63,1% (68,2%)        | 63,0% (67,6%)        | 63,5% (68,0%)        | 52,3% (52,6%)        | 66,2% (64,9%)            |
| SVM LOFAR 6000 ( <i>Base</i> )   | 62,4% (69,3%)        | 56,8% (64,5%)        | 60,5% (67,3%)        | 50,2% (49,6%)        | 63,8% (63,6%)            |
| <b>Cascata LOFAR + SL</b>        | <b>68,9% (70,7%)</b> | <b>67,9% (72,6%)</b> | <b>69,2% (71,6%)</b> | <b>54,5% (57,1%)</b> | <b>69,5% (68,3%)</b>     |

Formato: Índice SP % (Acurácia %)

## Análise de Robustez Espectral:

- ▶ **Grande melhora no Far CPA (C):** No regime de sinal atenuado e baixa SNR, o SP subiu de 56,8% (base) e 59,6% (artigo) para **67,9% (+11,1 p.p.)**, com acurácia de **72,6%**.
- ▶ **Superação no Near CPA (A):** Atingiu **68,9%** de SP, superando inclusive a CNN profunda do artigo (66,8%).
- ▶ **Resiliência no CPA OUT (B+D):** Fora da passagem direta do CPA, alcançou **54,5%** de SP vs. apenas 42,9% do baseline do artigo (+11,6 p.p.).



# Ranking Geral Consolidado de Todos os Modelos

Ordenação decrescente pelo **Índice SP** (avaliação  $5 \times 2cv$  em nível de áudio):

| Pos. | Modelo / Arquitetura                    | Espectro       | Índice SP (%)       | Acurácia (%)        | Categoria / Destaque                         |
|------|-----------------------------------------|----------------|---------------------|---------------------|----------------------------------------------|
| 1º   | <b>SVM em Cascata (LOFAR 6000 + SL)</b> | <b>Híbrido</b> | <b>69,48 ± 2,28</b> | <b>69,93 ± 2,23</b> | <b>Melhor modelo (proposta)</b>              |
| 2º   | <b>MLP [32, 16] LOFAR</b>               | <b>LOFAR</b>   | <b>66,25 ± 1,78</b> | <b>67,21 ± 1,65</b> | <b>Melhor Baseline do Artigo (Benchmark)</b> |
| 3º   | CNN Convolucional LOFAR                 | LOFAR          | 66,05 ± 1,90        | 67,02 ± 1,78        | Deep Learning LOFAR                          |
| 4º   | MLP [32, 16] MEL                        | MEL-256        | 64,66 ± 2,11        | 64,80 ± 2,00        | Baseline Conectado MEL                       |
| 5º   | SVM Nyström LOFAR ( $m = 6000$ )        | LOFAR          | 63,83 ± 1,91        | 65,47 ± 1,77        | Melhor SVM Multiclasse Isolado               |
| 6º   | SVM Nyström MEL ( $m = 4000$ )          | MEL-256        | 63,78 ± 1,14        | 64,56 ± 1,18        | Menor Variância ( $\pm 1,14\%$ )             |
| 7º   | CNN Convolutacional MEL                 | MEL-256        | 63,52 ± 2,26        | 64,99 ± 2,09        | Deep Learning MEL                            |
| 8º   | Random Forest (RF) MEL                  | MEL-256        | 62,22 ± 1,86        | 62,64 ± 1,84        | Ensemble de Árvores MEL                      |
| 9º   | Random Forest (RF) LOFAR                | LOFAR          | 56,92 ± 1,69        | 58,87 ± 1,68        | Ensemble de Árvores LOFAR                    |

## Conclusões Finais do Benchmark:

- **Superação do Benchmark:** O **SVM em Cascata (69,48%)** superou expressivamente o **Melhor Baseline do Artigo (MLP LOFAR: 66,25%)** em **+3,23 p.p.** de SP e **+2,72 p.p.** de acurácia.
- **Resgate Estratégico:** O ganho resultou do resgate de SMALL (38,2% → 70,1%), mantendo a interpretabilidade e baixo custo computacional frente a redes profundas.





# Discussão: Dúvidas e Próximos Passos da Pesquisa

Pontos abertos para discussão e direcionamento das próximas etapas:

## 1. Meta de Desempenho e Artigo

- ▶ Devemos tentar sempre melhorar o SP ou temos outros objetivos?
- ▶ Qual o patamar de SP almejado? (**69,5%** vs. romper **70 – 75%**)
- ▶ Resultados sustentam novo artigo? (superação do artigo seminal, SVM em Cascata e robustez ao CPA).

## 2. Novos Formatos de Entrada

- ▶ Vale a pena estudar entradas além de LOFAR e MEL?
- ▶ **DEMON**: *Demodulation of Envelope*
- ▶ **MFCC**: *Mel-Frequency Cepstral Coefficients*

## 3. Extração e Expansão de Dados

- ▶ Extrair novos recortes dados do IARA?
- ▶ Avaliar *Data Augmentation* acústico?

## 4. Avaliação de Novos Modelos

- ▶ Quais modelos podemos explorar? *Gated Recurrent Unit* (GRU) ? *Bi-GRU*? *LSTM*?



# Obrigado!

Evandro Rocha  
UFRJ / COPPE / PEE