Engenharia Elétrica UFRJ

COPPE UFRJ
Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia

Reconhecimento Acústico de Alvos Submarinos no Dataset IARA

Da Reprodução dos Baselines à Evolução dos Modelos SVM Nyström (MEL e LOFAR)

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ / COPPE / PEE

2026

Agenda da Apresentação

I. Fundamentação e Baselines

1. Contexto e Dataset IARA
2. Representações Espectrais
3. Reprodução dos Baselines

II. Proposta SVM Nyström

4. A Proposta com SVM Nyström
5. Evolução Experimental: SVM em MEL
6. Hiperparâmetros e Limites do SVM

III. Análise e Robustez Operacional

7. Incerteza e Opção de Rejeição
8. Robustez ao CPA
9. Síntese e Matrizes de Confusão

IV. Arquitetura Avançada e Síntese

10. Estratégia de SVM em Cascata
11. Discussão e Próximos Passos

Acervo e Coleções do Dataset IARA (Silva et al., 2025)

O **IARA** reúne 129h 34min de gravações reais na Bacia de Santos (PMPAS-BS / Petrobras):

Plataforma	Coleção	Áudios	CPA	Descrição Acústica
UO	A	456	In	Distância < 250 m (aproximação)
	B	199	Out	Distância < 250 m (afastamento)
	C	341	In	Distância $250 - 500$ m
	D	449	Out	Distância $250 - 500$ m
	E	261	—	Ruído ambiente marítimo puro
Subtotal UO (OS)		**1.706**		**Base oficial dos experimentos**
Gliders	F	35	In	Plataforma móvel (alto-mar)
	G	37	Out	Plataforma móvel (alto-mar)
	H	47	—	Ruído ambiente em águas profundas
Subtotal Gliders		**119**		0 SMALL, 3 MEDIUM (inviável p/ SP)
Total Geral IARA		**1.825**		129h 34min ($\sim$ 50 GB de dados)

Por que Usar Apenas UO (1.706)?

- **Estabilidade Física**: UO é fixo no leito marinho ($\sim$ 2.000 m). Canal acústico constante, sem ruído de propulsão próprio.
- **Inviabilidade dos Gliders**: O Glider não possui gravações de SMALL (0%) e apenas 3 de MEDIUM, zerando matematicamente o Índice SP.

Curadoria Rigorosa

Alvos únicos na zona de exclusão (2 km), validados via AIS com comprimento físico para rotulação precisa.

Protocolo Experimental 5 × 2cv: Treino, Validação e Teste

Como as **1.706 gravações de UO** são particionadas no protocolo oficial (Silva et al., 2025):

A Divisão dos 1.706 Áudios em 3 Conjuntos

Em cada iteração, os 1.706 áudios são divididos em duas metades:

- **50% Treino (853 áudios):** Ajuste dos pesos e parâmetros dos modelos.
- **50% Avaliação (853 áudios):** Fatia de 853 particionada em:
  - **Validação (214 áudios $\approx 12,5\%$ do total):** 25% da avaliação p/ *early stopping* em redes (MLP, CNN).
  - **Teste Final (639 áudios $\approx 37,5\%$ do total):** 75% da avaliação p/ avaliação cega oficial.

Balanço Amostral por Fold

$$\underbrace{853}_{\text{Treino (50\%)}} + \underbrace{214}_{\text{Val (12,5\%)}} + \underbrace{\mathbf{639}}_{\textbf{Teste (37,5\%)}} = \mathbf{1.706}\ \text{UO (100\%)}$$

Protocolo 5 × 2cv (10 Folds de Teste)

- **Divisão por gravação** (ID, como no artigo), **não** por navio: 63,5% das gravações de navio no teste têm o mesmo *Ship ID* no treino.
- **Volume de Teste**: 639×10 folds $=$ **6.390** avaliações de 1.706 áudios distintos (cada um em 1 a 5 folds; média 3,75).

Distribuição das Classes na Partição de Teste (639 Áudios)

Em cada um dos 10 folds, o conjunto de teste avaliado é composto por 639 gravações de UO, apresentando desbalanceamento natural entre categorias:

Classe Acústica	Porte Físico	Áudios no Teste / Fold	Proporção (%)	Testes (5×2cv)	Assinatura Predominante
SMALL	< 50 m	178	27,9%	1.780	Lanchas, botes (baixa SNR, motores rápidos)
MEDIUM	$50 - 100$ m	149	23,3%	1.490	Rebocadores, barcos de apoio e pesca
LARGE	> 100 m	214	**33,5%**	2.140	Petroleiros, cargueiros (raias puras, cavitação)
BACKGROUND	Sem alvos	98	**15,3%**	980	Ruído ambiente marítimo natural
Total	—	**639**	**100,0%**	**6.390**	$\approx 45,7$ h de gravação de teste por fold

Impacto do Desbalanceamento no Treinamento

- A classe **LARGE** representa um terço do teste (33,5%), enquanto **BACKGROUND** corresponde a apenas 15,3%.
- Devido à disparidade energética e amostral, modelos ingênuos tendem a negligenciar classes minoritárias, justificando o uso mandatório do **Índice SP** como métrica de avaliação.

Métrica Oficial de Avaliação: Índice SP

Para mitigar o desbalanceamento das classes, adota-se o **Índice SP** como métrica primária:

Índice SP (Média Geométrica dos Recalls por Classe)

$$\mathrm{SP} = \sqrt[4]{R_{\mathrm{SMALL}} \cdot R_{\mathrm{MEDIUM}} \cdot R_{\mathrm{LARGE}} \cdot R_{\mathrm{BACKGROUND}}} \times 100\%$$

Propriedades Críticas do Índice SP:

- **Penalização Severa de Zeros:** Se qualquer uma das 4 classes apresentar $\mathrm{Recall}_k = 0\%$, o índice zera instantaneamente ($\mathrm{SP} = 0\%$).
- **Robustez contra Vieses:** Diferentemente da acurácia global (que pode ser inflada pela classe majoritária *LARGE*), o SP avalia o equilíbrio real e só é alto se houver acerto consistente em todas as categorias.
- **Exigência Operacional:** Garante que embarcações pequenas (*SMALL*) e ruído (*BACKGROUND*) não sejam negligenciados.

Representações Espectrais: Vetores de Entrada dos Modelos

O áudio contínuo é fatiado em janelas de $0,512$ s e convertido em vetores numéricos para alimentar os classificadores:

1. Espectro LOFAR (1024 Atributos)

- **Vetor de Entrada: 1024** valores.
- **O que mede:** Energia sonora em frequências finas e lineares (tons puros e harmônicos periódicos).
- **Papel no Modelo:** Máxima riqueza e resolução detalhada em frequência.

2. Espectro MEL (256 Atributos)

- **Vetor de Entrada: 256** valores.
- **O que mede:** Energia agrupada em faixas perceptuais (timbre, envelope sonoro e ruídos contínuos).
- **Papel no Modelo:** Representação compacta e suave, resistente a variações espúrias.

Como Alimentam os Modelos?

Cada janela acústica gera um vetor (1024 ou 256 dimensões) processado individualmente por modelos tabulares (MLP, SVM, RF) ou empilhado temporalmente para redes profundas (CNN, CRNN).

Reprodução Local dos Baselines do Artigo (Silva et al., 2025)

Antes da proposição de novas abordagens, foi replicado com rigor o pipeline do artigo nos 10 folds (5×2cv):

Classificador	Espectro	Índice SP (%) (Artigo)	Índice SP (%) (Local)	Diferença
Random Forest (RF)	MEL	$62,22 \pm 1,86$	n/d*	—
Random Forest (RF)	LOFAR	$56,92 \pm 1,69$	n/d*	—
MLP [32, 16]	MEL	$63,38 \pm 1,81$	$64,74 \pm 2,05$	$+1,36$ p.p.
MLP [32, 16]	**LOFAR**	$\mathbf{66,51 \pm 1,39}$	$\mathbf{66,24 \pm 1,78}$	$\mathbf{-0,27}$ p.p.
CNN Convolucional	MEL	$63,52 \pm 2,26$	$63,80 \pm 2,23$	$+0,28$ p.p.
CNN Convolucional	LOFAR	$66,05 \pm 1,90$	n/d*	—

Coluna "Artigo" = Tabela 7 de Silva et al. (2025). Local = pipeline iara oficial (`mlp`, `mlp_lofar`, `cnn`), mesmos 10 folds; média $\pm$ desvio (ddof=0). *RF e CNN LOFAR não foram re-executados no pipeline oficial (janelas de 0,512 s). As versões ad hoc existentes usam cache de 5,12 s e não são comparáveis (RF MEL 61,50; RF LOFAR 63,07; CNN 2D LOFAR 35,40 $\pm$ 12,38, colapsada).

Conclusão da Reprodução

MLP MEL, MLP LOFAR e CNN MEL reproduzidos com diferença $\leq 1,36$ p.p. de SP ($\sim$1 desvio). O **MLP LOFAR (**$66,51\%$ **artigo /** $66,24\%$ **local)** é o benchmark; os F-tests 5×2cv a seguir usam a re-execução local (o artigo não publica valores por fold).

Motivação: O SVM em Sonar Passivo

Método Clássico em UATR

O SVM foi historicamente um dos primeiros métodos aplicados em UATR e continua sendo empregado como baseline de referência em trabalhos recentes (e.g., Xu et al., reportando 69,24% no **DeepShip**). Contudo, os datasets da literatura são de pequeno a médio porte (**ShipsEar**: 3h; **DeepShip**: 47h); a avaliação em bases de grande escala como o IARA ($\approx$ 130h; $\approx$ 122h no UO) permanecia em aberto.

Lacuna na Literatura:

- **Dados Limitados**: Validações anteriores restritas a bases pequenas e poucos trânsitos.
- **Custo Computacional**: Crescimento de memória e tempo $O(N^2)/O(N^3)$ inviabilizava testes massivos.

A Fronteira do Dataset IARA:

- **Base de Grande Escala**: O IARA é uma das maiores bases públicas mundiais (tráfego real).
- **Objetivo do Estudo**: Investigar a capacidade e o limite do SVM sob este patamar de complexidade.

SVM com Aproximação de Nyström

O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- **Volume de Amostras (N no IARA)**: N é o número de janelas espectrais de treinamento — MEL e LOFAR usam a mesma janela ($0,512$s): $\approx$ 200k janelas por fold (200.368 a 200.394 nos CSVs de treino).
- **Custo do RBF Clássico**: A matriz Gram $N \times N$ exigiria $\approx$ 160 GB (float32) ou $\approx$ 320 GB (float64) de RAM (inviável).

- **Aproximação de Nyström (Baixo Rank)**: Selecionam-se m amostras de referência (*landmarks*) para projetar o kernel no espaço linear explícito $\mathbb{R}^m$.
- **Base Projetada de Treinamento ($N \times m$)**:
  - $m = 4000$: 200k $\times$ 4000 $\times$ 4B $\approx$ **3, 2** GB de RAM (MEL ou LOFAR).
  - $m = 6000$: 200k $\times$ 6000 $\times$ 4B $\approx$ **4, 8** GB de RAM.
- **Complexidade Linear**: Reduz o treinamento para $O(N \cdot m^2)$, resolvido eficientemente via SGD.
- **Tamanho do Modelo Final**: pesos lineares ($4 \times m$ coeficientes) mais os m *landmarks* e o mapa de Nyström; o arquivo salvo por fold tem $\approx$ **68** MB (MEL, $m = 4000$) e $\approx$ **169** MB (LOFAR, $m = 6000$).

Evolução do SVM com Espectrograma MEL (Banda Larga)

Foi investigada a progressão da capacidade do SVM variando-se o número de componentes m de Nyström e a regularização:

Configuração SVM MEL	Componentes m	Índice SP (%)	Acurácia Bal. (%)	Observação
SVM MEL (m=300, C=1, L2)	300	$59,96 \pm 3,38$	$62,34 \pm 1,98$	Maior desvio entre folds
SVM MEL (m=1000, C=1, L2)	1000	$62,96 \pm 2,08$	$64,11 \pm 1,98$	$p = 0,34$ vs. $m = 300$
SVM MEL (m=2000, C=1, L2)	2000	$63,04 \pm 2,37$	$64,45 \pm 1,93$	$p = 0,81$ vs. $m = 1000$
SVM MEL (m=3000, C=1, L2)	3000	$63,65 \pm 1,99$	$64,77 \pm 1,87$	$p = 0,61$ vs. $m = 2000$
SVM MEL adotado ($m = 4000$)	**4000**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**ElasticNet, C=2.0** ($p = 0,70$ vs. $m = 3000$)
SVM MEL (m=4000, C=0.5)	4000	$63,48 \pm 1,50$	$64,90 \pm 1,23$	Equivalente ao C=2.0 ($p = 0,66$)

p = F-test 5 × 2cv sobre o SP por fold (como no artigo). Acurácia Bal. = média dos recalls por classe.

Destaque Experimental no MEL

A média do SP cresce de $m = 300$ a $m = 4000$, mas nenhum passo é estatisticamente significativo. O **SVM MEL ($m = 4000$)** alcançou $\mathbf{63,78 \pm 1,14}$% de SP, **equivalente** à CNN MEL (local $63,80 \pm 2,23$, $p = 0,27$; artigo $63,52$) e ao MLP MEL (local $64,74$, $p = 0,64$), com o **menor desvio de SP entre folds** dos modelos comparados ($\pm 1,14$; artigo: $\geq 1,39$).

Exploração de Hiperparâmetros e Limite de Desempenho do SVM

Foi realizada uma busca de hiperparâmetros (C, penalização ElasticNet ρ e componentes m), avaliada nos mesmos folds de teste:

Espectro	Configuração Avaliada	Comp. m	Reg. C	Índice SP (%)	Acur. Bal. (%)	Diagnóstico Experimental
LOFAR	SVM LOFAR (m=1000)	1000	1,0	$57,86 \pm 3,83$	$60,95 \pm 2,89$	Maior desvio; recall SMALL 27,4%
LOFAR	SVM LOFAR (m=2000, C=0.1)	2000	0,1	$54,84 \pm 1,60$	$59,67 \pm 1,28$	Menor SP; recall SMALL 18,0%
LOFAR	SVM LOFAR (m=4000, C=0.5, E-Net)	4000	0,5	$60,66 \pm 2,78$	$63,23 \pm 2,05$	Recall SMALL 31,2%; $p = 0,17$ vs. $m = 6000$
LOFAR	**SVM LOFAR (m=6000, C=1.0, E-Net)**	**6000**	**1,0**	$\mathbf{63,83 \pm 1,91}$	$\mathbf{65,47 \pm 1,77}$	**Melhor SVM LOFAR testado**
MEL	SVM MEL (m=4000, C=0.5, E-Net)	4000	0,5	$63,48 \pm 1,50$	$64,90 \pm 1,23$	Equivalente ao C=2.0 ($p = 0,66$); recall SMALL 38,5%
MEL	SVM MEL (m=2000, C=10.0, Puro)	2000	10,0	$62,18 \pm 3,14$	$63,53 \pm 2,50$	Desvio alto entre folds ($\pm 3,14$)
MEL	**Melhor SVM MEL (m=4000, C=2.0)**	**4000**	**2,0**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**Melhor SP MEL (menor desvio)**

Comparação dos Melhores SVM Nyström:

- **LOFAR** $m = 6000$ **($\mathbf{63,83}$%):** melhor média no LOFAR (1024-D), mas equivalente a $m = 4000$, C=0,5 ($p = 0,17$).
- **MEL** $m = 4000$ **($\mathbf{63,78}$%):** 256 filtros; menor desvio entre folds ($\pm 1,14$%). LOFAR 6000 e MEL 4000 são equivalentes ($p = 0,10$).

Conclusão: Limite Observado

Com $m = 6000$, o SVM LOFAR ficou em **$\mathbf{63,83}$%** de SP, abaixo em média do MLP LOFAR local ($66,24$%), mas a diferença **não é significativa** ($p = 0,15$). O gargalo visível é o recall de SMALL ($38,2$%); atribuí-lo à separação linear no espaço de Nyström é hipótese, não testada.

Análise de Incerteza e Opção de Rejeição (Tabela 9 do Artigo)

Foi replicado o experimento de opção de rejeição (**Tabela 9 do artigo**), avaliando-se o trade-off entre cobertura operacional e acurácia sob limiares de concordância temporal de janelas (t):

Modelo	$t = 0$ (100% Cobertura)		$t \geq 0,6$ (Maioria Absoluta)		$t \geq 0,9$ (Alto Consenso)	
	Cobertura	Acur. Bal.	Cobertura	Acur. Bal.	Cobertura	Acur. Bal.
SVM MEL ($m = 4000$)	100%	64,6%	76,1%	69,2%	37,5%	77,1%
SVM LOFAR ($m = 6000$)	100%	65,5%	65,8%	72,6%	31,8%	80,6%
MLP MEL (local)	100%	65,7%	70,4%	71,3%	32,9%	75,8%
MLP LOFAR (local)	100%	**67,2%**	61,0%	**76,0%**	24,8%	**81,2%**
CNN MEL (local)	100%	65,0%	**82,9%**	68,2%	**54,0%**	72,0% [Alerta]

Concordância = fração das janelas do áudio que votaram na classe vencedora; acurácia balanceada calculada só nos áudios aceitos (média dos 10 folds). Valores locais; a Tabela 9 do artigo usa outro ponto de operação (razão ótima por modelo, MEL).

Destaques do Comportamento Observado:

- **MEL:** maior cobertura em $t \geq 0,6$ entre os modelos de janela (SVM MEL 76,1%).
- **LOFAR:** maior acurácia balanceada sob alto consenso (80,6–81,2%), mas aceitando só 25–32% dos áudios.
- **CNN [Alerta]:** com apenas 7 segmentos por áudio, a concordância é discreta; mantém 54% de cobertura em $t \geq 0,9$ com a menor acurácia (72,0%).
- Comparações entre modelos devem ser feitas a cobertura semelhante, não ao mesmo t.

Robustez ao CPA e Variação de Distância (Tabela 10 do Artigo)

Foi avaliada a capacidade de generalização diante da distância física da embarcação ao hidrofone (reprodução da Tabela 10 do artigo):

Treinado em	Avaliado em	MLP MEL (artigo)	MLP MEL (local)	SVM LOFAR (local)	p
Near CPA (A)	Near CPA (A)	$67,25 \pm 2,44$	$67,33 \pm 2,67$	$67,24 \pm 3,42$	0,63
Near CPA (A)	Far CPA (C)	$59,08 \pm 6,51$	$60,16 \pm 5,99$	$55,35 \pm 4,45$	0,11
Far CPA (C)	Far CPA (C)	$58,08 \pm 3,70$	$59,46 \pm 4,45$	$55,84 \pm 6,00$	0,36
Far CPA (C)	Near CPA (A)	$59,59 \pm 5,22$	$59,36 \pm 4,55$	$58,52 \pm 4,95$	0,69

Índice SP (%). "Artigo" = Tabela 10 de Silva et al. (2025). Local = re-execução 5×2cv (`results/trainings/cpa_exp`); SVM LOFAR $m = 4000$, C=2, PCA64. p = F-test 5×2cv, SVM LOFAR vs. MLP MEL local. Não há experimento CPA com MLP LOFAR.

Conclusões de Robustez ao CPA

- **Near CPA (A):** Alta SNR. **Far CPA (C):** Baixa SNR, forte atenuação.
- O **SVM LOFAR** é **equivalente** ao MLP MEL em todos os cenários ($p \geq 0,11$) e não o supera: em A→A as médias empatam e, ao transferir A→C, o SVM LOFAR tem a maior queda de SP ($-11,9$ p.p. vs. $-7,2$ p.p. do MLP).
- A MLP local reproduz a Tabela 10 do artigo (diferenças $\leq 1,4$ p.p.).

Síntese dos Resultados Obtidos nesta Etapa

Modelo	Representação	Índice SP (%)	Acur. Bal. (%)	Destaque Técnico
RF (Artigo)	MEL	$62,22 \pm 1,86$	$62,64 \pm 1,84$	Baseline Árvores
CNN (Artigo)	MEL	$63,52 \pm 2,26$	$64,99 \pm 2,09$	Convolucional Profundo
SVM MEL (local)	**MEL (m=4000)**	$\mathbf{63,78 \pm 1,14}$	$\mathbf{64,56 \pm 1,18}$	**Menor desvio** ($\pm 1,14\%$)
RF (Artigo)	LOFAR	$56,92 \pm 1,69$	$58,87 \pm 1,68$	Degradação no LOFAR
CNN (Artigo)	LOFAR	$66,05 \pm 1,90$	$67,02 \pm 1,78$	Convolucional LOFAR
MLP (Artigo)	LOFAR	$66,51 \pm 1,39$	$67,48 \pm 1,24$	Melhor Baseline do Artigo
MLP Local	LOFAR	$66,24 \pm 1,78$	$67,22 \pm 1,65$	Re-execução local (referência do F-test)
SVM LOFAR (local)	**LOFAR (m=6000)**	$\mathbf{63,83 \pm 1,91}$	$\mathbf{65,47 \pm 1,77}$	**Melhor índice SP no SVM**

Aspectos dos Resultados Apresentados:

- **Consistência do MEL:** O SVM em MEL é equivalente à CNN MEL (local $63,80\%$, $p = 0,27$) e tem média acima do RF MEL do artigo ($62,22\%$; sem teste pareado possível), com o menor desvio entre folds da tabela ($\pm 1,14\%$).
- **SVM no LOFAR:** O SVM atingiu $63,83\%$ de SP ($m = 6000$), abaixo em média do MLP LOFAR (local $66,24\%$; artigo $66,51\%$), sem diferença significativa frente ao MLP local ($p = 0,15$). O recall de SMALL ($38,2\%$) motivou a estratégia em cascata.

Matrizes de Confusão: Nível de Áudio (5×2cv)

Linhas = classe real — Colunas = predição (%) — Acumulado sobre 10 folds (6.390 avaliações de 1.706 áudios distintos)

MLP MEL (Baseline)

	S	M	L	BG
SMALL	44,8	25,5	17,9	11,8
MEDIUM	20,3	**64,1**	13,2	2,5
LARGE	12,7	14,9	**68,8**	3,6
BG	6,0	3,8	5,0	**85,2**

SVM MEL ($m = 4000$)

	S	M	L	BG
SMALL	50,7	24,3	17,7	7,3
MEDIUM	26,0	**60,4**	12,5	1,1
LARGE	14,8	13,6	**69,3**	2,4
BG	11,0	4,9	6,2	**77,9**

MLP LOFAR (re-execução local do melhor baseline do artigo)

	S	M	L	BG
SMALL	46,3	21,2	25,4	7,0
MEDIUM	22,3	**61,5**	13,8	2,3
LARGE	12,7	10,0	**74,7**	2,6
BG	7,3	3,8	2,6	**86,3**

SVM LOFAR ($m = 6000$)

	S	M	L	BG
SMALL	38,1	22,8	28,7	10,4
MEDIUM	17,6	**60,4**	17,2	4,8
LARGE	9,2	10,9	**76,3**	3,6
BG	6,1	2,8	4,1	**87,0**

- **Alvo Crítico (SMALL):** O **SVM MEL** obteve maior acerto na classe (50, 7%) vs. 46, 3% (MLP LOFAR) e 38, 1% (SVM LOFAR).
- **Especialização Espectral:** Modelos LOFAR maximizam acerto em LARGE (74, 7–76, 3%) e BACKGROUND (86, 3–87, 0%); o SVM MEL tem o menor acerto em BACKGROUND (77, 9%).

Atacando o Gargalo: Especialista em Cascata SMALL vs. LARGE (SL)

Diagnóstico: No SVM LOFAR ($m = 6000$), a classe **SMALL** obteve apenas $38,1\%$ de acerto (acumulado nos 10 folds), sendo que $28,7\%$ **dos áudios SMALL foram preditos erroneamente como LARGE**.

1. Especialista SL (Alta Precisão)

Classificador binário dedicado exclusivamente a distinguir **SMALL vs. LARGE**:

- Treinado só com SMALL e LARGE (MEL-256 + LOFAR-PCA8, $m = 6000$), nas partições do modelo de 4 classes.

2. Mecanismo de Resgate em Cascata

1. O **SVM LOFAR 6000** emite predição inicial.
2. Se a predição for **LARGE**, aciona o **Especialista SL**.
3. Se o especialista **não confirmar LARGE**, a predição é revertida para **SMALL**.
4. As demais classes seguem inalteradas.

Objetivo Operacional

Resgatar embarcações pequenas absorvidas pela classe LARGE, elevando o Recall de SMALL e o SP. **Nota:** o SL original (jun/2026) tinha no treino $49,1\%$ (1.925/3.920) dos áudios SMALL/LARGE de teste; foi retreinado em 20/10/2026 (0/3.920) e todas as cascatas foram re-executadas (o SP anterior de $69,48\%$ não é válido).

Evolução dos Classificadores Especialistas SL (SMALL vs. LARGE)

Variantes híbridas do Especialista Binário SL (métricas por áudio na tarefa SMALL vs. LARGE, média $\pm$ desvio nos 10 folds):

Abordagem SL	Espaço de Entrada	Marcos (m)	Precisão LARGE (%)	Acur. Bal. (%)	Observação
SVM Híbrido (PCA-4)	MEL-256 + LOFAR-PCA4 (260-D)	6000	$77,6 \pm 4,2$	$74,6 \pm 1,9$	Partição antiga (jun/2026)
SVM Híbrido (PCA-16)	MEL-256 + LOFAR-PCA16 (272-D)	6000	$77,3 \pm 3,3$	$75,0 \pm 1,8$	Partição antiga (jun/2026)
SVM Híbrido (PCA-64)	MEL-256 + LOFAR-PCA64 (320-D)	6000	$77,0 \pm 3,9$	$75,0 \pm 2,1$	Partição antiga (jun/2026)
Especialista SL adotado	**MEL-256 + LOFAR-PCA8 (264-D)**	**6000**	$\mathbf{78,4 \pm 4,1}$	$\mathbf{75,8 \pm 2,2}$	**Retreinado (20/10/2026)**

As variantes PCA-4/16/64 usam a partição antiga do especialista (válida para a tarefa binária, mas com vazamento em relação ao teste do modelo de 4 classes) e não são pareadas com o PCA-8 retreinado. Não foram encontrados em disco especialistas SL "MEL puro" ou "LOFAR puro" (removidos da tabela).

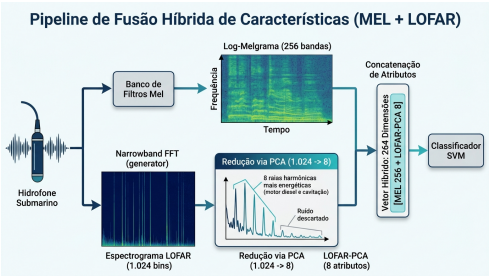
PCA-8: escolha, não vitória

- As variantes diferem em $\leq 1,4$ p.p. de precisão LARGE, dentro do desvio entre folds (3–4 p.p.).
- **LOFAR-PCA8 (8-D):** as 8 componentes principais do LOFAR (máxima variância), não raias harmônicas específicas.

Eficiência Computacional

- Vetor compacto (264-D) permite projeção Nyström rápida ($m = 6000$).
- Precisão LARGE de $\approx 78\%$: cerca de 1 em cada 5 áudios confirmados como LARGE é, na verdade, SMALL.

Arquitetura do Especialista SL: Fusão Híbrida (MEL-256 + LOFAR-PCA8)



1. Fusão de Características (264-D)

- **Vetor Combinado:** Concatenação direta de **MEL (256-D)** com **LOFAR-PCA (8-D)**.
- **Papel do PCA-8:** Comprime o LOFAR de 1.024 para as 8 componentes de maior variância (efeito sobre o sobreajuste não testado).

2. Roteamento em Cascata

- **Acionamento:** só se o modelo base prediz **LARGE** (janela a janela).
- **Resgate:** se não confirmar LARGE, vira **SMALL**: 293 SMALL resgatados de LARGE (10 folds), mas 146 MEDIUM corretos viraram SMALL.

Impacto da Cascata: Matrizes de Confusão (%)

Linhas = classe real — Colunas = predição — Avaliação por áudio (5×2cv, 10 folds acumulados; especialista SL retreinado)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Rec.
SMALL	38,1	22,8	28,7	10,4	38,1%
MEDIUM	17,6	**60,4**	17,2	4,8	60,4%
LARGE	9,2	10,9	**76,3**	3,6	76,3%
BG	6,1	2,8	4,1	**87,0**	87,0%
Prec.	56,7%	57,5%	66,9%	71,9%	

ACC micro 63,6% — **bal.** 65,5% — **SP** 63,8%

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Rec.
SMALL	**63,7**	15,7	**11,5**	9,1	**63,7%**
MEDIUM	30,3	57,7	7,9	4,2	57,7%
LARGE	23,5	9,4	63,5	3,6	63,5%
BG	9,9	2,0	2,3	**85,7**	85,7%
Prec.	51,9%	63,1%	**79,8%**	73,6%	

ACC micro 65,6% — **bal.** 67,6% — **SP** 67,2%

Principais Mudanças:

- **Recall SMALL:** 38,1% → **63,7%** (**+25,5 p.p.**) — Confusão S→L: 28,7% → **11,5%** — **Recall LARGE:** 76,3% → 63,5% (−12,8 p.p.)
- **Precisão LARGE:** 66,9% → **79,8%** (**+12,9 p.p.**)
- **SP global:** 63,8% → **67,2%** (**+3,3 p.p.**; F-test 5×2cv $p = 0,007$ vs. base) — **ACC micro:** 63,6% → 65,6% (+2,0 p.p.)

Impacto da Cascata: Contagem Bruta de Áudios

Número absoluto de avaliações por áudio (10 folds acumulados, 6.390 testes no total)

SVM LOFAR 6000 (Base)

	S	M	L	BG	Total
SMALL	679	405	511	185	1.780
MEDIUM	262	**900**	257	71	1.490
LARGE	197	233	**1.633**	77	2.140
BG	60	27	40	**853**	980

Corretos: 4.065/6.390
ACC micro: 63, 6% — **SP:** 63, 8%

Cascata LOFAR 6000 + SL (Proposta)

	S	M	L	BG	Total
SMALL	**1.133**	280	**205**	162	1.780
MEDIUM	452	859	117	62	1.490
LARGE	502	202	1.359	77	2.140
BG	97	20	23	**840**	980

Corretos: **4.191**/6.390 (**+126**)
ACC micro: 65, 6% — **SP:** 67, 2%

Ganhos e Perdas em Números Absolutos:

- **Resgate de SMALL:** De 679 para **1.133** corretos (**+454**), com confusão S→L caindo de 511 para **205**.
- **LARGE:** De 1.633 para 1.359 corretos (−**274**); L→S sobe de 197 para 502. **MEDIUM:** De 900 para 859 (−41) — efeito colateral da reclassificação janela a janela. **BG:** −13.
- **Saldo total:** **+126** avaliações corretas (de 6.390). Cada áudio aparece em média em 3,75 folds de teste; as contagens não são áudios únicos.

Efeito Colateral: Impacto do Especialista SL sobre MEDIUM e LARGE

Embora o Especialista SL atue **exclusivamente** na distinção SMALL vs. LARGE, ele gerou efeitos colaterais em MEDIUM e, sobretudo, em LARGE:

Recall por Classe (média 10 folds)	SMALL	MEDIUM	LARGE	BG	Índice SP
SVM LOFAR 6000 (Base)	$38,15\%$	$60,40\%$	$76,31\%$	$87,04\%$	$63,83 \pm 1,91\%$
Cascata + SL (Proposta)	$63,65\%$	$57,65\%$	$63,50\%$	$85,71\%$	$\mathbf{67,16 \pm 1,82}\%$
Variação	**+25,51 p.p.**	$-2,75$ p.p.	$-12,80$ p.p.	$-1,33$ p.p.	**+3,33 p.p.** ($p = 0,007$)

Por que MEDIUM caiu se o SL não toca nele?

A cascata atua **janela a janela** ($0,512$ s). Em um navio MEDIUM, parte das janelas é classificada como LARGE pelo multiclasse. O Especialista SL converte essas janelas para SMALL, inflando os votos de SMALL na **votação majoritária** do áudio e invertendo o resultado final de MEDIUM para SMALL (146 avaliações MEDIUM corretas passaram a SMALL). Pelo mesmo mecanismo, 502 avaliações LARGE terminam como SMALL (eram 197).

Por que o SP subiu mesmo assim?

O Índice SP combina média aritmética e **média geométrica** dos recalls, que penaliza o menor termo. Como SMALL era o gargalo ($38,15\%$), o salto para $63,65\%$ compensou as perdas em MEDIUM ($-2,75$) e LARGE ($-12,80$ p.p.).

Robustez ao CPA: Desempenho da Cascata nos Regimes Acústicos

Desempenho por coleção do áudio de teste (modelos de 4 classes; re-execuções locais, 5×2cv):

Modelo	Near CPA (A)	Far CPA (C)	CPA IN (A+C)	CPA OUT (B+D)	Geral (5×2cv)
MLP LOFAR *(local)*	67,0% (68,1%)	59,7% (61,2%)	64,2% (65,3%)	52,3% (52,6%)	66,2% (67,2%)
MLP MEL *(local)*	62,6% (64,0%)	61,0% (62,6%)	62,3% (63,6%)	50,1% (50,6%)	64,7% (65,7%)
CNN MEL *(local)*	60,2% (61,9%)	58,4% (60,0%)	59,9% (61,3%)	48,3% (48,9%)	63,8% (65,0%)
MLP Híbrido *(MEL+LOFAR-PCA64)*	63,1% (64,6%)	63,0% (64,0%)	63,6% (64,6%)	52,2% (52,5%)	66,1% (66,9%)
SVM LOFAR 6000 *(Base)*	62,3% (64,2%)	56,8% (59,0%)	60,4% (62,2%)	50,2% (50,8%)	63,8% (65,5%)
Cascata LOFAR + SL (janela)	65,3% (65,8%)	**64,4% (65,4%)**	**65,6% (66,0%)**	51,7% (52,6%)	**67,2% (67,6%)**
Cascata LOFAR + SL (arquivo)	64,6% (65,3%)	61,9% (63,2%)	64,0% (64,6%)	51,0% (51,4%)	66,0% (66,8%)
p cascata (janela) vs. MLP LOFAR	0,71	0,056	0,65	0,40	0,56

Formato: SP % (Acurácia Balanceada %). Coleções A–D têm só navios (SP sobre 3 classes); BACKGROUND (E) entra só em "Geral".

Análise de Robustez Espectral:

- **Melhora no Far CPA (C):** o SP subiu de 56,8% (base) para **64,4%** (+7,6 p.p., $p = 0,003$). Frente ao MLP LOFAR (59,7%) a diferença (+4,7 p.p.) não é significativa ($p = 0,056$), e o MLP Híbrido chega a 63,0% ($p = 0,39$).
- **Near CPA (A):** a cascata (65,3%) fica **abaixo** em média do MLP LOFAR (67,0%; $p = 0,71$).
- **CPA OUT (B+D):** todos os modelos caem para 48–52%; a cascata (51,7%) é equivalente ao MLP LOFAR (52,3%; $p = 0,40$).

Ranking Geral Consolidado de Todos os Modelos

Ordem decrescente da média do **Índice SP** (5 × 2cv por áudio); p = F-test 5 × 2cv vs. MLP LOFAR local:

Pos.	Modelo / Arquitetura	Espectro	Índice SP (%)	Acur. Bal. (%)	p	Fonte / Destaque
1°	**SVM em Cascata por janela (LOFAR 6000 + SL)**	Híbrido	$\mathbf{67,16 \pm 1,82}$	$67,63 \pm 1,87$	0,56	Local; $p = 0,007$ vs. SVM base
2°	**MLP [32, 16] LOFAR**	LOFAR	$\mathbf{66,51 \pm 1,39}$	$\mathbf{67,48 \pm 1,24}$	—	Artigo (Tabela 7): benchmark
3°	MLP [32, 16] LOFAR	LOFAR	$66,24 \pm 1,78$	$67,22 \pm 1,65$	ref.	Local (re-execução)
4°	MLP Híbrido (MEL + LOFAR-PCA64)	Híbrido	$66,13 \pm 1,09$	$66,92 \pm 1,06$	0,67	Local
5°	CNN Convolucional LOFAR	LOFAR	$66,05 \pm 1,90$	$67,02 \pm 1,78$	—	Artigo (Tabela 7)
6°	SVM em Cascata por arquivo (LOFAR 6000 + SL)	Híbrido	$66,00 \pm 1,90$	$66,77 \pm 1,92$	0,37	Local; $p = 0,030$ vs. SVM base
7°	MLP [32, 16] MEL	MEL-256	$64,74 \pm 2,05$	$65,73 \pm 1,90$	0,65	Local (artigo: 63, 38)
8°	SVM Nyström LOFAR ($m = 6000$)	LOFAR	$63,83 \pm 1,91$	$65,47 \pm 1,77$	0,15	Local; melhor SVM isolado
9°	CNN Convolucional MEL	MEL-256	$63,80 \pm 2,23$	$65,01 \pm 2,05$	0,22	Local (artigo: 63, 52)
10°	SVM Nyström MEL ($m = 4000$)	MEL-256	$63,78 \pm 1,14$	$64,56 \pm 1,18$	0,27	Local; menor desvio
11°	Random Forest (RF) MEL	MEL-256	$62,22 \pm 1,86$	$62,64 \pm 1,84$	—	Artigo (Tabela 7)
12°	Random Forest (RF) LOFAR	LOFAR	$56,92 \pm 1,69$	$58,87 \pm 1,68$	—	Artigo (Tabela 7)

Conclusões Finais do Benchmark:

- **Sem superação estatística do benchmark:** a melhor cascata ($67,16 \pm 1,82\%$) é **equivalente** ao MLP LOFAR local ($66,24\%$; $p = 0,56$) e fica $+0,65$ p.p. acima do MLP LOFAR do artigo ($66,51 \pm 1,39\%$), dentro do desvio. Nenhum modelo local difere significativamente do MLP LOFAR.
- **Ganho real sobre o próprio SVM:** a cascata melhora o SVM LOFAR base ($63,83 \rightarrow 67,16\%$, $p = 0,007$) ao resgatar SMALL ($38,15 \rightarrow 63,65\%$), à custa de LARGE ($76,31 \rightarrow 63,50\%$).

Discussão: Dúvidas e Próximos Passos da Pesquisa

Pontos abertos para discussão e direcionamento das próximas etapas:

1. Meta de Desempenho e Artigo

- Devemos tentar sempre melhorar o SP ou temos outros objetivos?
- Qual o patamar de SP almejado? (hoje $\mathbf{67,2\%}$, equivalente ao MLP LOFAR)
- Resultados sustentam novo artigo? (sem superação estatística do artigo; ganho significativo só sobre o SVM base).

2. Novos Formatos de Entrada

- Vale a pena estudar entradas além de LOFAR e MEL?
- **DEMON**: *Demodulation of Envelope*
- **MFCC**: *Mel-Frequency Cepstral Coefficients*

3. Extração e Expansão de Dados

- Extrair novos recortes dados do IARA?
- Avaliar *Data Augmentation* acústico?

4. Avaliação de Novos Modelos

- Quais modelos podemos explorar? *Gated Recurrent Unit* (GRU) ? *Bi-GRU*? *LSTM*?



Obrigado!

Evandro Rocha
UFRJ / COPPE / PEE