



Classificação Acústica Submarina Passiva em Datasets de Grande Porte

Estudo de Caso no Dataset IARA com SVM

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ/COPPE/PEE

Junho de 2026



Agenda

1. Introdução e Contexto (Dataset IARA)
2. Representação Espectral, Baseline e Avaliação
3. Método Proposto
4. Trajetória de Escalonamento
5. Resultados Gerais de Desempenho
6. Conclusões e Trabalhos Futuros



Introdução e Contexto



Classificação Acústica Submarina (UATR)

Desafio de Sonar Passivo

Identificar embarcações baseando-se unicamente nas suas assinaturas acústicas irradiadas através da água. Uma tarefa altamente crítica para monitoramento de tráfego, soberania nacional e preservação ambiental.

Dificuldades Intrínsecas:

- ▶ **Atenuação do Meio:**
Variabilidade do canal acústico (temperatura, salinidade, densidade).
- ▶ **Interferência de Fronteiras:**
Efeitos multipath (reflexão em fundo e superfície) e obstáculos.
- ▶ **Ruído de Fundo:** Fontes biológicas, ondas do mar e vento mascarando os alvos.

Limitação da Literatura Geral:


- ▶ Uso predominante de dados fechados/privados que inviabilizam a reprodutibilidade.
- ▶ Modelos aplicados a datasets pequenos, sem validação cruzada rigorosa baseada em isolamento de navios específicos.



SIMMAO: Plataformas e Trajetórias de Captura

Aquisição e Monitoramento via SIMMAO

O **Sistema de Medições e Modelagem Acústica Oceânica** gerencia os dados do PMPAS-BS (Petrobras): rastreia a trajetória de Gliders/perfiladores, calcula o Nível de Pressão Sonora (SPL) e visualiza de forma integrada o tráfego naval na Bacia de Santos.





Curadoria do Dataset IARA: Isolamento de Alvos

Para garantir que os áudios correspondam unicamente à embarcação monitorada, os autores (Silva et al., 2025) adotaram um protocolo rigoroso de filtragem espacial baseada em AIS:

Zonas de Inclusão e Exclusão

- ▶ **Inclusão (Navio Alvo):** Distância limite ao hidrofone (UO costeira: < 500 m, Glider: < 10 km).
- ▶ **Exclusão (Outros Navios):** Raio livre de tráfego concorrente (UO costeira: 2 km, Glider: 30 km).
- ▶ **Atenuação:** Garante isolamento da assinatura acústica e evita contaminação.

Verificação e Validação

- ▶ **Análise Espectral:** Confirmação de ganho de energia durante a máxima aproximação (CPA).
- ▶ **Consistência AIS:** Cruzamento de dados de múltiplos bancos para evitar erros cadastrais.
- ▶ **Revisão Manual:** Inspeção humana visual/auditiva em todas as gravações.



O Dataset de Referência IARA

Projeto de Monitoramento da Paisagem Acústica Submarina da Bacia de Santos (PMPAS-BS)

Criado pela PETROBRAS em conformidade com as exigências ambientais do licenciamento federal do IBAMA. Trata-se de uma base aberta de extrema riqueza científica.

Riqueza de Volume e Diversidade:

- ▶ **129 h 34 min** de gravações acústicas (50 GB).
- ▶ **1.825 áudios** contínuos de 2 a 5 minutos.
- ▶ **ShipsEar** possui apenas 3h 9min.
- ▶ **DeepShip** abrange 47h 4min.

Duas Plataformas de Captura:

- ▶ **Gliders:** Monitoramento oceânico móvel (descida até 1000m depth, taxa de 125 kHz).
- ▶ **Observatório Submarino (UO):** Fixado em regiões costeiras de tráfego a 19-28m de profundidade (taxa de 48 kHz).



Artigo de Referência: Silva et al. (IEEE Access, 2025)

Trabalho de Referência do Dataset IARA

Título: “IARA: An Underwater Acoustic Database”

Autores: F. O. B. da Silva et al. (UFRJ/LPS, LNCC, IPqM - Marinha do Brasil, Petrobras).

Publicação: *IEEE Access*, Vol. 13, Julho de 2025.

Três Arquiteturas de Baselines Estabelecidas:

- ▶ **Random Forest (RF)** [6]: Algoritmo de aprendizado por comitê (*ensemble*) baseado em árvores de decisão combinadas via *bagging* e seleção aleatória de atributos.
- ▶ **MLP** [7]: Redes neurais feedforward totalmente conectadas (Perceptron Multicamadas) que aproximam mapeamentos não-lineares através de camadas ocultas e treinamento via retropropagação (*backpropagation*).
- ▶ **CNN** [8]: Redes neurais convolucionais projetadas para a extração automática de padrões espaciais e temporais (aplicadas sobre espectrogramas 2D).



Objetivo do Trabalho

Considerando a indicação da **MLP** como baseline de melhor desempenho por Silva et al. (2025), o objetivo principal deste trabalho é **complementar** essa análise através de uma nova abordagem baseada em SVM.

“Baselines were established using Random Forest, MLP, and CNN classification models, with the MLP achieving the best performance: a balanced accuracy of $67.48 \pm 1.24\%$ ”

— Silva et al. (2025)

Diretrizes Principais

- ▶ **Novo Modelo (SVM Nyström):** Propor e avaliar o SVM aproximado via Nyström para processamento em larga escala.
- ▶ **Comparação Direta (SVM vs. MLP):** Comparar sistematicamente nosso modelo com a **MLP** (modelo campeão do estudo de referência) sob validação cruzada $5 \times 2cv$.



Definição do Problema e Mapeamento de Classes

Metadados Originais do IARA

Dados brutos de rastreamento AIS:

- ▶ Identificação única do navio físico.
- ▶ Tipo de embarcação geral (*Cargo*, *Passenger*, *Tug*) e detalhado (34 tipos).
- ▶ **Comprimento físico exato** (em metros).

Limitação: Alta variabilidade dentro da mesma categoria nominal (ex: *Passenger* com comprimentos de 10m a 333m).

Mapeamento Proposto (Silva et al., 2025)

Mapeamento multiclasse unificado focado no comprimento (limiares do ShipsEar):

- ▶ **SMALL** (comprimento < 50 m)
- ▶ **MEDIUM** (comprimento 50 m a 100 m)
- ▶ **LARGE** (comprimento > 100 m)
- ▶ **BACKGROUND** (ruído oceânico ambiental)

Vantagem: Melhor correlação físico-acústica e padronização das assinaturas.



Desafios Técnicos e Requisitos do Projeto

Desafios Técnicos

Características físicas do ambiente:

- ▶ **Atenuação e Multipath:** Canal acústico instável distorce severamente as assinaturas propagadas.
- ▶ **Mascaramento de Ruído:** Ruído de fundo oceânico oculta raias discretas de interesse.
- ▶ **Desbalanceamento:** Predomínio de LARGE/BACKGROUND, tornando a classe SMALL (minoridade, baixo SNR) o principal desafio aberto.

Requisitos do Sistema

Metas de engenharia e operação:

- ▶ **Robustez a Ruído:** Identificação de alvos sob flutuações severas de SNR.
- ▶ **Métrica de Equilíbrio:** Uso do Índice SP para expor e penalizar o viés em favor de classes majoritárias (avaliando minorias físicas).
- ▶ **Baixa Latência:** Viabilidade de processamento embarcado local em tempo real.



Representação Espectral, Baseline e Avaliação



Extração de Características Espectrais

Do Áudio ao Espectro: O sinal bruto de sonar passivo é mapeado para o domínio tempo-frequência (STFT), gerando espectrogramas que revelam as assinaturas acústicas das embarcações.

Espectrograma Mel (MEL) [9]

Mapeamento não-linear baseado na escala Mel (percepção auditiva humana).

- ▶ **Resolução:** Banco de 256 filtros triangulares.
- ▶ **Foco Físico:** Banda larga (ruído de cavitação de hélice e hidrodinâmico).
- ▶ **Dinâmica:** Compressão logarítmica das amplitudes de energia.

Espectrograma LOFAR [10]

Análise espectral de banda estreita com espaçamento de frequência linear.

- ▶ **Resolução:** 1024 bins de frequência linear fina.
- ▶ **Foco Físico:** Raias harmônicas discretas de maquinário (motores, eixos).
- ▶ **Uso:** Padrão na análise clássica de sonar passivo.



Técnicas de Normalização Espectral

Objetivo: Mitigar flutuações de amplitude induzidas pelo canal acústico (distância, atenuação, efeitos de multipath) e ganho de captura, isolando o perfil acústico intrínseco.

Normalização L2 (MEL) [12]

Aplica-se em cada janela de 0.512s.

- ▶ **Método:** Divide a janela por sua norma:
$$\bar{x} = x / \|x\|_2$$
- ▶ **Foco:** Neutraliza ganho/volume absoluto.
- ▶ **Efeito:** Classificador avalia apenas a forma da distribuição de energia.


Filtro TPSW (LOFAR) [11]

Algoritmo *Two-Pass Split Window* para estimativa de ruído local.


- ▶ **Método:** Estima patamar local de ruído contínuo.
- ▶ **Foco:** Suprime ruído de fundo oceânico.
- ▶ **Efeito:** Achatamento espectral e realce automático de raíais.



Pipelines de Extração: MEL e LOFAR



MEL (256 bins): Banco de filtros triangulares em escala logarítmica. Captura envelope de banda larga e cavitação. Normalização L2 por janela de 0.512s.



LOFAR (1024 bins): Espectro linear de banda estreita. Captura raias harmônicas de motores rotativos. Filtro TPSW suprime ruído oceânico contínuo.



Arquitetura MLP de Referência (Silva et al., 2025)

Mesma topologia de camadas ocultas para ambas as variantes — a única diferença está na entrada e no uso de dropout:

MLP MEL

Camada	Detalhe
Entrada	256 features (MEL)
FC + BN + ReLU	32 neurônios
Dropout	$p = 0.2$
FC + BN + ReLU	16 neurônios
Dropout	$p = 0.2$
Saída	4 classes (Sigmoid)

MLP LOFAR

Camada	Detalhe
Entrada	1024 features (LOFAR)
FC + BN + ReLU	32 neurônios (sem dropout)
FC + BN + ReLU	16 neurônios (sem dropout)
Saída	4 classes (Sigmoid)

Protocolo de Treinamento

Adam ($\eta = 10^{-4}$, weight decay = 10^{-3}) · CrossEntropyLoss · Batch size = 32 · *Early stopping* (paciência = 8 épocas, máx. 50 épocas).



Rigor Experimental: Validação Cruzada $5 \times 2cv$

O protocolo experimental garante avaliações estatísticas robustas e impede vazamento de dados:

O que é o Protocolo $5 \times 2cv$ (Alpaydm, 1999)

Realiza **5 repetições** de uma validação de **2 folds** (divisão em metades A e B):

- ▶ **Passo 1:** Treina no conjunto A e testa no conjunto B.
- ▶ **Passo 2:** Treina no conjunto B e testa no conjunto A.

Vantagem Estatística

- ▶ **Variância Realista:** Estimativas de variância sem subestimação.
- ▶ **Menor Viés:** Reduz dependência de dados entre partições.
- ▶ **Teste-t:** Permite comparação estatística via teste-t corrigido.

Isolamento de Navios

- ▶ **Foco no ID:** Partição feita por ID físico de cada navio.
- ▶ **Sem Vazamento:** Navio no treino nunca aparece no teste.
- ▶ **Generalização:** Avaliação real para alvos inéditos.



Figuras de Mérito

Índice SP (métrica principal)

Média geométrica dos recalls por classe:

$$SP = \sqrt[4]{\prod_{k=1}^4 Recall_k}$$

Se qualquer $Recall_k = 0$, $SP = 0$. Penaliza falhas em qualquer classe, especialmente minorias.

F1-Score Macro

Média dos F1 por classe:

$$F1 = \frac{1}{K} \sum_k \frac{2 \cdot P_k \cdot R_k}{P_k + R_k}$$

Complementar ao SP: incorpora Precisão além do Recall, penalizando igualmente classes minoritárias.

Acurácia Global (ACC)

Proporção de acertos globais:

$$ACC = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i)$$

Limitação: em bases desbalanceadas, inflada pelas classes majoritárias — mascara falhas em SMALL.



Método Proposto



Motivação: O SVM em Sonar Passivo

O Clássico de Referência na Literatura

O SVM é amplamente consolidado como um baseline robusto em classificação acústica de alvos submarinos (UATR), sendo empregado em bases de dados consagradas como **ShipsEar** (Santos-Domínguez, 2016) e **DeepShip** (Irfan, 2021).

Lacuna na Literatura:


- ▶ **Dados Limitados:** Trabalhos anteriores validam o SVM em bases de pequeno porte (de 3h a 47h) e com trânsitos restritos.
- ▶ **Custo Computacional:** O crescimento do custo RBF $O(N^3)$ limita o teste em bases massivas.

A Fronteira do Dataset IARA:

- ▶ **Base de Grande Escala:** O IARA é uma das maiores bases públicas mundiais (**129h+** de dados, tráfego real).
- ▶ **Questão de Pesquisa:** Como o SVM tradicional se comporta sob este novo patamar de volume e complexidade de dados?

Entradas do SVM: Conectando o Pré-Processamento

Como Landmarks se Tornam Dimensões (Projeção Nyström)



Dois modos de entrada avaliados em paralelo:

- **MEL** $\rightarrow$ vetor $x \in \mathbb{R}^{256}$.
- **LOFAR** $\rightarrow$ vetor $x \in \mathbb{R}^{1024}$.

Classificação por janela:

- O SVM Nyström ($m = 4000$) classifica cada janela de 0.512s individualmente.
- O rótulo final do áudio é decidido por **votação por consenso temporal** sobre todas as janelas.

4 Classes de Saída:

- **SMALL / MEDIUM / LARGE / BACKGROUND**



SVM com Aproximação de Nyström


O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- ▶ **O que é N no IARA:** N é o número de janelas espectrais de treinamento — **varia com o espectro:** MEL (0.512s/janela) $\approx$ 500K janelas; LOFAR (0.058s/janela) $\approx$ 800K janelas.
- ▶ **Custo do SVM RBF Clássico:** Matriz $N \times N$ exige 1,0 **Terabyte de RAM** (inviável localmente).
- ▶ **Aproximação de Nyström (Baixo Rank):** Seleciona m amostras de referência (landmarks) do treino para mapear implicitamente cada amostra no espaço linear $\mathbb{R}^m$.
- ▶ **Base Projetada de Treinamento ($N \times m$):** Memória dominante — escala com ambos N e m :
 - ▶ MEL, $m = 4000$: $500K \times 4000 \times 4B \approx$ 8 GB (overhead total $\approx$ 10 GB).
 - ▶ LOFAR, $m = 4000$: $800K \times 4000 \times 4B \approx$ 13 GB (overhead total $\approx$ 15 GB).
- ▶ **Complexidade de Tempo:** Reduz de $O(N^3)$ para $O(N \cdot m^2)$, permitindo o treinamento linear em lotes via classificador SGD.
- ▶ **Tamanho do Modelo Final:** Armazena apenas o vetor de pesos linear das classes ($4 \times m$ floats $\approx$ < 100 KB).



Visualização: Seleção de Landmarks




Amostragem Uniforme Aleatória:

- **Processo:** Das ≈ 500.000 janelas de treino, o algoritmo sorteia aleatoriamente $m = 4000$ amostras reais.
- **Representatividade:** O sorteio aleatório em larga escala captura perfeitamente as densidades reais de todas as classes acústicas marinhas.
- **Custo zero:** Evita algoritmos pesados de clustering (como K-Means), economizando recursos e tempo.



Kernel RBF com Nyström

O Truque do Kernel RBF com Nyström



Geometria da Separação:

- ▶ **Espaço Original (256D):** Os dados acústicos marinhos são altamente não-lineares e misturados (inseparáveis por retas).
- ▶ **Projeção de Nyström (4000D):** O cálculo da similaridade RBF contra os 4000 landmarks projeta os dados em alta dimensão.
- ▶ **Margem Linear:** No espaço projetado $\mathbb{R}^{4000}$, as classes tornam-se separáveis por um **Hiperplano de Decisão Linear** ($w^T z + b = 0$).



Trajetória de Escalonamento (Hiperparâmetros)



Sintonia de Kernel e Complexidade (m)

A Relação entre Componentes de Nyström (m) e Desempenho

O escalonamento de $m = 300$ até $m = 6000$ revela dinâmicas distintas entre os espectros MEL e LOFAR ao longo da curva de complexidade.

- ▶ **Fase Inicial ($m = 300$):** SP modesto ($\approx 61\%$, MEL). Espaço projetado insuficiente para capturar não-linearidades acústicas.
- ▶ **Fase Intermediária ($m = 1000\text{--}3000$):** **MEL supera LOFAR** consistentemente — a banda larga se beneficia mais rapidamente do aumento de pontos de referência.
- ▶ **MEL estabiliza em $m = 4000$:** SP de $64.56\% \pm 1.18\%$ (sem PCA) com variância reduzida — ganhos marginais adicionais se tornam negligenciáveis.
- ▶ **LOFAR continua evoluindo além de $m = 4000$:** As raias harmônicas finas exigem maior capacidade de representação. Em $m = 6000$, Ac. Bal. de $65.48\% \pm 1.76\%$ — LOFAR ultrapassa MEL e consolida-se como modelo de maior desempenho, replicando o padrão observado no MLP (melhor baseline do artigo de referência).



Ajuste de C , γ e Regularização: Impacto Marginal

► Penalidade C :

- MEL — $C = 0.5$: SP cai para 57.5%; $C = 2.0$: SP 63.8%, ganho < 0.1 p.p. sobre o padrão.
- LOFAR — $C = 0.1$: SP despenca para 54.8%; $C = 2.0$: praticamente idêntico ao padrão.

► Largura do kernel γ :

- Padrão sklearn: $\gamma = 1/d$. Variações testadas reduziram a separabilidade em ambos os espectros.

► Razão ElasticNet (ℓ_1/ℓ_2):

- Ajustes na proporção ℓ_1/ℓ_2 não trouxeram ganhos sobre a configuração padrão.

► Landmarks via MiniBatchKMeans:

- Centroides de clustering como landmarks — esperava-se melhor cobertura do espaço de características.
- Resultados equivalentes ao Nyström com amostragem aleatória; custo de clustering não se justificou.

Conclusão

Nenhuma dessas estratégias superou os valores padrão. **O ganho decisivo veio exclusivamente do aumento de m :** mais landmarks $\Rightarrow$ projeção mais fiel ao kernel RBF $\Rightarrow$ fronteiras de decisão mais precisas.



Resultados Gerais



Benchmarking com melhores modelos: SVM vs. MLP

Origem	Modelo	Espectro	SP (%)	Ac. Bal. (%)	F1 Macro (%)
Artigo	MLP	MEL	63.38 ± 1.81	64.51 ± 1.75	62.89 ± 1.68
	MLP	LOFAR	66.51 ± 1.39	67.48 ± 1.24	66.72 ± 1.17
Reproduzido	MLP	MEL	64.66 ± 2.11	65.64 ± 1.96	64.12 ± 2.19
	MLP	LOFAR	66.25 ± 1.78	67.21 ± 1.65	66.44 ± 1.88
Proposto	SVM ($m=4000$)	MEL	63.80 ± 1.12	64.58 ± 1.14	64.36 ± 1.05
	SVM ($m=6000$)	LOFAR	63.84 ± 1.91	65.48 ± 1.76	63.60 ± 1.71

- ▶ **Reprodução:** MLP LOFAR local (SP 66.25%, Ac. Bal. 67.21%) vs. artigo (66.51%, 67.48%) — diferença < 0.3 p.p. ✓
- ▶ **SVM MEL** (proposta) reduz variância em **38%** vs. MLP MEL (σ : 1.12% vs. 1.81%) com SP equivalente.
- ▶ **SVM LOFAR** (proposta) fica a apenas **2.67 p.p.** do MLP LOFAR sem uso de PCA.



Matrizes de Confusão — Nível de Áudio (5×2cv)

Linhas = classe real — Colunas = predição — Acumulado sobre 10 folds, avaliação por navio (votação majoritária)

Desvio padrão omitido nas células por clareza visual — prática padrão na literatura.

MLP MEL (Baseline)

	S	M	L	BG
SMALL	44.8	25.4	17.9	11.8
MEDIUM	20.4	64.0	13.1	2.5
LARGE	12.9	15.0	68.6	3.6
BG	6.1	3.8	5.0	85.1

SVM MEL ($m=4000$, Proposto)

	S	M	L	BG
SMALL	50.9	24.3	17.6	7.2
MEDIUM	26.0	60.4	12.5	1.1
LARGE	14.9	13.6	69.2	2.3
BG	11.0	4.9	6.2	77.9

MLP LOFAR (Melhor Baseline do Artigo)

	S	M	L	BG
SMALL	46.6	21.2	25.3	7.0
MEDIUM	22.6	61.3	13.8	2.3
LARGE	12.8	10.0	74.7	2.5
BG	7.3	3.8	2.6	86.3

SVM LOFAR ($m=6000$, Proposto)

	S	M	L	BG
SMALL	38.2	22.9	28.6	10.3
MEDIUM	17.6	60.5	17.2	4.8
LARGE	9.3	10.8	76.3	3.6
BG	6.1	2.8	4.2	86.9

- ▶ **SMALL** é o alvo crítico: **SVM MEL** lidera com 51% vs. 47% (MLP LOFAR) e 38% (SVM LOFAR).
- ▶ Modelos **LOFAR** maximizam LARGE (74–76%) mas confundem SMALL↔LARGE; modelos **MEL** confundem SMALL↔MEDIUM.
- ▶ **BG** bem classificado por todos (>77%); MEDIUM e LARGE convergem acima de 60% em todos os modelos.



Conclusões e Próximos Passos



Conclusões do Trabalho

Como resultado da avaliação e benchmarking do SVM Gaussiano com Nyström frente à MLP de referência (Silva et al., 2025) na base IARA, conclui-se que:

- ▶ **SVM Nyström é competitivo e estável:** SVM LOFAR ($m=6000$) alcança SP 63.8% e ACC 65.5%, frente ao MLP LOFAR (SP 66.5%, ACC 67.5%) — gap de apenas ≈ 2.7 p.p. com desvio padrão fold-wise menor.
- ▶ **SVM MEL supera MLP no alvo SMALL:** recall SMALL de **50.9%** (SVM MEL) vs. 46.6% (MLP LOFAR) — vantagem no alvo de maior dificuldade.
- ▶ **LOFAR e MEL são complementares:** LOFAR maximiza LARGE/BG; MEL favorece SMALL — motivando estratégias de fusão como trabalho futuro.



Trabalhos Futuros

Com o objetivo de refinar as margens de decisão e mitigar os erros de classificação no alvo mais difícil (**SMALL**), propõem-se os seguintes passos:

- ▶ **Estratégia Híbrida de Dois Estágios:** Classificação hierárquica com especialistas focados nas classes de menor recall (**SMALL** e **MEDIUM**), combinando as forças complementares de LOFAR e MEL para reduzir confusões críticas entre categorias de navios.
- ▶ **Exploração de Outras Representações Espectrais:** Avaliar Outras Técnicas de Extração de características como **DEMON** (modulação do hélice/taxa de pás) e **MFCC** (coeficientes cepstrais), que capturam fenômenos físicos distintos de LOFAR e MEL e podem beneficiar especialmente o alvo **SMALL**.
- ▶ **Modelos com Dinâmica Temporal:** Avaliar arquiteturas recorrentes como **GRU** e **LSTM**, capazes de processar a sequência de frames espectrais ao longo do tempo — capturando padrões temporais (ciclos do hélice, ritmos de maquinário) que o SVM descarta ao agregar o segmento em vetor fixo.



Referências I



Silva, F. O. B. da, Fernandes, J. C. V., Soares Filho, W., Souza Filho, J. B. O. e, Spengler, A. & Moura Júnior, N. N. (2025). IARA: An Underwater Acoustic Database. *IEEE Access*, Vol. 13, doi: 10.1109/ACCESS.2025.3585467.



Santos-Domínguez, D., Torres-Guijarro, S., Cardenal-Martín, J. & Pena-Gimenez, A. (2016). ShipsEar: An underwater vessel noise database. *Applied Acoustics*, 113, 64-69.



Irfan, M., Jiang, Z., Ali, S., et al. (2021). DeepShip: An underwater acoustic threshold-based database for ship classification. *Scientific Reports*, 11, 23005.



Williams, C. K. I. & Seeger, M. (2001). Using the Nyström method to speed up algorithms on kernel matrices. *Advances in Neural Information Processing Systems (NeurIPS)*.



Chow, C. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41-46.



Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.



Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.



LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.



Hummel, H. I., van der Mei, R. & Bhulai, S. (2024). A survey on machine learning in ship radiated noise. *Ocean Engineering*, Vol. 298, Art. 117252.



Referências II



Fernandes, J. C. V., Moura Júnior, N. N. de & Seixas, J. M. de (2022). Deep learning models for passive sonar signal classification of military data. *Remote Sensing*, Vol. 14, No. 11, p. 2648.



Nielsen, P. A. (1994). A comparison of three estimators for the background noise level in lofargrams. *IEEE Journal of Oceanic Engineering*, 19(1), 106-110.



Zhou, A., et al. (2023). A novel cross-attention fusion-based joint training framework for robust underwater acoustic signal recognition. *IEEE Transactions on Geoscience and Remote Sensing*, Vol. 61, Art. 4209516.