



Classificação Acústica Submarina Passiva no Dataset IARA

Benchmarking do SVM Nyström e Otimização via Opção de
Rejeição

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ/COPPE/PEE

Junho de 2026



Agenda

1. Introdução e Contexto (Dataset IARA)
2. O Artigo de Referência e Baselines
3. Método Proposto (SVM Nyström)
4. Resultados Gerais de Desempenho
5. Classificação Seletiva (Opção de Rejeição)
6. Análise por Alvo e Limitações do SMALL
7. Generalização Física em Distância (CPA)
8. Trajetória de Escalonamento
9. Conclusões e Mitigações Futuras



Introdução e Contexto



Classificação Acústica Submarina (UATR)

Desafio de Sonar Passivo

Identificar embarcações baseando-se unicamente nas suas assinaturas acústicas irradiadas através da água. Uma tarefa altamente crítica para monitoramento de tráfego, soberania nacional e preservação ambiental.

Dificuldades Intrínsecas:

- ▶ **Atenuação do Meio:**
Variabilidade do canal acústico (temperatura, salinidade, densidade).
- ▶ **Interferência de Fronteiras:**
Efeitos multipath (reflexão em fundo e superfície) e obstáculos.
- ▶ **Ruído de Fundo:** Fontes biológicas, ondas do mar e vento mascarando os alvos.

Limitação da Literatura Geral:

- ▶ Uso predominante de dados fechados/privados que inviabilizam a reprodutibilidade.
- ▶ Modelos aplicados a datasets pequenos, sem validação cruzada rigorosa baseada em isolamento de navios específicos.



O Dataset de Referência IARA

Santos Basin Soundscape Monitoring Project (PMPAS-BS)

Criado pela PETROBRAS em conformidade com as exigências ambientais do licenciamento federal do IBAMA. Trata-se de uma base aberta de extrema riqueza científica.

Riqueza de Volume e Diversidade:

- ▶ **129 h 34 min** de gravações acústicas (50 GB).
- ▶ **1.825 áudios** contínuos de 2 a 5 minutos.
- ▶ **ShipsEar** possui apenas 3h 9min.
- ▶ **DeepShip** abrange 47h 4min.

Duas Plataformas de Captura:

- ▶ **Gliders:** Monitoramento oceânico móvel (descida até 1000m depth, taxa de 125 kHz).
- ▶ **Observatório Submarino (UO):** Fixado em regiões costeiras de tráfego a 19-28m de profundidade (taxa de 48 kHz).



O Artigo de Referência e Baselines



A Literatura Científica que Estabelece os Baselines

Título: *"IARA: An Underwater Acoustic Database"*

Autores: F. O. B. da Silva et al. (UFRJ/LPS, LNCC, IPqM - Marinha do Brasil, Petrobras).

Publicação: *IEEE Access*, Vol. 13, Julho de 2025.

Três Arquiteturas de Baselines:

- ▶ **Random Forest (RF):**
Classificação baseada em florestas decisórias de baixa variabilidade.
- ▶ **MLP:** Redes feedforward totalmente conectadas profundas.
- ▶ **CNN:** Redes convolucionais processando imagens espectrais 2D (time-frequency).

Extrações Espectrais Utilizadas:

- ▶ **MEL:** Mel-Spectrogram (256 bins), focado no mapeamento da audição humana.
- ▶ **LOFAR:** Normalização TPSW para destacar assinaturas discretas de maquinaria (raias harmônicas).



Processamento de Sinais: Extratores MEL e LOFAR

Banco de Filtros MEL (Log-Melgram):

- ▶ **Dimensão:** 256 bandas (bins) em escala logarítmica.
- ▶ **Foco:** Representa o envelope espectral de banda larga e ruído difuso de cavitação.
- ▶ **Configuração:** Janelamento de 0.512s ($N_{pts} = 1024$), sem sobreposição, decimação por 3.

LOFAR Espectral (TPSW):

- ▶ **Dimensão:** 1024 bins lineares (banda estreita).
- ▶ **Foco:** Raias harmônicas discretas de máquinas rotativas.
- ▶ **TPSW** (*Two-Pass Split Window*): Normalização espectral adaptativa para atenuar o ruído contínuo de fundo oceânico.

Normalização das Variáveis

Para mitigar flutuações de ganho do hidrofone, distância do alvo e perdas de propagação do meio acústico, aplica-se a normalização ****L2**** ao nível de frame em ambos os extratores espectrais.



Metodologia de Re-processamento e Dados

► Verificação de Intrusos (Zonas de Exclusão):

- Cruzamento de dados de GPS e rastreamento AIS define regiões de exclusão temporal.
- Capturas contaminadas por múltiplas embarcações na proximidade do hidrofone são expurgadas.
- Parâmetro `include_others = False` assegura que o áudio corresponde unicamente ao navio vigiado.

► Seleção e Estrutura das Entradas (Inputs):

- **Classificadores 1D** (Random Forest, MLP, SVM): Alimentados por vetores de janelas discretas de 0.512s (`InputType.Window()`).
- **Classificador 2D** (CNN Convolutacional): Imagem temporal composta por 32 janelas consecutivas com 50% de sobreposição (`InputType.Image()`).

► Divisão de Conjuntos (Treino, Validação e Teste):

- **Rigor Temático:** Protocolo $5 \times 2cv$ (10 folds) restrito ao nível de ****ID de Navio Físico**** (*Exclusive Ships on Test*) para evitar vazamento temporal.
- **Parâmetro de Validação:** MLP e CNN separam uma fração do treino para validação interna (*early stopping* com paciência de 8 épocas). O SVM dispensa conjunto de validação durante o fit.



Categorias de Alvos e Rigor Experimental

Definição das 4 Classes Baseada em Tamanho [41]:

- ▶ **SMALL:** Embarcações de baixo calado (comprimento físico < 50 m).
- ▶ **MEDIUM:** Embarcações de porte médio (50 m a 100 m).
- ▶ **LARGE:** Navios de grande porte (> 100 m) – forte ruído de cavitação e motores.
- ▶ **BACKGROUND:** Ruído de fundo oceânico ambiental (exclusão absoluta de embarcações por radar/AIS).

Rigor de Validação Cruzada 5x2:

- ▶ Protocolo de **Validação Cruzada 5x2** (10 folds totais).
- ▶ **Exclusive Ships on Test:** Restrição rigorosa garantindo que amostras acústicas de um navio no treino jamais vazem para o conjunto de teste.
- ▶ **Sum-Product Index (SP):** Figura de mérito principal equilibrada para lidar com desbalanceamento.

Melhor Resultado Original das Baselines do Artigo

O melhor baseline no artigo de Silva et al. foi a **MLP LOFAR**, alcançando acurácia global de $67.48\% \pm 1.24\%$ e SP de $66.51\% \pm 1.39\%$.



Método Proposto: SVM Nyström



Motivação: O SVM em Sonar Passivo

O Clássico de Referência na Literatura

O SVM é amplamente consolidado como um baseline robusto em classificação acústica de alvos submarinos (UATR), sendo empregado em bases de dados consagradas como **ShipsEar** (Santos-Domínguez, 2016) e **DeepShip** (Irfan, 2021).

Lacuna na Literatura:

- ▶ **Dados Limitados:** Trabalhos anteriores validam o SVM em bases de pequeno porte (de 3h a 47h) e com trânsitos restritos.
- ▶ **Custo Computacional:** O crescimento do custo RBF $O(N^3)$ limitava o teste em bases massivas.

A Fronteira do Dataset IARA:

- ▶ **Base de Grande Escala:** O IARA é uma das maiores bases públicas mundiais (**129h+** de dados, tráfego real).
- ▶ **Questão de Pesquisa:** Como o SVM tradicional se comporta sob este novo patamar de volume e complexidade de dados?



SVM com Aproximação de Nyström

O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- ▶ **O que é N no IARA:** $N \approx 500.000$ janelas espectrais no treino (853 arquivos $\times$ 586 janelas/arquivo).
- ▶ **Custo do SVM RBF Clássico:** Matriz $N \times N$ exige 1,0 **Terabyte de RAM** (inviável localmente).
- ▶ **Aproximação de Nyström (Baixo Rank):** Seleciona $m = 4000$ amostras de referência (landmarks) do treino para mapear implicitamente cada amostra no espaço linear $\mathbb{R}^m$.
- ▶ **Matriz de Kernel Nyström ($m \times m$):** Mede apenas 4000×4000 de float32 $\approx$ 64 **Megabytes de RAM** (inversão matemática instantânea).
- ▶ **Base Projetada de Treinamento ($N \times m$):** Matriz $500K \times 4000$ de float32 $\approx$ 8,0 **Gigabytes de RAM** (viabiliza o treino em hardware convencional com overhead total $\approx$ 10 GB).
- ▶ **Complexidade de Tempo:** Reduz de $O(N^3)$ para $O(N \cdot m^2)$, permitindo o treinamento linear em lotes através de classificador SGD.
- ▶ **Tamanho do Modelo Final:** Armazena apenas o vetor de pesos linear das classes (4×4000 floats $\approx$ < 100 KB).



Representações Espectrais e a Dinâmica do PCA

Banco de Filtros MEL (256 bins):

- ▶ Entrada direta de 256 bandas sem redução.
- ▶ **Por que sem PCA?** A representação Mel-Spectrogram já é uma compressão logarítmica integradora não-linear. Aplicar PCA linear gera perda severa de informações das bandas espectrais.
- ▶ Confirmado em testes: MEL com PCA degradou o desempenho.

LOFAR Espectral (TPSW):

- ▶ Entrada comprimida previamente via PCA linear ($n_{components} = 64$).
- ▶ **Por que com PCA?** O espectrograma LOFAR cru é extremamente caótico e ruidoso. O PCA atua como um excelente filtro de ruído tridimensional de fundo marinho, evidenciando as raiais discretas e melhorando a separabilidade linear.

Descoberta Científica Relevante

Verificou-se uma dinâmica inversa do PCA: essencial para LOFAR (limpeza de ruído), mas prejudicial para MEL (supressão de features anatômicas já integradas de forma não-linear).



Resultados Gerais



Benchmarking Global de Teste (Sem Rejeição)

Modelo / Classificador	Espectro	Índice SP (%)	Acurácia Global
RF	MEL	62.22 ± 1.86	62.64 ± 1.86
RF	LOFAR	56.92 ± 1.69	58.87 ± 1.69
MLP (Baseline Artigo)	MEL	63.38 ± 1.81	64.51 ± 1.77
MLP (Baseline Artigo)	LOFAR	66.51 ± 1.39	67.48 ± 1.39
CNN	MEL	63.52 ± 2.26	64.99 ± 2.09
CNN	LOFAR	66.05 ± 1.90	67.02 ± 1.77
SVM Proposto (m=4000)	MEL	63.78 ± 1.14	64.56 ± 1.14
SVM Proposto (m=4000)	LOFAR	63.10 ± 2.19	64.04 ± 1.14

Tabela: Resultados gerais sob Validação Cruzada 5x2 no IARA.

Destaque: O **SVM Mel** proposto alcançou desempenho estatisticamente equivalente à CNN Mel profunda, porém com **metade de sua variância fold-wise** ($\sigma_{SVM} = 1.18\%$ vs. $\sigma_{CNN} = 2.09\%$), comprovando a estabilidade da fronteira geométrica convexa.



Classificação Seletiva (Opção de Rejeição)



Calibração Geométrica vs. Superconfiança da CNN

O que é a Opção de Rejeição?

Proposta de consenso temporal baseada no acúmulo de janelas consecutivas de classificação (de 0.512s). Um áudio completo só é rotulado se o limiar de concordância de votos t for alcançado. Caso contrário, o sistema prudentemente se recusa a classificar (rejeita).

Superconfiança da CNN

Convolutacional:

- ▶ Sob alta severidade de ruído ($t \geq 0.9$), a CNN Mel mantém cobertura de **54.01%**, mas sua acurácia satura em apenas **74.39%**.
- ▶ Revela calibração fraca das probabilidades de saída, tomando decisões erradas de forma superconfiante.

Calibração Estatística do SVM:

- ▶ Ao delimitar margens rígidas de separabilidade espectral, o SVM Nyström exibe calibração de confiança notável.
- ▶ Rejeita trechos sob atenuação severa de SNR e atinge precisões excepcionais nos áudios aceitos.



Curva de Trade-off Cobertura-Acurácia

Limiar de Votos (t)	Representação / Modelo	Taxa de Cobertura (%)	Acurácia de Teste (%)	Índice S
$t = 0$ (Sem Rejeição)	MEL (SVM - Proposto)	100.00 $\pm$ 0.00	64.56 $\pm$ 1.18	63.78 $\pm$ 1.18
	LOFAR (SVM - Proposto)	100.00 $\pm$ 0.00	63.32 $\pm$ 2.10	63.10 $\pm$ 1.18
$t \geq 0.5$ (Maioria)	LOFAR (SVM - Proposto)	78.25 $\pm$ 1.90	70.36 $\pm$ 2.13	68.56 $\pm$ 2.13
	MEL (SVM - Proposto)	89.67 $\pm$ 1.17	66.23 $\pm$ 1.48	66.07 $\pm$ 1.48
$t \geq 0.7$ (Forte)	LOFAR (SVM - Proposto)	47.12 $\pm$ 3.23	82.39 $\pm$ 3.22	77.25 $\pm$ 3.22
	MEL (SVM - Proposto)	63.40 $\pm$ 2.91	73.60 $\pm$ 2.22	70.79 $\pm$ 2.22
$t \geq 0.8$ (Seguro)	LOFAR (SVM - Proposto)	35.04 $\pm$ 3.35	86.75 $\pm$ 2.81	79.79 $\pm$ 2.81
	MEL (SVM - Proposto)	51.28 $\pm$ 2.94	77.70 $\pm$ 2.35	73.10 $\pm$ 2.35
$t \geq 0.9$ (Crítico)	LOFAR (SVM - Proposto)	22.27 $\pm$ 2.86	90.43 $\pm$ 2.95	78.85 $\pm$ 2.95
	MEL (SVM - Proposto)	37.48 $\pm$ 2.32	83.42 $\pm$ 2.07	75.58 $\pm$ 2.07

Tabela: Curva empírica de trade-off sob consenso temporal.

Conclusão do Trade-off: No limiar de segurança máxima ($t \geq 0.90$), o **SVM LOFAR** estabelece a acurácia recorde de **90.43% $\pm$ 2.95%**, operando com cobertura de 22.27% dos dados (assertividade máxima).



Análise por Alvo e Gargalo do SMALL



Distribuição de Classes no Filtro Crítico ($t \geq 0.90$)

Classe de Alvo	Áudios Totais / Fold	Taxa de Cobertura (%)	Acu
LARGE	214.0	27.01 ± 6.76	96.
BACKGROUND	98.0	52.55 ± 8.23	95.
MEDIUM	149.0	13.36 ± 4.56	81.0
SMALL	178.0	7.36 ± 1.84	49.7
GLOBAL	639.0	22.27 ± 2.86	90.

Tabela: Métricas por classe com SVM LOFAR ($t \geq 0.90$).

- ▶ **LARGE e BACKGROUND:** Acurácia espetacular superior a **95%**.
- ▶ **MEDIUM:** Aproveitamento seguro e equilibrado com **81.00%** de acerto.
- ▶ **SMALL:** Gargalo severo com acurácia pífia de **49.74%** e baixíssima cobertura.



A Limitação Física do Alvo SMALL

Entendimento Físico-Acústico do Problema

Embarcações de pequeno porte (SMALL) produzem assinaturas de baixíssima potência e carecem das clássicas raias harmônicas discretas abaixo de 1000Hz (que compõem a maior parte das energias do LOFAR).

Fatores de Degradação:

- ▶ **Ruído Difuso de Banda Larga:** A assinatura acústica assemelha-se ao mar aberto e vento, gerando forte confusão espectral com a classe **BACKGROUND** (alta entropia de Shannon).
- ▶ **A Sabedoria Geométrica da Rejeição:** A opção de rejeição temporal atua descartando sabiamente **92.64%** de todas as janelas acústicas do SMALL. Isso evita sobrecarregar o operador de sonar com falsas classificações e alarmes inconsistentes.



Generalização CPA (Proximidade)



Robustez ao CPA Proximity (Distância do Alvo)

Generalização entre Níveis de SNR

Avaliação da capacidade do modelo de lidar com atenuação extrema de sinal decorrente da distância ao hidrofone:

- **Dataset A (Near CPA):** Alta SNR (distância < 250 metros).
- **Dataset C (Far CPA):** Baixa SNR (distância entre 250 e 500 metros).

Classificador	Treinado em	SP A (%)	ACC A (%)	SP C (%)	ACC C (%)
MLP Mel	Dataset A (Near)	67.33 ± 2.67	67.74 ± 2.69	60.16 ± 5.99	61.03 ± 5.18
CNN Mel	Dataset A (Near)	61.84 ± 3.26	62.61 ± 2.85	56.58 ± 4.80	58.09 ± 4.30
SVM Mel (m=4000)	Dataset A (Near)	64.15 ± 2.87	65.08 ± 2.91	59.24 ± 4.55	60.84 ± 3.59
SVM LOFAR (m=4000)	Dataset A (Near)	67.24 ± 3.42	68.23 ± 2.94	55.35 ± 4.45	57.26 ± 3.66
MLP Mel	Dataset C (Far)	59.36 ± 4.55	59.70 ± 4.47	59.46 ± 4.45	60.21 ± 4.17
SVM LOFAR (m=4000)	Dataset C (Far)	58.52 ± 4.95	59.59 ± 4.65	55.84 ± 6.00	57.38 ± 5.49

Tabela: Recomposição da Tabela 10 de Silva et al. (2025) com os modelos SVM.

- **Recorde Absoluto:** O **SVM LOFAR** estabelece o melhor resultado de acurácia global do estudo de CPA no Dataset A: **68.23%**.
- **Estabilidade:** Na transição de A $\rightarrow$ C, o SVM Mel **exibe queda de**



Trajetória de Escalonamento (Hiperparâmetros)



Sintonia de Kernel e Complexidade (m)

A Relação entre Componentes de Nyström (m) e Desempenho

O escalonamento logarítmico de $m = 300$ até $m = 4000$ revela a evolução da modelagem matemática das fronteiras de decisão complexas das classes acústicas.

- ▶ **Fase Inicial ($m = 300$):** Acurácia modesta de $61.02\% \pm 1.94\%$ (MEL). O espaço projetado carece de representação para as frequências não-lineares.
- ▶ **Fase Intermediária ($m = 1000$ a 3000):** Aumento contínuo da representatividade. O modelo captura transições espectrais importantes de motores.
- ▶ **Golden Scale ($m = 4000$):**
 - ▶ **Golden MEL:** $64.56\% \pm 1.18\%$ (sem PCA) – estabilidade com variância reduzida.
 - ▶ **Golden LOFAR:** $64.04\% \pm 1.88\%$ (com PCA64) – excepcional para generalização e filtragem temporal.



Conclusões e Próximos Passos



Conclusões e Recomendações

Síntese do Trabalho Científico

O modelo proposto de **SVM com Aproximação de Nyström** provou ser um estimador robusto e estável para sonar passivo, superando as baselines profundas em cenários de alta variabilidade e apresentando excelente calibração.

Direcionamentos Principais:

- ▶ **Rejeição Temporal:** Essencial para viabilidade prática. Eleva a precisão global para **90.43%** na maioria simples dos áudios aceitos.
- ▶ **Dualidade do PCA:** Deve ser empregado estritamente sob representações brutas de alta frequência (LOFAR) e desativado em extratores já integrados de forma logarítmica (MEL).



Mitigações Futuras para o Alvo SMALL

Para superar a limitação física do alvo SMALL frente ao BACKGROUND, propõem-se 4 estratégias fundamentais de pesquisa:

1. **Fusão Espectral Híbrida:** Concatenar a banda discretizada do LOFAR (< 1000 Hz) com a escala Mel de alta frequência (1.5 kHz a 10 kHz), onde pequenos alvos produzem maior energia de cavitação.
2. **Redução de Ruído Adaptativa:** Implementar filtragem de Wiener adaptativa ou subtração espectral antes da classificação das janelas.
3. **Classificação Cascata Hierárquica:**
 - ▶ *Etapa 1:* Segmentar ruído de fundo (BACKGROUND vs. NAVIOS).
 - ▶ *Etapa 2:* Separar de forma binária SMALL vs. MEDIUM/LARGE.
4. **Aprendizado de Representação por Contraste (Contrastive Learning):** Forçar geometricamente a separação dos vetores de SMALL e BACKGROUND no espaço latente.



Referências



Silva, F. O. B. da, Fernandes, J. C. V., Soares Filho, W., Souza Filho, J. B. O. e, Spengler, A. & Moura Júnior, N. N. (2025). IARA: An Underwater Acoustic Database. *IEEE Access*, Vol. 13, doi: 10.1109/ACCESS.2025.3585467.



Santos-Domínguez, D., Torres-Guijarro, S., Cardenal-Martín, J. & Pena-Gimenez, A. (2016). ShipsEar: An underwater vessel noise database. *Applied Acoustics*, 113, 64-69.



Irfan, M., Jiang, Z., Ali, S., et al. (2021). DeepShip: An underwater acoustic threshold-based database for ship classification. *Scientific Reports*, 11, 23005.



Williams, C. K. I. & Seeger, M. (2001). Using the Nyström method to speed up algorithms on kernel matrices. *Advances in Neural Information Processing Systems (NeurIPS)*.



Chow, C. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41-46.