



Classificação Acústica Submarina Passiva em Datasets de Grande Porte

Estudo de Caso no Dataset IARA com SVM

Evandro Rocha

Universidade Federal do Rio de Janeiro
UFRJ/COPPE/PEE

Junho de 2026



Agenda

1. Introdução e Contexto (Dataset IARA)
2. Metodologia e Protocolo Experimental
3. Método Proposto (SVM Nyström)
4. Resultados Gerais de Desempenho
5. Trajetória de Escalonamento
6. Conclusões e Mitigações Futuras



Introdução e Contexto



Classificação Acústica Submarina (UATR)

Desafio de Sonar Passivo

Identificar embarcações baseando-se unicamente nas suas assinaturas acústicas irradiadas através da água. Uma tarefa altamente crítica para monitoramento de tráfego, soberania nacional e preservação ambiental.

Dificuldades Intrínsecas:

- ▶ **Atenuação do Meio:**
Variabilidade do canal acústico (temperatura, salinidade, densidade).
- ▶ **Interferência de Fronteiras:**
Efeitos multipath (reflexão em fundo e superfície) e obstáculos.
- ▶ **Ruído de Fundo:** Fontes biológicas, ondas do mar e vento mascarando os alvos.

Limitação da Literatura Geral:

- ▶ Uso predominante de dados fechados/privados que inviabilizam a reprodutibilidade.
- ▶ Modelos aplicados a datasets pequenos, sem validação cruzada rigorosa baseada em isolamento de navios específicos.



O Dataset de Referência IARA

Projeto de Monitoramento da Paisagem Acústica Submarina da Bacia de Santos (PMPAS-BS)

Criado pela PETROBRAS em conformidade com as exigências ambientais do licenciamento federal do IBAMA. Trata-se de uma base aberta de extrema riqueza científica.

Riqueza de Volume e Diversidade:

- ▶ **129 h 34 min** de gravações acústicas (50 GB).
- ▶ **1.825 áudios** contínuos de 2 a 5 minutos.
- ▶ **ShipsEar** possui apenas 3h 9min.
- ▶ **DeepShip** abrange 47h 4min.

Duas Plataformas de Captura:


- ▶ **Gliders:** Monitoramento oceânico móvel (descida até 1000m depth, taxa de 125 kHz).
- ▶ **Observatório Submarino (UO):** Fixado em regiões costeiras de tráfego a 19-28m de profundidade (taxa de 48 kHz).



SIMMAO: Plataformas e Trajetórias de Captura

Aquisição e Monitoramento via SIMMAO

O **Sistema de Medições e Modelagem Acústica Oceânica** gerencia os dados do PMPAS-BS (Petrobras): rastreia a trajetória de Gliders/perfiladores, calcula o Nível de Pressão Sonora (SPL) e visualiza de forma integrada o tráfego naval na Bacia de Santos.





Curadoria do Dataset IARA: Isolamento de Alvos

Para garantir que os áudios correspondam unicamente à embarcação monitorada, os autores (Silva et al., 2025) adotaram um protocolo rigoroso de filtragem espacial baseada em AIS:

Zonas de Inclusão e Exclusão

- ▶ **Inclusão (Navio Alvo):** Distância limite ao hidrofone (UO costeira: < 500 m, Glider: < 10 km).
- ▶ **Exclusão (Outros Navios):** Raio livre de tráfego concorrente (UO costeira: 2 km, Glider: 30 km).
- ▶ **Atenuação:** Garante isolamento da assinatura acústica e evita contaminação.

Verificação e Validação

- ▶ **Análise Espectral:** Confirmação de ganho de energia durante a máxima aproximação (CPA).
- ▶ **Consistência AIS:** Cruzamento de dados de múltiplos bancos para evitar erros cadastrais.
- ▶ **Revisão Manual:** Inspeção humana visual/auditiva em todas as gravações.



Artigo de Referência: Silva et al. (IEEE Access, 2025)

Trabalho de Referência do Dataset IARA

Título: “IARA: An Underwater Acoustic Database”

Autores: F. O. B. da Silva et al. (UFRJ/LPS, LNCC, IPqM - Marinha do Brasil, Petrobras).

Publicação: *IEEE Access*, Vol. 13, Julho de 2025.

Três Arquiteturas de Baselines Estabelecidas:

- ▶ **Random Forest (RF)** [6]: Algoritmo de aprendizado por comitê (*ensemble*) baseado em árvores de decisão combinadas via *bagging* e seleção aleatória de atributos.
- ▶ **MLP** [7]: Redes neurais feedforward totalmente conectadas (Perceptron Multicamadas) que aproximam mapeamentos não-lineares através de camadas ocultas e treinamento via retropropagação (*backpropagation*).
- ▶ **CNN** [8]: Redes neurais convolucionais projetadas para a extração automática de padrões espaciais e temporais (aplicadas sobre espectrogramas 2D).



Objetivo do Trabalho

Considerando a indicação da **MLP** como baseline de melhor desempenho por Silva et al. (2025), o objetivo principal deste trabalho é **complementar** essa análise através de uma nova abordagem baseada em SVM.

"Baselines were established using Random Forest, MLP, and CNN classification models, with the MLP achieving the best performance: a balanced accuracy of $67.48 \pm 1.24\%$ "

— Silva et al. (2025)

Diretrizes Principais

- ▶ **Novo Modelo (SVM Nyström):** Propor e avaliar o SVM aproximado via Nyström para processamento em larga escala.
- ▶ **Comparação Direta (SVM vs. MLP):** Comparar sistematicamente nosso modelo com a **MLP** (modelo campeão do estudo de referência) sob validação cruzada $5 \times 2cv$.
- ▶ **Opção de Rejeição:** Desenvolver uma estratégia de classificação com rejeição por votação temporal para aumentar a acurácia de decisão.



Definição do Problema e Mapeamento de Classes

Metadados Originais do IARA

Dados brutos de rastreamento AIS:

- ▶ Identificação única do navio físico.
- ▶ Tipo de embarcação geral (*Cargo*, *Passenger*, *Tug*) e detalhado (34 tipos).
- ▶ **Comprimento físico exato** (em metros).

Limitação: Alta variabilidade dentro da mesma categoria nominal (ex: *Passenger* com comprimentos de 10m a 333m).

Mapeamento Proposto (Silva et al., 2025)

Mapeamento multiclasse unificado focado no comprimento (limiares do ShipsEar):

- ▶ **SMALL** (comprimento < 50 m)
- ▶ **MEDIUM** (comprimento 50 m a 100 m)
- ▶ **LARGE** (comprimento > 100 m)
- ▶ **BACKGROUND** (ruído oceânico ambiental)

Vantagem: Melhor correlação físico-acústica e padronização das assinaturas.



Desafios Técnicos e Requisitos do Projeto

Desafios Técnicos

Características físicas do ambiente:

- ▶ **Atenuação e Multipath:** Canal acústico instável distorce severamente as assinaturas propagadas.
- ▶ **Mascaramento de Ruído:** Ruído de fundo oceânico oculta raias discretas de interesse.
- ▶ **Desbalanceamento:** Predomínio de LARGE/BACKGROUND, tornando a classe SMALL (minoridade, baixo SNR) o principal desafio aberto.

Requisitos do Sistema

Metas de engenharia e operação:

- ▶ **Robustez a Ruído:** Identificação de alvos sob flutuações severas de SNR.
- ▶ **Métrica de Equilíbrio:** Uso do Índice SP para expor e penalizar o viés em favor de classes majoritárias (avaliando minorias físicas).
- ▶ **Baixa Latência:** Viabilidade de processamento embarcado local em tempo real.



Metodologia e Protocolo Experimental



Extração de Características Espectrais

Do Áudio ao Espectro: O sinal bruto de sonar passivo é mapeado para o domínio tempo-frequência (STFT), gerando espectrogramas que revelam as assinaturas acústicas das embarcações.

Espectrograma Mel (MEL) [9]

Mapeamento não-linear baseado na escala Mel (percepção auditiva humana).

- ▶ **Resolução:** Banco de 256 filtros triangulares.
- ▶ **Foco Físico:** Banda larga (ruído de cavitação de hélice e hidrodinâmico).
- ▶ **Dinâmica:** Compressão logarítmica das amplitudes de energia.

Espectrograma LOFAR [10]

Análise espectral de banda estreita com espaçamento de frequência linear.

- ▶ **Resolução:** 1024 bins de frequência linear fina.
- ▶ **Foco Físico:** Raias harmônicas discretas de maquinário (motores, eixos).
- ▶ **Uso:** Padrão na análise clássica de sonar passivo.



Técnicas de Normalização Espectral

Objetivo: Mitigar flutuações de amplitude induzidas pelo canal acústico (distância, atenuação, efeitos de multipath) e ganho de captura, isolando o perfil acústico intrínseco.

Normalização L2 (MEL) [12]

Aplica-se em cada janela de 0.512s.

- ▶ **Método:** Divide a janela por sua norma:
$$\bar{x} = x / \|x\|_2$$
- ▶ **Foco:** Neutraliza ganho/volume absoluto.
- ▶ **Efeito:** Classificador avalia apenas a forma da distribuição de energia.


Filtro TPSW (LOFAR) [11]

Algoritmo *Two-Pass Split Window* para estimativa de ruído local.

- ▶ **Método:** Estima patamar local de ruído contínuo.
- ▶ **Foco:** Suprime ruído de fundo oceânico.
- ▶ **Efeito:** Achatamento espectral e realce automático de raíais.




Pipeline MEL: Áudio → Vetor de 256 Features



Banco de Filtros MEL (256 bins):

- ▶ **Dimensão**: 256 bandas em escala logarítmica (percepção humana).
- ▶ **Janelamento**: 0.512s ($N_{pts} = 1024$), sem sobreposição.
- ▶ **Foco**: Envelope espectral de banda larga e ruído difuso de cavitação.
- ▶ **Normalização L2**: Mitiga flutuações de ganho e distância do alvo.
- ▶ **Sem PCA**: A compressão log-mel já é não-linear; PCA adicional degrada desempenho.

Pipeline LOFAR: Áudio → Vetor de 64 Features (PCA)



LOFAR Espectral + TPSW (1024 bins):

- ▶ **Dimensão:** 1024 bins lineares de banda estreita.
- ▶ **Foco:** Raias harmônicas discretas de motores rotativos.
- ▶ **TPSW** (*Two-Pass Split Window*): Normalização adaptativa que suprime o ruído oceânico contínuo de fundo.
- ▶ **PCA (n=64):** Remove ruído residual e melhora separabilidade linear das classes.



Estruturação dos Modelos e Filtros de Software

► Seleção Lógica de Dados (Via Código):

- **Filtro de Classes:** O parâmetro `include_others = False` descarta áudios de embarcações que não pertencem a nenhuma das 4 classes do estudo (comprimento ausente ou categoria inválida).
- **Rotulação:** Mapeamento automático em tempo de carregamento do comprimento físico do navio (em metros) para as classes **SMALL**, **MEDIUM** ou **LARGE**.

► Seleção e Estrutura das Entradas (Inputs):

- **Classificadores 1D** (Random Forest, MLP, SVM): Alimentados por vetores de janelas discretas de 0.512s (`InputType.Window()`).
- **Classificador 2D** (CNN Convolutacional): Imagem temporal composta por 32 janelas consecutivas com 50% de sobreposição (`InputType.Image()`).

► Validação Interna e Parada Antecipada:

- **Early Stopping:** MLP e CNN separam uma fração do treino para validação interna, monitorando perda para interromper o treinamento (paciência de 8 épocas).
- **Sem Validação:** O classificador SVM aproximado via Nyström dispensa conjunto de validação interna, realizando o ajuste (*fit*) direto no treino global.



Rigor Experimental: Validação Cruzada $5 \times 2cv$

O protocolo experimental garante avaliações estatísticas robustas e impede vazamento de dados:

O que é o Protocolo $5 \times 2cv$ (Alpaydm, 1999)

Realiza **5 repetições** de uma validação de **2 folds** (divisão em metades A e B):

- ▶ **Passo 1:** Treina no conjunto A e testa no conjunto B.
- ▶ **Passo 2:** Treina no conjunto B e testa no conjunto A.

Vantagem Estatística

- ▶ **Variância Realista:** Estimativas de variância sem subestimação.
- ▶ **Menor Viés:** Reduz dependência de dados entre partições.
- ▶ **Teste-t:** Permite comparação estatística via teste-t corrigido.

Isolamento de Navios

- ▶ **Foco no ID:** Partição feita por ID físico de cada navio.
- ▶ **Sem Vazamento:** Navio no treino nunca aparece no teste.
- ▶ **Generalização:** Avaliação real para alvos inéditos.



Métricas de Avaliação: Acurácia Global

Para avaliar com rigor científico a classificação em bases de dados desbalanceadas, adota-se a tradicional acurácia global complementada por métricas robustas:

Acurácia Global (ACC)

Proporção de acertos globais do classificador sobre o conjunto de teste.

$$ACC = \frac{1}{N_{total}} \sum_{i=1}^{N_{total}} \mathbb{I}(\hat{y}_i = y_i) \times 100\%$$

Limitação e Viés: Em bases desbalanceadas (como o IARA), a acurácia é altamente inflada pelo acerto nas classes majoritárias (como alvos grandes e ruído de fundo), mascarando falhas críticas de identificação em classes de baixo calado (alvos pequenos).



Métricas de Avaliação: Índice Sum-Product (SP)

Como principal figura de mérito do dataset IARA, adota-se uma métrica balanceada que avalia o equilíbrio de desempenho entre todas as classes:

Índice Sum-Product (SP)

Média geométrica das taxas de acerto ($Recall$) de cada uma das K classes ($K = 4$).

$$SP = \left(\prod_{k=1}^K Recall_k \right)^{\frac{1}{K}} = \sqrt[4]{Recall_{Small} \cdot Recall_{Med} \cdot Recall_{Large} \cdot Recall_{Back}}$$

Justificativa Física e Matemática:

- ▶ Se o $Recall$ de qualquer classe colapsar para zero, o Índice SP cai imediatamente a **0%**.
- ▶ Penaliza assimetrias e a incapacidade de generalizar em minorias físicas, forçando o classificador a manter taxas decentes de acerto em todas as categorias.



Método Proposto: SVM Nyström



Motivação: O SVM em Sonar Passivo

O Clássico de Referência na Literatura

O SVM é amplamente consolidado como um baseline robusto em classificação acústica de alvos submarinos (UATR), sendo empregado em bases de dados consagradas como **ShipsEar** (Santos-Domínguez, 2016) e **DeepShip** (Irfan, 2021).

Lacuna na Literatura:

- ▶ **Dados Limitados:** Trabalhos anteriores validam o SVM em bases de pequeno porte (de 3h a 47h) e com trânsitos restritos.
- ▶ **Custo Computacional:** O crescimento do custo RBF $O(N^3)$ limitava o teste em bases massivas.


A Fronteira do Dataset IARA:

- ▶ **Base de Grande Escala:** O IARA é uma das maiores bases públicas mundiais (**129h+** de dados, tráfego real).
- ▶ **Questão de Pesquisa:** Como o SVM tradicional se comporta sob este novo patamar de volume e complexidade de dados?



Entradas do SVM: Conectando o Pré-Processamento

Como Landmarks se Tornam Dimensões (Projeção Nyström)



Dois modos de entrada avaliados em paralelo:

- ▶ **MEL** $\rightarrow$ vetor $x \in \mathbb{R}^{256}$ (sem PCA).
- ▶ **LOFAR** $\rightarrow$ vetor $x \in \mathbb{R}^{64}$ (após PCA).

Classificação por janela:

- ▶ O SVM Nyström ($m = 4000$) classifica cada janela de 0.512s individualmente.
- ▶ O rótulo final do áudio é decidido por **votação por consenso temporal** sobre todas as janelas.

4 Classes de Saída:

- ▶ **SMALL / MEDIUM / LARGE / BACKGROUND**



SVM com Aproximação de Nyström


O Gargalo do SVM RBF Clássico

O SVM padrão com kernel RBF exige calcular e armazenar a matriz de kernel $N \times N$, com complexidade espacial $O(N^2)$.

- ▶ **O que é N no IARA:** $N \approx 500.000$ janelas espectrais no treino (853 arquivos $\times$ 586 janelas/arquivo).
- ▶ **Custo do SVM RBF Clássico:** Matriz $N \times N$ exige 1,0 **Terabyte de RAM** (inviável localmente).
- ▶ **Aproximação de Nyström (Baixo Rank):** Seleciona $m = 4000$ amostras de referência (landmarks) do treino para mapear implicitamente cada amostra no espaço linear $\mathbb{R}^m$.
- ▶ **Matriz de Kernel Nyström ($m \times m$):** Mede apenas 4000×4000 de float32 $\approx$ 64 **Megabytes de RAM** (inversão matemática instantânea).
- ▶ **Base Projetada de Treinamento ($N \times m$):** Matriz $500K \times 4000$ de float32 $\approx$ 8,0 **Gigabytes de RAM** (viabiliza o treino em hardware convencional com overhead total $\approx$ 10 GB).
- ▶ **Complexidade de Tempo:** Reduz de $O(N^3)$ para $O(N \cdot m^2)$, permitindo o treinamento linear em lotes através de classificador SGD.
- ▶ **Tamanho do Modelo Final:** Armazena apenas o vetor de pesos linear das classes (4×4000 floats $\approx$ < 100 KB).



Visualização: Seleção de Landmarks




Amostragem Uniforme Aleatória:

- **Processo:** Das ≈ 500.000 janelas de treino, o algoritmo sorteia aleatoriamente $m = 4000$ amostras reais.
- **Representatividade:** O sorteio aleatório em larga escala captura perfeitamente as densidades reais de todas as classes acústicas marinhas.
- **Custo zero:** Evita algoritmos pesados de clustering (como K-Means), economizando recursos e tempo.



Visualização: O Truque do Kernel RBF com Nyström

O Truque do Kernel RBF com Nyström



Geometria da Separação:

- ▶ **Espaço Original (256D):** Os dados acústicos marinhos são altamente não-lineares e misturados (inseparáveis por retas).
- ▶ **Projeção de Nyström (4000D):** O cálculo da similaridade RBF contra os 4000 landmarks projeta os dados em alta dimensão.
- ▶ **Margem Linear:** No espaço projetado $\mathbb{R}^{4000}$, as classes tornam-se separáveis por um **Hiperplano de Decisão Linear** ($w^T z + b = 0$).



Representações Espectrais e a Dinâmica do PCA

Banco de Filtros MEL (256 bins):

- ▶ Entrada direta de 256 bandas sem redução.
- ▶ **Por que sem PCA?** A representação Mel-Spectrogram já é uma compressão logarítmica integradora não-linear. Aplicar PCA linear gera perda severa de informações das bandas espectrais.
- ▶ Confirmado em testes: MEL com PCA degradou o desempenho.

LOFAR Espectral (TPSW):

- ▶ Entrada comprimida previamente via PCA linear ($n_{components} = 64$).
- ▶ **Por que com PCA?** O espectrograma LOFAR cru é extremamente caótico e ruidoso. O PCA atua como um excelente filtro de ruído tridimensional de fundo marinho, evidenciando as raiais discretas e melhorando a separabilidade linear.

Descoberta Científica Relevante

Verificou-se uma dinâmica inversa do PCA: essencial para LOFAR (limpeza de ruído), mas prejudicial para MEL (supressão de features anatômicas já integradas de forma não-linear).



Resultados Gerais



Benchmarking Global de Teste (Sem Rejeição)

Modelo / Classificador	Espectro	Índice SP (%)	Acurácia Global (%)
RF	MEL	62.22 ± 1.86	62.64 ± 1.86
RF	LOFAR	56.92 ± 1.69	58.87 ± 1.69
MLP (Baseline Artigo)	MEL	63.38 ± 1.81	64.51 ± 1.81
MLP (Baseline Artigo)	LOFAR	66.51 ± 1.39	67.48 ± 1.39
MLP Híbrido (pca64)	HYBRID	66.13 ± 1.09	66.92 ± 1.09
CNN	MEL	63.52 ± 2.26	64.99 ± 2.26
CNN	LOFAR	66.05 ± 1.90	67.02 ± 1.90
SVM Proposto (m=4000)	MEL	63.78 ± 1.14	64.56 ± 1.14
SVM Proposto (m=4000)	LOFAR (C=0.5)	63.81 ± 2.35	64.89 ± 2.35
SVM Proposto (m=6000)	LOFAR (elasticnet)	63.83 ± 1.91	65.47 ± 1.91
SVM Híbrido (C=0.5)	HYBRID	65.16 ± 1.67	65.77 ± 1.67

Destaque: O SVM Mel equivale à CNN Mel com metade da variância ($\sigma_{SVM} = 1.18\%$ vs. 2.09%). Os modelos de **Fusão Híbrida** (MLP: 66.13% SP, SVM: 65.16% SP) unem a força de banda larga e banda estreita com excelente estabilidade inter-fold.



A Limitação Física do Alvo SMALL

Entendimento Físico-Acústico do Problema

Embarcações de pequeno porte (SMALL) produzem assinaturas de baixíssima potência e carecem das clássicas raias harmônicas discretas abaixo de 1000Hz (que compõem a maior parte das energias do LOFAR).

Fatores de Degradação:

- ▶ **Ruído Difuso de Banda Larga:** A assinatura acústica assemelha-se ao mar aberto e vento, gerando forte confusão espectral com a classe **BACKGROUND** (alta entropia de Shannon).
- ▶ **A Sabedoria Geométrica da Rejeição:** A opção de rejeição temporal atua descartando sabiamente **92.64%** de todas as janelas acústicas do SMALL. Isso evita sobrecarregar o operador de sonar com falsas classificações e alarmes inconsistentes.



Trajetória de Escalonamento (Hiperparâmetros)



Sintonia de Kernel e Complexidade (m)

A Relação entre Componentes de Nyström (m) e Desempenho

O escalonamento logarítmico de $m = 300$ até $m = 4000$ revela a evolução da modelagem matemática das fronteiras de decisão complexas das classes acústicas.

- ▶ **Fase Inicial ($m = 300$):** Acurácia modesta de $61.02\% \pm 1.94\%$ (MEL). O espaço projetado carece de representação para as frequências não-lineares.
- ▶ **Fase Intermediária ($m = 1000$ a 3000):** Aumento contínuo da representatividade. O modelo captura transições espectrais importantes de motores.
- ▶ **Golden Scale ($m = 4000$):**
 - ▶ **Golden MEL:** $64.56\% \pm 1.18\%$ (sem PCA) – estabilidade com variância reduzida.
 - ▶ **Golden LOFAR:** $64.04\% \pm 1.88\%$ (com PCA64) – excepcional para generalização e filtragem temporal.



Conclusões e Próximos Passos



Conclusões do Trabalho

Como resultado da avaliação e benchmarking do SVM Gaussiano com Nyström na base de dados de grande escala IARA, conclui-se que:

- ▶ **SVM Nyström:** Estimador altamente robusto e estável, entregando desempenho equivalente a redes convolucionais profundas (CNN) com metade do desvio padrão fold-wise (menor sensibilidade a variações de partição).
- ▶ **Opção de Rejeição:** Essencial para a viabilidade tática prática, permitindo elevar a precisão global de teste para **90,43%** nos alvos classificados com alto limiar de consenso ($t \geq 0.9$).
- ▶ **Dualidade do PCA:** Revelou-se benéfico como filtro passa-faixa estatístico no LOFAR (limpeza de ruído), mas prejudicial no MEL (onde degrada a separabilidade não-linear já integrada).



Trabalhos Futuros (Foco no Alvo SMALL)

Com o objetivo de refinar as margens de decisão e mitigar os erros de classificação no alvo mais difícil (**SMALL**), propõem-se os seguintes passos:

- ▶ **Estratégia Híbrida de Dois Estágios:** Classificação hierárquica dividida em duas etapas (Etapa 1: separação binária de BACKGROUND/Navio; Etapa 2: classificação multiclasse de SMALL vs. MEDIUM/LARGE).
- ▶ **Modelo Híbrido Avançado:** Fusão espectral completa concatenando a banda estreita fina (LOFAR) com a banda larga integradora (MEL) na entrada.
- ▶ **Landmarks via MiniBatchKMeans:** Substituição da amostragem aleatória do Nyström por centroides obtidos via clustering. Otimiza a representatividade espacial, reduzindo a dimensão m (RAM) sem perdas de acurácia.



Referências I



Silva, F. O. B. da, Fernandes, J. C. V., Soares Filho, W., Souza Filho, J. B. O. e, Spengler, A. & Moura Júnior, N. N. (2025). IARA: An Underwater Acoustic Database. *IEEE Access*, Vol. 13, doi: 10.1109/ACCESS.2025.3585467.



Santos-Domínguez, D., Torres-Guijarro, S., Cardenal-Martín, J. & Pena-Gimenez, A. (2016). ShipsEar: An underwater vessel noise database. *Applied Acoustics*, 113, 64-69.



Irfan, M., Jiang, Z., Ali, S., et al. (2021). DeepShip: An underwater acoustic threshold-based database for ship classification. *Scientific Reports*, 11, 23005.



Williams, C. K. I. & Seeger, M. (2001). Using the Nyström method to speed up algorithms on kernel matrices. *Advances in Neural Information Processing Systems (NeurIPS)*.



Chow, C. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41-46.



Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.



Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.



LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.



Hummel, H. I., van der Mei, R. & Bhulai, S. (2024). A survey on machine learning in ship radiated noise. *Ocean Engineering*, Vol. 298, Art. 117252.



Referências II



Fernandes, J. C. V., Moura Júnior, N. N. de & Seixas, J. M. de (2022). Deep learning models for passive sonar signal classification of military data. *Remote Sensing*, Vol. 14, No. 11, p. 2648.



Nielsen, P. A. (1994). A comparison of three estimators for the background noise level in lofargrams. *IEEE Journal of Oceanic Engineering*, 19(1), 106-110.



Zhou, A., et al. (2023). A novel cross-attention fusion-based joint training framework for robust underwater acoustic signal recognition. *IEEE Transactions on Geoscience and Remote Sensing*, Vol. 61, Art. 4209516.