Classificação Acústica Submarina Passiva em Base de Dados de Grande Porte: Estudo de Caso no Dataset IARA com SVM Gaussiano via Aproximação de Nyström

Evandro Rocha

Universidade Federal do Rio de Janeiro — UFRJ/COPPE/PEE

evandro.rocha@coppe.ufrj.br

Junho de 2026

Resumo

Este trabalho propõe e avalia o uso de *Support Vector Machines* (SVM) com kernel Gaussiano (RBF) aproximado pela técnica de Nyström para a classificação acústica submarina passiva na base de dados de grande escala IARA (*Silva et al.*, 2025). O dataset IARA, com 129 horas e 34 minutos de gravações reais de tráfego marítimo na Bacia de Santos, representa um dos maiores repositórios públicos de acústica submarina do mundo. O modelo proposto é comparado diretamente com a MLP — baseline de melhor desempenho do artigo de referência —, utilizando o protocolo de validação cruzada 5×2cv com isolamento de navios. Dois extratores espectrais são avaliados: espectrograma Mel (MEL, 256 bandas) e análise de banda estreita LOFAR (1024 bins). Os resultados demonstram que o SVM Nyström é uma alternativa competitiva e estável à MLP, com menor variância fold-wise e vantagem na classe minoritária SMALL — o alvo de maior dificuldade acústica. A aproximação de Nyström viabiliza o treinamento em escala massiva, reduzindo o custo de memória de terabytes para grandezas compatíveis com hardware de pesquisa convencional.

Palavras-chave: SVM, Nyström, LOFAR, MEL, classificação acústica, sonar passivo, IARA.

1. Introdução

A classificação acústica de alvos submarinos (UATR — *Underwater Acoustic Target Recognition*) consiste em identificar embarcações a partir de suas assinaturas acústicas irradiadas pelo meio aquático, sem qualquer auxílio visual ou de radar. Trata-se de uma tarefa com aplicações diretas em monitoramento de tráfego naval, soberania nacional e preservação ambiental.

O problema é intrinsecamente difícil: o canal acústico submarino sofre atenuação variável com temperatura, salinidade e densidade; efeitos de *multipath* (reflexões no fundo e na superfície do oceano) distorcem as assinaturas; e ruído ambiental de origem biológica e meteorológica compete com o sinal de interesse. Agravando o cenário, a literatura da área opera predominantemente com bases de dados fechadas ou de pequeno porte, dificultando a reprodutibilidade e a comparação justa entre modelos.

O dataset IARA [1], publicado em 2025 na IEEE Access, representa um avanço significativo neste contexto: é uma base pública com 129h 34min de gravações reais de tráfego marítimo na Bacia de Santos, capturadas por gliders oceânicos e observatórios submarinos fixos no âmbito do Projeto de Monitoramento da Paisagem Acústica Submarina da Bacia de Santos (PMPAS-BS) da Petrobras. Os autores estabeleceram baselines com Random Forest, MLP e CNN, sendo a MLP LOFAR o modelo de melhor desempenho (Acurácia Balanceada: $67{,}48\% \pm 1{,}24\%$).

O SVM com kernel RBF é um classificador clássico consolidado em UATR, com aplicações documentadas em bases como ShipsEar [2] e DeepShip [3]. Contudo, o custo computacional do SVM clássico — $O(N^3)$ e memória $O(N^2)$ — inviabiliza sua aplicação direta ao IARA: para $N \approx 500.000$ janelas espectrais (MEL), a matriz de kernel exigiria aproximadamente 1 TB de RAM.

Este trabalho investiga se o SVM com aproximação de Nyström [4] — que reduz o custo para $O(N \cdot m^2)$ selecionando m landmarks — constitui uma alternativa viável, competitiva e estável frente à MLP na base IARA.

2. Base de Dados e Curadoria

2.1. Dataset IARA

O dataset IARA contém 1.825 áudios contínuos de 2 a 5 minutos, totalizando ≈50 GB de gravações. Duas plataformas de captura foram utilizadas: *gliders* oceânicos autônomos (taxa de 125 kHz, até 1000 m de profundidade) e observatórios submarinos fixos em regiões costeiras (taxa de 48 kHz, 19–28 m de profundidade). Para comparação de escala: a base ShipsEar possui 3h 9min e a DeepShip, 47h 4min.

2.2. Curadoria e Isolamento de Alvos

Para garantir que cada gravação corresponda unicamente ao navio-alvo, os autores adotaram filtragem espacial baseada em dados AIS (*Automatic Identification System*): um áudio é incluído apenas se o navio-alvo estiver dentro de distância máxima do sensor (500 m para observatórios costeiros; 10 km para gliders) e não houver outros navios dentro de um raio de exclusão (2 km e 30 km, respectivamente). Cada gravação passou por análise espectral, cruzamento de dados AIS em múltiplos bancos e revisão manual humana.

2.3. Mapeamento de Classes

Os metadados AIS fornecem o comprimento físico exato de cada embarcação. O artigo de referência propõe um mapeamento de quatro classes baseado no comprimento — alinhado com os limiares do ShipsEar:

- **SMALL**: comprimento < 50 m (embarcações pequenas, baixo SNR);
- **MEDIUM**: $50 \leq$ comprimento < 100 m;
- **LARGE**: comprimento ≥ 100 m (navios de grande porte);
- **BACKGROUND**: ausência de navio (ruído oceânico ambiental).

O dataset apresenta desbalanceamento de classes, com predominância de LARGE e BACKGROUND. A classe SMALL, minoritária e acusticamente mais fraca, constitui o principal desafio aberto do problema.

3. Extração de Características Espectrais

3.1. Representações Espectrais

O sinal bruto de sonar é convertido para o domínio tempo-frequência via STFT. Dois extratores são avaliados:

MEL: banco de 256 filtros triangulares em escala logarítmica (Mel), que captura o envelope de banda larga — ruído de cavitação do hélice e ruído hidrodinâmico. Produz janelas de 0,512 s, resultando em ≈500.000 janelas por corpus completo.

LOFAR: espectro de banda estreita com 1024 bins de frequência linear, padrão histórico de sonar passivo naval. Resolve raias harmônicas finas emitidas por motores rotativos, eixos e engrenagens. Usa janelas de ≈0,058 s (alta sobreposição temporal), produzindo ≈800.000 janelas por corpus.

Os dois extratores capturam fenômenos físicos distintos e complementares: MEL privilegia energia integrada de banda larga; LOFAR privilegia estrutura discreta de harmônicas.

3.2. Normalização Espectral

Ambos os extratores incorporam normalização para mitigar variações de amplitude causadas pelo canal acústico (distância, atenuação, ganho do sensor):

Normalização L2 (MEL): cada janela é dividida por sua norma euclidiana:

$$\bar{x} = \frac{x}{\|x\|_2} \tag{1}$$

O classificador avalia apenas a forma da distribuição de energia, não o volume absoluto.

Filtro TPSW (LOFAR): o algoritmo *Two-Pass Split Window* [6] estima o patamar local de ruído oceânico contínuo e o subtrai, realçando automaticamente as raias harmônicas. Equivale a um branqueamento espectral local adaptativo.

4. Baseline: MLP de Referência (Silva et al., 2025)

O artigo de referência estabelece três baselines — RF, MLP e CNN — avaliados em MEL e LOFAR. A MLP foi o melhor modelo. Sua arquitetura para ambas as variantes consiste em:

Camada	**MLP MEL**	**MLP LOFAR**
Entrada	256 features	1024 features
FC + BN + ReLU	32 neurônios	32 neurônios
Dropout	$p = 0{,}2$	— (sem dropout)
FC + BN + ReLU	16 neurônios	16 neurônios
Dropout	$p = 0{,}2$	— (sem dropout)
Saída	Sigmoid (4 classes)	Sigmoid (4 classes)

Protocolo de treinamento: Adam ($\eta = 10^{-4}$, *weight decay* $= 10^{-3}$), CrossEntropyLoss, *batch* $= 32$, *early stopping* com paciência de 8 épocas (máximo 50). Este trabalho reproduziu o experimento localmente e confirmou compatibilidade: MLP LOFAR reproduzida obteve SP $66{,}25\% \pm 1{,}78\%$ e Ac. Bal. $67{,}21\% \pm 1{,}65\%$, diferença inferior a 0,3 p.p. do artigo.

5. Método Proposto: SVM com Aproximação de Nyström

5.1. Motivação e Escalabilidade

O SVM com kernel RBF resolve o problema de classificação em um espaço de alta dimensão implícito definido pela função de kernel $k(x_i, x_j) = \exp(-\gamma\|x_i - x_j\|^2)$. Para o IARA com $N \approx 500.000$ janelas (MEL), a matriz de kernel $N \times N$ exigiria:

$$500.000 \times 500.000 \times 4\,\text{bytes} = 1\,\text{TB de RAM} \tag{2}$$

Este custo é proibitivo. A complexidade de tempo $O(N^3)$ do SVM dual é igualmente inviável.

5.2. Aproximação de Nyström

A aproximação de Nyström [4] seleciona $m \ll N$ amostras de referência (landmarks) do conjunto de treino. Cada amostra x é projetada para um vetor m-dimensional:

$$\phi(x) = K(x, L)\, K_{LL}^{-1/2} \in \mathbb{R}^m \tag{3}$$

onde $L \in \mathbb{R}^{m \times d}$ é a matriz de landmarks e K_{LL} é a submatriz de kernel entre os landmarks. Esta projeção aproxima implicitamente o espaço de características do kernel RBF.

Custo de memória: a base de treinamento projetada ($N \times m$ floats) domina o consumo. Para MEL com $m = 4000$: $500.000 \times 4.000 \times 4\,\text{B} \approx 8\,\text{GB}$ — viável em hardware de pesquisa.

Custo de tempo: reduzido de $O(N^3)$ para $O(N \cdot m^2)$, permitindo treinamento via classificador linear com SGD (*hinge loss*, equivalente ao SVM primal). O modelo final armazena apenas o vetor de pesos ($4 \times m$ floats $< 100\,\text{KB}$).

5.3. Seleção de Landmarks

Os m landmarks são selecionados por amostragem uniforme aleatória das janelas de treino. Testou-se também seleção via centroides MiniBatchKMeans — esperando-se melhor cobertura do espaço de características — mas os resultados foram equivalentes à amostragem aleatória, sem justificar o custo adicional de clustering.

5.4. Decisão por Votação Temporal

O modelo classifica cada janela espectral individualmente. O rótulo final de cada arquivo de áudio é determinado por votação por consenso temporal: a classe com maior frequência de predição entre todas as janelas do áudio.

5.5. Regularização ElasticNet

O classificador linear SGD incorpora regularização ElasticNet — combinação de ℓ_1 e ℓ_2:

$$\mathcal{L} = \text{HingeLoss} + \alpha \left[\frac{1-\rho}{2} \|w\|_2^2 + \rho \|w\|_1 \right] \tag{4}$$

onde ρ é a razão ℓ_1/ℓ_2 (padrão: $\rho = 0{,}15$). Isso permite esparsidade controlada nos pesos sem degradar a capacidade de generalização.

6. Protocolo Experimental

6.1. Validação Cruzada 5×2cv

Adotou-se o protocolo 5×2cv [5]: em cada uma das 5 repetições, o dataset é dividido em duas metades (A e B), treinando-se em A e testando em B, depois invertendo. Totalizam-se 10 folds independentes.

Partição por gravação: como no artigo, a partição é feita pelo identificador da gravação (`ID`, `exclusive_header='ID'`): as janelas de uma mesma gravação nunca aparecem simultaneamente em treino e teste, o que evita o vazamento entre janelas vizinhas. A partição **não** isola navios: o mesmo navio (`Ship ID`) pode ter gravações diferentes em treino e teste — 63,5% das gravações de navio no teste têm o mesmo navio no treino. Os resultados medem, portanto, a generalização para **gravações** inéditas, e não necessariamente para navios inéditos.

6.2. Métricas de Avaliação

Índice SP (métrica principal): média geométrica e aritmética combinada dos recalls por classe:

$$SP = \sqrt[K]{\prod_{k=1}^{K} Recall_k} \tag{5}$$

Para $K = 4$ classes. Se qualquer $Recall_k = 0$, então $SP = 0$. Penaliza duramente falhas em qualquer classe, especialmente minorias.

Acurácia Balanceada (ACC): média aritmética dos recalls por classe — equivale à acurácia balanceada implementada em `iara.ml.metrics.Metric.BALANCED_ACCURACY`.

F1-Score Macro: média dos F1 por classe, incorporando precisão além do recall.

7. Ajuste de Hiperparâmetros

7.1. Número de Landmarks (m)

O hiperparâmetro mais impactante é m. A Tabela 1 resume a curva de desempenho do SVM ao escalar m de 300 a 6000.

Observa-se que na fase intermediária ($m = 1000$–3000), o MEL supera o LOFAR consistentemente — a representação de banda larga se beneficia mais rapidamente do aumento de landmarks. O MEL estabiliza em $m = 4000$ com variância reduzida ($\sigma = 1{,}12\%$). O LOFAR, por operar em espaço de maior dimensionalidade (1024 features), exige mais pontos de referência para aproximar as raias harmônicas finas, continuando a melhorar até $m = 6000$.

Tabela 1: Desempenho do SVM em função do número de landmarks m.

m	Espectro	SP (%)	Ac. Bal. (%)
300	MEL	$59{,}96 \pm 3{,}38$	$62{,}34 \pm 1{,}98$
1000	MEL	$62{,}96 \pm 2{,}08$	$64{,}11 \pm 1{,}98$
2000	MEL	$63{,}04 \pm 2{,}37$	$64{,}45 \pm 1{,}93$
3000	MEL	$63{,}65 \pm 1{,}99$	$64{,}77 \pm 1{,}87$
4000	**MEL**	$\mathbf{63{,}80 \pm 1{,}12}$	$\mathbf{64{,}58 \pm 1{,}14}$
1000	LOFAR	$57{,}86 \pm 3{,}83$	$60{,}95 \pm 2{,}89$
2000	LOFAR	$60{,}10 \pm 2{,}25$	$62{,}54 \pm 1{,}98$
4000	LOFAR	$61{,}70 \pm 3{,}67$	$63{,}55 \pm 2{,}91$
6000	**LOFAR**	$\mathbf{63{,}84 \pm 1{,}91}$	$\mathbf{65{,}48 \pm 1{,}76}$

7.2. Penalidade C, Largura γ e Regularização ElasticNet

Variações nos demais hiperparâmetros não produziram ganhos sobre os valores padrão:

- **Penalidade** C: $C = 0{,}5$ (MEL) reduz SP para 57,5%; $C = 2{,}0$ alcança 63,8% — ganho de $< 0{,}1$ p.p. sobre $C = 1$. Para LOFAR, $C = 0{,}1$ derruba SP para 54,8%; $C = 2{,}0$ é praticamente idêntico ao padrão.
- **Largura** γ: o padrão `sklearn` ($\gamma = 1/d$) mostrou-se ótimo. Variações reduziram a separabilidade em ambos os espectros.
- **Razão ElasticNet** (ℓ_1/ℓ_2): ajustes na proporção não trouxeram ganhos sobre $\rho = 0{,}15$.
- **Landmarks MiniBatchKMeans**: centroides de clustering como landmarks produziram resultados equivalentes à amostragem aleatória; o custo de clustering não se justificou.

A conclusão é direta: **o ganho de desempenho veio exclusivamente do aumento de** m.

8. Resultados

8.1. Comparação Global: SVM vs. Baselines

A Tabela 2 consolida os resultados dos melhores modelos.

Observações principais:

- A reprodução da MLP LOFAR confirma o protocolo: diferença $< 0{,}3$ p.p. em todas as métricas.

Tabela 2: Benchmarking dos melhores modelos — protocolo 5 × 2cv.

Origem	Modelo / Espectro	SP (%)	Ac. Bal. (%)	F1 Macro (%)
Artigo [1]	RF / MEL	$62{,}22 \pm 1{,}86$	$62{,}64 \pm 1{,}84$	$63{,}79 \pm 1{,}73$
	RF / LOFAR	$56{,}92 \pm 1{,}69$	$58{,}87 \pm 1{,}68$	$58{,}00 \pm 1{,}41$
	MLP / MEL	$63{,}38 \pm 1{,}81$	$64{,}51 \pm 1{,}75$	$62{,}89 \pm 1{,}68$
	MLP / LOFAR	$\mathbf{66{,}51 \pm 1{,}39}$	$\mathbf{67{,}48 \pm 1{,}24}$	$\mathbf{66{,}72 \pm 1{,}17}$
Reproduzido	MLP / MEL	$64{,}66 \pm 2{,}11$	$65{,}64 \pm 1{,}96$	$64{,}12 \pm 2{,}19$
	MLP / LOFAR	$66{,}25 \pm 1{,}78$	$67{,}21 \pm 1{,}65$	$66{,}44 \pm 1{,}88$
Proposto	**SVM (m=4000) / MEL**	$\mathbf{63{,}80 \pm 1{,}12}$	$\mathbf{64{,}58 \pm 1{,}14}$	$\mathbf{64{,}36 \pm 1{,}05}$
	SVM (m=6000) / LOFAR	$\mathbf{63{,}84 \pm 1{,}91}$	$\mathbf{65{,}48 \pm 1{,}76}$	$\mathbf{63{,}60 \pm 1{,}71}$

- O SVM MEL alcança SP equivalente ao MLP MEL (63,80% vs. 63,38%) com variância 38% menor ($\sigma = 1{,}12\%$ vs. $1{,}81\%$).
- O SVM LOFAR fica a apenas **2,67 p.p.** do MLP LOFAR em SP, sem uso de PCA.
- O RF LOFAR (SP 56,92%) é o baseline mais fraco, confirmando a limitação de florestas aleatórias em espaços de alta dimensionalidade como o LOFAR.

8.2. Análise de Erros: Matrizes de Confusão

A Tabela 3 apresenta as matrizes de confusão por modelo (percentual por linha = recall por classe). Os valores são acumulados sobre os 10 folds do protocolo 5 × 2cv, na avaliação por navio (votação majoritária).

Tabela 3: Matrizes de confusão por modelo (%). Verde: recall $\geq 60\%$; Amarelo: 40%–59%; Vermelho: $< 40\%$ ou erro off-diagonal $> 22\%$.

(a) MLP LOFAR (Melhor Baseline)

	S	M	L	BG
SMALL	46,6	21,2	25,3	7,0
MEDIUM	22,6	61,3	13,8	2,3
LARGE	12,8	10,0	74,7	2,5
BG	7,3	3,8	2,6	86,3

(b) SVM MEL (m=4000, Proposto)

	S	M	L	BG
SMALL	50,9	24,3	17,6	7,2
MEDIUM	26,0	60,4	12,5	1,1
LARGE	14,9	13,6	69,2	2,3
BG	11,0	4,9	6,2	77,9

(c) SVM LOFAR (m=6000, Proposto)

	S	M	L	BG
SMALL	38,2	22,9	28,6	10,3
MEDIUM	17,6	60,5	17,2	4,8
LARGE	9,3	10,8	76,3	3,6
BG	6,1	2,8	4,2	86,9

(d) MLP MEL (Baseline)

	S	M	L	BG
SMALL	44,8	25,4	17,9	11,8
MEDIUM	20,4	64,0	13,1	2,5
LARGE	12,9	15,0	68,6	3,6
BG	6,1	3,8	5,0	85,1

A análise das matrizes revela padrões de erro distintos e complementares entre os espectros:

- **SMALL é o alvo crítico**: o melhor recall individual é do SVM MEL (50,9%), superando o MLP LOFAR (46,6%), o MLP MEL (44,8%) e o SVM LOFAR (38,2%).
- **Padrão de confusão LOFAR**: modelos LOFAR (MLP e SVM) confundem SMALL com LARGE (respectivamente 25,3% e 28,6% de erro SMALL→LARGE). Fisicamente, raias harmônicas de embarcações pequenas podem assemelhar-se às de grandes navios a certas distâncias.
- **Padrão de confusão MEL**: modelos MEL confundem SMALL com MEDIUM (respectivamente 25,4% e 24,3% de erro SMALL→MEDIUM), pois a energia de banda larga integrada de ambas as classes se sobrepõe.
- **LARGE e BACKGROUND**: bem classificados por todos os modelos. BG varia de 77,9% (SVM MEL) a 86,9% (SVM LOFAR). LARGE de 68,6% (MLP MEL) a 76,3% (SVM LOFAR).
- **Complementaridade MEL/LOFAR**: os padrões de erro opostos sugerem que MEL e LOFAR capturam informações complementares — motivando estratégias de fusão como trabalho futuro.

8.3. Análise Estatística da Variância

O desvio padrão fold-wise é uma medida da estabilidade do modelo às variações de partição. O SVM MEL apresenta $\sigma_{SP} = 1{,}12\%$ frente a 1,81% do MLP MEL — redução de **38%**. Isso indica que o SVM Nyström é menos sensível à escolha de quais navios compõem cada fold, propriedade importante para implantação operacional. O SVM LOFAR apresenta $\sigma_{SP} = 1{,}91\%$, levemente superior ao MLP LOFAR (1,39%), mas ambos dentro de margem compatível com diferenças estatisticamente não significativas.

9. Conclusões

Este trabalho demonstrou que o SVM Gaussiano com aproximação de Nyström constitui uma alternativa competitiva, estável e computacionalmente viável à MLP para classificação acústica submarina no dataset IARA. Três conclusões principais emergem:

1. **Competitividade com variância reduzida**: O SVM LOFAR ($m = 6000$) alcança SP 63,84% e Ac. Bal. 65,48%, a apenas 2,67 p.p. do MLP LOFAR — o melhor baseline do artigo — com desvio padrão comparável. O SVM MEL iguala o MLP MEL em SP com variância 38% menor.
2. **Superioridade no alvo crítico SMALL**: O SVM MEL é o modelo com maior recall para SMALL (50,9%), superando todos os baselines neurais — incluindo

o MLP LOFAR (46,6%). Em aplicações onde a classe minoritária é a de maior relevância tática, o SVM MEL é a escolha mais adequada.

3. **Complementaridade MEL/LOFAR**: LOFAR maximiza LARGE/BG por capturar raias harmônicas discretas; MEL favorece SMALL pela integração energética de banda larga. Os padrões de erro opostos confirmam que as duas representações são complementares.

Do ponto de vista computacional, a aproximação de Nyström reduziu o problema de 1 TB de RAM para ≈8 GB (MEL) e ≈15 GB (LOFAR), com modelo final de <100 KB — viável para implantação embarcada em sistemas de sonar passivo.

10. Trabalhos Futuros

1. **Estratégia Híbrida de Dois Estágios**: Classificação hierárquica com especialistas para as classes de menor recall (SMALL e MEDIUM), combinando as forças complementares de LOFAR e MEL. Resultados preliminares são promissores.

2. **Exploração de Novas Técnicas de Extração de Características**: Avaliar DEMON (*Detection of Envelope Modulation on Noise*) — que captura a modulação de amplitude das pás do hélice — e MFCC (coeficientes cepstrais Mel), que capturam fenômenos físicos distintos de LOFAR e MEL, potencialmente beneficiando o alvo SMALL.

3. **Modelos com Dinâmica Temporal**: Avaliar arquiteturas recorrentes como GRU e LSTM, que processam a sequência de frames espectrais ao longo do tempo. O SVM, ao agregar o áudio em um vetor fixo por votação, descarta padrões temporais como os ciclos do hélice e os ritmos de maquinário que distinguem o tamanho dos navios.

Referências

[1] Silva, F. O. B. da, Fernandes, J. C. V., Soares Filho, W., Souza Filho, J. B. O. e, Spengler, A. & Moura Júnior, N. N. (2025). IARA: An Underwater Acoustic Database. *IEEE Access*, Vol. 13, doi: 10.1109/ACCESS.2025.3585467.

[2] Santos-Domínguez, D., Torres-Guijarro, S., Cardenal-Martín, J. & Pena-Gimenez, A. (2016). ShipsEar: An underwater vessel noise database. *Applied Acoustics*, 113, 64–69.

[3] Irfan, M., Jiang, Z., Ali, S., et al. (2021). DeepShip: An underwater acoustic threshold-based database for ship classification. *Scientific Reports*, 11, 23005.

[4] Williams, C. K. I. & Seeger, M. (2001). Using the Nyström method to speed up algorithms on kernel matrices. *Advances in Neural Information Processing Systems (NeurIPS)*.

[5] Alpaydın, E. (1999). Combined 5×2 cv F test for comparing supervised classification learning algorithms. *Neural Computation*, 11(8), 1885–1892.

[6] Nielsen, P. A. (1994). A comparison of three estimators for the background noise level in lofargrams. *IEEE Journal of Oceanic Engineering*, 19(1), 106–110.

[7] Hummel, H. I., van der Mei, R. & Bhulai, S. (2024). A survey on machine learning in ship radiated noise. *Ocean Engineering*, Vol. 298, Art. 117252.

[8] Fernandes, J. C. V., Moura Júnior, N. N. de & Seixas, J. M. de (2022). Deep learning models for passive sonar signal classification of military data. *Remote Sensing*, Vol. 14, No. 11, p. 2648.