

Classificação Acústica Submarina Passiva em Base de Dados de Grande Porte: Estudo de Caso no Dataset IARA com SVM Gaussiano via Aproximação de Nyström

Evandro Rocha

Universidade Federal do Rio de Janeiro — UFRJ/COPPE/PEE

`evandro.rocha@coppe.ufrj.br`

Junho de 2026

Resumo

Este trabalho propõe e avalia o uso de *Support Vector Machines* (SVM) com kernel Gaussiano (RBF) aproximado pela técnica de Nyström para a classificação acústica submarina passiva na base de dados de grande escala IARA (*Silva et al.*, 2025). O dataset IARA, com 129 horas e 34 minutos de gravações reais de tráfego marítimo na Baía de Santos, representa um dos maiores repositórios públicos de acústica submarina do mundo. O modelo proposto é comparado diretamente com a MLP — baseline de melhor desempenho do artigo de referência —, utilizando o protocolo de validação cruzada $5 \times 2cv$ com isolamento de navios. Dois extratores espectrais são avaliados: espectrograma Mel (MEL, 256 bandas) e análise de banda estreita LOFAR (1024 bins). Os resultados demonstram que o SVM Nyström é uma alternativa competitiva e estável à MLP, com menor variância fold-wise e vantagem na classe minoritária SMALL — o alvo de maior dificuldade acústica. A aproximação de Nyström viabiliza o treinamento em escala massiva, reduzindo o custo de memória de terabytes para grandezas compatíveis com hardware de pesquisa convencional.

Palavras-chave: SVM, Nyström, LOFAR, MEL, classificação acústica, sonar passivo, IARA.

1. Introdução

A classificação acústica de alvos submarinos (UATR — *Underwater Acoustic Target Recognition*) consiste em identificar embarcações a partir de suas assinaturas acústicas irradiadas pelo meio aquático, sem qualquer auxílio visual ou de radar. Trata-se de uma tarefa com aplicações diretas em monitoramento de tráfego naval, soberania nacional e preservação ambiental.

O problema é intrinsecamente difícil: o canal acústico submarino sofre atenuação variável com temperatura, salinidade e densidade; efeitos de *multipath* (reflexões no fundo e na superfície do oceano) distorcem as assinaturas; e ruído ambiental de origem biológica e meteorológica compete com o sinal de interesse. Agravando o cenário, a literatura da área opera predominantemente com bases de dados fechadas ou de pequeno porte, dificultando a reprodutibilidade e a comparação justa entre modelos.

O dataset IARA [1], publicado em 2025 na IEEE Access, representa um avanço significativo neste contexto: é uma base pública com 129h 34min de gravações reais de tráfego marítimo na Baía de Santos, capturadas por gliders oceânicos e observatórios submarinos fixos no âmbito do Projeto de Monitoramento da Paisagem Acústica Submarina da Baía de Santos (PMPAS-BS) da Petrobras. Os autores estabeleceram baselines com Random Forest, MLP e CNN, sendo a MLP LOFAR o modelo de melhor desempenho (Acurácia Balanceada: $67,48\% \pm 1,24\%$).

O SVM com kernel RBF é um classificador clássico consolidado em UATR, com aplicações documentadas em bases como ShipsEar [2] e DeepShip [3]. Contudo, o custo computacional do SVM clássico — $O(N^3)$ e memória $O(N^2)$ — inviabiliza sua aplicação direta ao IARA: para $N \approx 500.000$ janelas espectrais (MEL), a matriz de kernel exigiria aproximadamente 1 TB de RAM.

Este trabalho investiga se o SVM com aproximação de Nyström [4] — que reduz o custo para $O(N \cdot m^2)$ selecionando m landmarks — constitui uma alternativa viável, competitiva e estável frente à MLP na base IARA.

2. Base de Dados e Curadoria

2.1. Dataset IARA

O dataset IARA contém 1.825 áudios contínuos de 2 a 5 minutos, totalizando ≈ 50 GB de gravações. Duas plataformas de captura foram utilizadas: *gliders* oceânicos autônomos (taxa de 125 kHz, até 1000 m de profundidade) e observatórios submarinos fixos em regiões costeiras (taxa de 48 kHz, 19–28 m de profundidade). Para comparação de escala: a base ShipsEar possui 3h 9min e a DeepShip, 47h 4min.

2.2. Curadoria e Isolamento de Alvos

Para garantir que cada gravação corresponda unicamente ao navio-alvo, os autores adotaram filtragem espacial baseada em dados AIS (*Automatic Identification System*): um áudio é incluído apenas se o navio-alvo estiver dentro de distância máxima do sensor (500 m para observatórios costeiros; 10 km para gliders) e não houver outros navios dentro de um raio de exclusão (2 km e 30 km, respectivamente). Cada gravação passou por análise espectral, cruzamento de dados AIS em múltiplos bancos e revisão manual humana.

2.3. Mapeamento de Classes

Os metadados AIS fornecem o comprimento físico exato de cada embarcação. O artigo de referência propõe um mapeamento de quatro classes baseado no comprimento — alinhado com os limiares do ShipsEar:

- **SMALL**: comprimento < 50 m (embarcações pequenas, baixo SNR);
- **MEDIUM**: $50 \leq$ comprimento < 100 m;
- **LARGE**: comprimento ≥ 100 m (navios de grande porte);
- **BACKGROUND**: ausência de navio (ruído oceânico ambiental).

O dataset apresenta desbalanceamento de classes, com predominância de LARGE e BACKGROUND. A classe SMALL, minoritária e acusticamente mais fraca, constitui o principal desafio aberto do problema.

3. Extração de Características Espectrais

3.1. Representações Espectrais

O sinal bruto de sonar é convertido para o domínio tempo-frequência via STFT. Dois extratores são avaliados:

MEL: banco de 256 filtros triangulares em escala logarítmica (Mel), que captura o envelope de banda larga — ruído de cavitação do hélice e ruído hidrodinâmico. Produz janelas de 0,512 s, resultando em ≈ 500.000 janelas por corpus completo.

LOFAR: espectro de banda estreita com 1024 bins de frequência linear, padrão histórico de sonar passivo naval. Resolve raias harmônicas finas emitidas por motores rotativos, eixos e engrenagens. Usa janelas de $\approx 0,058$ s (alta sobreposição temporal), produzindo ≈ 800.000 janelas por corpus.

Os dois extratores capturam fenômenos físicos distintos e complementares: MEL privilegia energia integrada de banda larga; LOFAR privilegia estrutura discreta de harmônicas.

3.2. Normalização Espectral

Ambos os extratores incorporam normalização para mitigar variações de amplitude causadas pelo canal acústico (distância, atenuação, ganho do sensor):

Normalização L2 (MEL): cada janela é dividida por sua norma euclidiana:

$$\bar{x} = \frac{x}{\|x\|_2} \quad (1)$$

O classificador avalia apenas a forma da distribuição de energia, não o volume absoluto.

Filtro TPSW (LOFAR): o algoritmo *Two-Pass Split Window* [6] estima o patamar local de ruído oceânico contínuo e o subtrai, realçando automaticamente as raiais harmônicas. Equivale a um branqueamento espectral local adaptativo.

4. Baseline: MLP de Referência (Silva et al., 2025)

O artigo de referência estabelece três baselines — RF, MLP e CNN — avaliados em MEL e LOFAR. A MLP foi o melhor modelo. Sua arquitetura para ambas as variantes consiste em:

Camada	MLP MEL	MLP LOFAR
Entrada	256 features	1024 features
FC + BN + ReLU	32 neurônios	32 neurônios
Dropout	$p = 0,2$	— (sem dropout)
FC + BN + ReLU	16 neurônios	16 neurônios
Dropout	$p = 0,2$	— (sem dropout)
Saída	Sigmoid (4 classes)	Sigmoid (4 classes)

Protocolo de treinamento: Adam ($\eta = 10^{-4}$, *weight decay* = 10^{-3}), CrossEntropy-Loss, *batch* = 32, *early stopping* com paciência de 8 épocas (máximo 50). Este trabalho reproduziu o experimento localmente e confirmou compatibilidade: MLP LOFAR reproduzida obteve SP $66,25\% \pm 1,78\%$ e Ac. Bal. $67,21\% \pm 1,65\%$, diferença inferior a 0,3 p.p. do artigo.

5. Método Proposto: SVM com Aproximação de Nyström

5.1. Motivação e Escalabilidade

O SVM com kernel RBF resolve o problema de classificação em um espaço de alta dimensão implícito definido pela função de kernel $k(x_i, x_j) = \exp(-\gamma\|x_i - x_j\|^2)$. Para o IARA com $N \approx 500.000$ janelas (MEL), a matriz de kernel $N \times N$ exigiria:

$$500.000 \times 500.000 \times 4 \text{ bytes} = 1 \text{ TB de RAM} \quad (2)$$

Este custo é proibitivo. A complexidade de tempo $O(N^3)$ do SVM dual é igualmente inviável.

5.2. Aproximação de Nyström

A aproximação de Nyström [4] seleciona $m \ll N$ amostras de referência (landmarks) do conjunto de treino. Cada amostra x é projetada para um vetor m -dimensional:

$$\phi(x) = K(x, L) K_{LL}^{-1/2} \in \mathbb{R}^m \quad (3)$$

onde $L \in \mathbb{R}^{m \times d}$ é a matriz de landmarks e K_{LL} é a submatriz de kernel entre os landmarks. Esta projeção aproxima implicitamente o espaço de características do kernel RBF.

Custo de memória: a base de treinamento projetada ($N \times m$ floats) domina o consumo. Para MEL com $m = 4000$: $500.000 \times 4.000 \times 4 \text{ B} \approx 8 \text{ GB}$ — viável em hardware de pesquisa.

Custo de tempo: reduzido de $O(N^3)$ para $O(N \cdot m^2)$, permitindo treinamento via classificador linear com SGD (*hinge loss*, equivalente ao SVM primal). O modelo final armazena apenas o vetor de pesos ($4 \times m$ floats $< 100 \text{ KB}$).

5.3. Seleção de Landmarks

Os m landmarks são selecionados por amostragem uniforme aleatória das janelas de treino. Testou-se também seleção via centroides MiniBatchKMeans — esperando-se melhor cobertura do espaço de características — mas os resultados foram equivalentes à amostragem aleatória, sem justificar o custo adicional de clustering.

5.4. Decisão por Votação Temporal

O modelo classifica cada janela espectral individualmente. O rótulo final de cada arquivo de áudio é determinado por votação por consenso temporal: a classe com maior frequência de predição entre todas as janelas do áudio.

5.5. Regularização ElasticNet

O classificador linear SGD incorpora regularização ElasticNet — combinação de ℓ_1 e ℓ_2 :

$$\mathcal{L} = \text{HingeLoss} + \alpha \left[\frac{1-\rho}{2} \|w\|_2^2 + \rho \|w\|_1 \right] \quad (4)$$

onde ρ é a razão ℓ_1/ℓ_2 (padrão: $\rho = 0,15$). Isso permite esparsidade controlada nos pesos sem degradar a capacidade de generalização.

6. Protocolo Experimental

6.1. Validação Cruzada $5 \times 2cv$

Adotou-se o protocolo $5 \times 2cv$ [5]: em cada uma das 5 repetições, o dataset é dividido em duas metades (A e B), treinando-se em A e testando em B, depois invertendo. Totalizam-se 10 folds independentes.

Isolamento de navios: a partição é feita por ID físico de navio — o mesmo navio nunca aparece simultaneamente em treino e teste. Isso previne vazamento de dados (*data leakage*) temporal e garante avaliação real de generalização para alvos completamente inéditos.

6.2. Métricas de Avaliação

Índice SP (métrica principal): média geométrica e aritmética combinada dos recalls por classe:

$$SP = \sqrt[K]{\prod_{k=1}^K Recall_k} \quad (5)$$

Para $K = 4$ classes. Se qualquer $Recall_k = 0$, então $SP = 0$. Penaliza duramente falhas em qualquer classe, especialmente minorias.

Acurácia Balanceada (ACC): média aritmética dos recalls por classe — equivale à acurácia balanceada implementada em `iara.ml.metrics.Metric.BALANCED_ACCURACY`.

F1-Score Macro: média dos F1 por classe, incorporando precisão além do recall.

7. Ajuste de Hiperparâmetros

7.1. Número de Landmarks (m)

O hiperparâmetro mais impactante é m . A Tabela 1 resume a curva de desempenho do SVM ao escalar m de 300 a 6000.

Observa-se que na fase intermediária ($m = 1000$ – 3000), o MEL supera o LOFAR consistentemente — a representação de banda larga se beneficia mais rapidamente do aumento de landmarks. O MEL estabiliza em $m = 4000$ com variância reduzida ($\sigma = 1,12\%$). O LOFAR, por operar em espaço de maior dimensionalidade (1024 features), exige mais pontos de referência para aproximar as raias harmônicas finas, continuando a melhorar até $m = 6000$.

7.2. Penalidade C , Largura γ e Regularização ElasticNet

Variações nos demais hiperparâmetros não produziram ganhos sobre os valores padrão:

Tabela 1: Desempenho do SVM em função do número de landmarks m .

m	Espectro	SP (%)	Ac. Bal. (%)
300	MEL	$59,96 \pm 3,38$	$62,34 \pm 1,98$
1000	MEL	$62,96 \pm 2,08$	$64,11 \pm 1,98$
2000	MEL	$63,04 \pm 2,37$	$64,45 \pm 1,93$
3000	MEL	$63,65 \pm 1,99$	$64,77 \pm 1,87$
4000	MEL	$63,80 \pm 1,12$	$64,58 \pm 1,14$
1000	LOFAR	$57,86 \pm 3,83$	$60,95 \pm 2,89$
2000	LOFAR	$60,10 \pm 2,25$	$62,54 \pm 1,98$
4000	LOFAR	$61,70 \pm 3,67$	$63,55 \pm 2,91$
6000	LOFAR	$63,84 \pm 1,91$	$65,48 \pm 1,76$

- **Penalidade C :** $C = 0,5$ (MEL) reduz SP para 57,5%; $C = 2,0$ alcança 63,8% — ganho de $< 0,1$ p.p. sobre $C = 1$. Para LOFAR, $C = 0,1$ derruba SP para 54,8%; $C = 2,0$ é praticamente idêntico ao padrão.
- **Largura γ :** o padrão `sklearn` ($\gamma = 1/d$) mostrou-se ótimo. Variações reduziram a separabilidade em ambos os espectros.
- **Razão ElasticNet (ℓ_1/ℓ_2):** ajustes na proporção não trouxeram ganhos sobre $\rho = 0,15$.
- **Landmarks MiniBatchKMeans:** centroides de clustering como landmarks produziram resultados equivalentes à amostragem aleatória; o custo de clustering não se justificou.

A conclusão é direta: **o ganho de desempenho veio exclusivamente do aumento de m .**

8. Resultados

8.1. Comparação Global: SVM vs. Baselines

A Tabela 2 consolida os resultados dos melhores modelos.

Observações principais:

- A reprodução da MLP LOFAR confirma o protocolo: diferença $< 0,3$ p.p. em todas as métricas.
- O SVM MEL alcança SP equivalente ao MLP MEL (63,80% vs. 63,38%) com variância 38% menor ($\sigma = 1,12\%$ vs. $1,81\%$).
- O SVM LOFAR fica a apenas **2,67 p.p.** do MLP LOFAR em SP, sem uso de PCA.

Tabela 2: Benchmarking dos melhores modelos — protocolo $5 \times 2cv$.

Origem	Modelo / Espectro	SP (%)	Ac. Bal. (%)	F1 Macro (%)
Artigo [1]	RF / MEL	$62,22 \pm 1,86$	$62,64 \pm 1,84$	$63,79 \pm 1,73$
	RF / LOFAR	$56,92 \pm 1,69$	$58,87 \pm 1,68$	$58,00 \pm 1,41$
	MLP / MEL	$63,38 \pm 1,81$	$64,51 \pm 1,75$	$62,89 \pm 1,68$
	MLP / LOFAR	$66,51 \pm 1,39$	$67,48 \pm 1,24$	$66,72 \pm 1,17$
Reproduzido	MLP / MEL	$64,66 \pm 2,11$	$65,64 \pm 1,96$	$64,12 \pm 2,19$
	MLP / LOFAR	$66,25 \pm 1,78$	$67,21 \pm 1,65$	$66,44 \pm 1,88$
Proposto	SVM ($m=4000$) / MEL	$63,80 \pm 1,12$	$64,58 \pm 1,14$	$64,36 \pm 1,05$
	SVM ($m=6000$) / LOFAR	$63,84 \pm 1,91$	$65,48 \pm 1,76$	$63,60 \pm 1,71$

- O RF LOFAR (SP 56,92%) é o baseline mais fraco, confirmando a limitação de florestas aleatórias em espaços de alta dimensionalidade como o LOFAR.

8.2. Análise de Erros: Matrizes de Confusão

A Tabela 3 apresenta as matrizes de confusão por modelo (percentual por linha = recall por classe). Os valores são acumulados sobre os 10 folds do protocolo $5 \times 2cv$, na avaliação por navio (votação majoritária).

Tabela 3: Matrizes de confusão por modelo (%). Verde: recall $\geq 60\%$; Amarelo: 40%–59%; Vermelho: $< 40\%$ ou erro off-diagonal $> 22\%$.

(a) MLP LOFAR (Melhor Baseline)					(b) SVM MEL ($m=4000$, Proposto)				
	S	M	L	BG		S	M	L	BG
SMALL	46,6	21,2	25,3	7,0	SMALL	50,9	24,3	17,6	7,2
MEDIUM	22,6	61,3	13,8	2,3	MEDIUM	26,0	60,4	12,5	1,1
LARGE	12,8	10,0	74,7	2,5	LARGE	14,9	13,6	69,2	2,3
BG	7,3	3,8	2,6	86,3	BG	11,0	4,9	6,2	77,9

(c) SVM LOFAR ($m=6000$, Proposto)					(d) MLP MEL (Baseline)				
	S	M	L	BG		S	M	L	BG
SMALL	38,2	22,9	28,6	10,3	SMALL	44,8	25,4	17,9	11,8
MEDIUM	17,6	60,5	17,2	4,8	MEDIUM	20,4	64,0	13,1	2,5
LARGE	9,3	10,8	76,3	3,6	LARGE	12,9	15,0	68,6	3,6
BG	6,1	2,8	4,2	86,9	BG	6,1	3,8	5,0	85,1

A análise das matrizes revela padrões de erro distintos e complementares entre os espectros:

- **SMALL é o alvo crítico:** o melhor recall individual é do SVM MEL (50,9%), superando o MLP LOFAR (46,6%), o MLP MEL (44,8%) e o SVM LOFAR (38,2%).
- **Padrão de confusão LOFAR:** modelos LOFAR (MLP e SVM) confundem SMALL com LARGE (respectivamente 25,3% e 28,6% de erro SMALL→LARGE).

Fisicamente, raias harmônicas de embarcações pequenas podem assemelhar-se às de grandes navios a certas distâncias.

- **Padrão de confusão MEL:** modelos MEL confundem SMALL com MEDIUM (respectivamente 25,4% e 24,3% de erro SMALL→MEDIUM), pois a energia de banda larga integrada de ambas as classes se sobrepõe.
- **LARGE e BACKGROUND:** bem classificados por todos os modelos. BG varia de 77,9% (SVM MEL) a 86,9% (SVM LOFAR). LARGE de 68,6% (MLP MEL) a 76,3% (SVM LOFAR).
- **Complementaridade MEL/LOFAR:** os padrões de erro opostos sugerem que MEL e LOFAR capturam informações complementares — motivando estratégias de fusão como trabalho futuro.

8.3. Análise Estatística da Variância

O desvio padrão fold-wise é uma medida da estabilidade do modelo às variações de partição. O SVM MEL apresenta $\sigma_{SP} = 1,12\%$ frente a 1,81% do MLP MEL — redução de **38%**. Isso indica que o SVM Nyström é menos sensível à escolha de quais navios compõem cada fold, propriedade importante para implantação operacional. O SVM LOFAR apresenta $\sigma_{SP} = 1,91\%$, levemente superior ao MLP LOFAR (1,39%), mas ambos dentro de margem compatível com diferenças estatisticamente não significativas.

9. Conclusões

Este trabalho demonstrou que o SVM Gaussiano com aproximação de Nyström constitui uma alternativa competitiva, estável e computacionalmente viável à MLP para classificação acústica submarina no dataset IARA. Três conclusões principais emergem:

1. **Competitividade com variância reduzida:** O SVM LOFAR ($m = 6000$) alcança SP 63,84% e Ac. Bal. 65,48%, a apenas 2,67 p.p. do MLP LOFAR — o melhor baseline do artigo — com desvio padrão comparável. O SVM MEL iguala o MLP MEL em SP com variância 38% menor.
2. **Superioridade no alvo crítico SMALL:** O SVM MEL é o modelo com maior recall para SMALL (50,9%), superando todos os baselines neurais — incluindo o MLP LOFAR (46,6%). Em aplicações onde a classe minoritária é a de maior relevância tática, o SVM MEL é a escolha mais adequada.
3. **Complementaridade MEL/LOFAR:** LOFAR maximiza LARGE/BG por capturar raias harmônicas discretas; MEL favorece SMALL pela integração energética

de banda larga. Os padrões de erro opostos confirmam que as duas representações são complementares.

Do ponto de vista computacional, a aproximação de Nyström reduziu o problema de 1 TB de RAM para ≈ 8 GB (MEL) e ≈ 15 GB (LOFAR), com modelo final de < 100 KB — viável para implantação embarcada em sistemas de sonar passivo.

10. Trabalhos Futuros

1. **Estratégia Híbrida de Dois Estágios:** Classificação hierárquica com especialistas para as classes de menor recall (SMALL e MEDIUM), combinando as forças complementares de LOFAR e MEL. Resultados preliminares são promissores.
2. **Exploração de Novas Técnicas de Extração de Características:** Avaliar DEMON (*Detection of Envelope Modulation on Noise*) — que captura a modulação de amplitude das pás do hélice — e MFCC (coeficientes cepstrais Mel), que capturam fenômenos físicos distintos de LOFAR e MEL, potencialmente beneficiando o alvo SMALL.
3. **Modelos com Dinâmica Temporal:** Avaliar arquiteturas recorrentes como GRU e LSTM, que processam a sequência de frames espectrais ao longo do tempo. O SVM, ao agregar o áudio em um vetor fixo por votação, descarta padrões temporais como os ciclos do hélice e os ritmos de maquinário que distinguem o tamanho dos navios.

Referências

- [1] Silva, F. O. B. da, Fernandes, J. C. V., Soares Filho, W., Souza Filho, J. B. O. e, Spengler, A. & Moura Júnior, N. N. (2025). IARA: An Underwater Acoustic Database. *IEEE Access*, Vol. 13, doi: 10.1109/ACCESS.2025.3585467.
- [2] Santos-Domínguez, D., Torres-Guijarro, S., Cardenal-Martín, J. & Pena-Gimenez, A. (2016). ShipsEar: An underwater vessel noise database. *Applied Acoustics*, 113, 64–69.
- [3] Irfan, M., Jiang, Z., Ali, S., et al. (2021). DeepShip: An underwater acoustic threshold-based database for ship classification. *Scientific Reports*, 11, 23005.
- [4] Williams, C. K. I. & Seeger, M. (2001). Using the Nyström method to speed up algorithms on kernel matrices. *Advances in Neural Information Processing Systems (NeurIPS)*.

- [5] Alpaydm, E. (1999). Combined 5×2 cv F test for comparing supervised classification learning algorithms. *Neural Computation*, 11(8), 1885–1892.
- [6] Nielsen, P. A. (1994). A comparison of three estimators for the background noise level in lofargrams. *IEEE Journal of Oceanic Engineering*, 19(1), 106–110.
- [7] Hummel, H. I., van der Mei, R. & Bhulai, S. (2024). A survey on machine learning in ship radiated noise. *Ocean Engineering*, Vol. 298, Art. 117252.
- [8] Fernandes, J. C. V., Moura Júnior, N. N. de & Seixas, J. M. de (2022). Deep learning models for passive sonar signal classification of military data. *Remote Sensing*, Vol. 14, No. 11, p. 2648.